

第31讲：练习题与答案

建议先独立作答，再看参考答案。

1. Benchmark 的核心组成有哪些？

你的答案：_____

参考答案：任务/数据、输入协议或 `prompt`、参考答案或 `judge`、指标，以及开发/测试 `split`。

2. Accuracy 和 Exact Match 有什么区别？

你的答案：_____

参考答案：Accuracy 是样本级正确率；Exact Match 是一种严格的判定规则，要求输出和参考答案完全匹配。EM 常作为 Accuracy 的具体判定方式之一。

3. Precision、Recall、F1 分别在测什么？

你的答案：_____

参考答案：Precision 看预测为正的样本里有多少真的正；Recall 看所有真阳性里找回多少；F1 是两者调和平均。

4. Pass@k 为什么不能脱离 k 单独比较？

你的答案：_____

参考答案：因为 k 是额外采样预算。k 越大，至少一次成功的概率自然上升，所以不同系统必须在相同 k 或相同总计算预算下比较。

5. LLM-as-a-Judge 最常见的偏差有哪些？

你的答案：_____

参考答案：Position bias、verbosity bias、style bias、self-preference 等；还可能受 reference 和 judge prompt 影响。

6. Human Evaluation 为什么也需要严格协议？

你的答案：_____

参考答案：人类评审也有主观差异、疲劳和顺序偏差，因此需要 rubric、多评审、随机顺序和一致性/仲裁规则。

7. 什么叫 Benchmark Contamination？

你的答案：_____

参考答案：测试题、答案或高度相似内容进入训练/调优过程，使评测混入记忆或过拟合效应，而不再纯粹测泛化。

8. Agent 评测为什么必须同时看 Outcome、Process 和 Cost？

你的答案：_____

参考答案：最终成功可能来自大量重试或危险过程；只有同时看成功率、轨迹/恢复/非法动作与资源成本，才能判断系统是否真正更好。

9. 多 Agent 实验中哪些资源变量必须控制？

你的答案：_____

参考答案：模型调用数、输入/输出 tokens、工具调用数、讨论轮数、judge/verifier 使用、总时间和成本等。

10. 如果你研究“通信能否降低错误相关性”，你会用什么主指标和 baseline？

你的答案：_____

参考答案：主指标可用样本级 error correlation / overlap、collective gain 和 communication cost；baseline 至少包括 no-communication、same-compute single agent、不同通信强度，并控制模型和总 token。

附加实验题

运行 `04_evaluation_passk_judge_bias_demo.py`。观察 Pass@k 随 k 的变化，以及带 position/verbosity bias 的 Toy Judge 在交换 A/B 顺序后是否改变结论。

参考：Pass@k 上升主要来自更多采样机会；Judge

结论若随顺序或长度变化，说明评测器本身正在影响结果。评测协议不是中性的。