


第32讲: Uncertainty & Calibration

模型到底知不知道自己不知道? ——Confidence、Entropy、ECE、Abstention 与 Agent Disagreement

本讲目标

学完后你应该能区分“模型输出概率”“事实置信度”“不确定性信号”和“校准”; 理解 Entropy、Reliability Diagram、ECE、Selective Prediction、Abstention; 并判断多次采样或多 Agent disagreement 什么时候能作为不确定性信号, 什么时候会因为共同错误而失效。



不确定性只有进入决策规则, 才真正变成系统可靠性能力。

先记住一句: 知道“不确定”本身还不够; 只有当系统能据此选择“回答、验证、调用工具或弃答”, 不确定性才真正有价值。

1. 什么叫 Uncertainty?

在 LLM / Agent 系统里，Uncertainty（不确定性）不是单一数字。它可以指：模型对下一个 token 分布很分散、多个采样结果彼此不一致、多个 Agent 观点冲突、检索证据互相矛盾，或者系统对当前任务缺乏足够外部信息。

不确定性来源	例子
Token-level	next-token 概率分布很平
Sequence-level	同一问题多次生成得到不同结论
Knowledge-level	冷门事实或训练后发生的新事实
Evidence-level	RAG 文档冲突/缺失
Agent-level	多个 Agent 对同一问题明显分歧
Environment-level	工具失败、状态未知、外部世界变化

关键

“不确定性”不是“回答一定错误”，而是系统缺少把握的信号。好的研究要看这个信号能否预测错误、触发验证或支持弃答。

2. Confidence 不等于 Correctness

模型可以非常自信地错，也可以低置信度地答对。因此：

High confidence -> not necessarily correct Low confidence -> not necessarily wrong

真正要研究的是：置信度是否和长期真实正确率匹配。

连接第24讲

Token probability 描述的是生成分布，不自动等于命题真值概率。Calibration 研究的是：你给出的“把握程度”到底有没有统计意义。

3. Token Entropy: 概率分布 “散不散”

如果 next-token 概率集中在一个候选上，分布比较尖；如果很多 token 概率接近，分布更平。常用 Entropy（熵）描述这种不确定性：

$H(p) = - \sum_i p_i * \log(p_i)$		
分布	Entropy	直觉
[0.95, 0.03, 0.02]	低	模型几乎只看好一个 token
[0.34, 0.33, 0.33]	高	三个候选都差不多

限制

低 Entropy 也可能稳定地错。它只表示模型分布集中，不表示事实一定正确。

4. Sequence-level


Uncertainty: 为什么一条答案不能只看单个 token?

长回答由许多 token 组成，局部 token 的高概率不代表整段命题可靠。

常见做法包括：多次采样看答案一致性、比较多个候选、计算语义层面的 disagreement，或者用 verifier 检查关键结论。

single token confidence -> local signal multiple samples / semantic agreement -> sequence-level signal

5. Calibration: 什么叫“80% 把握真的约 80% 正确”？



若 0.8 置信度的样本长期只有 0.6 正确率，系统就是过度自信。

一个理想校准系统满足：在所有声称 80% 置信度的样本中，大约 80% 真的正确；声称 60% 的样本中，大约 60% 正确。

过度自信

如果系统说 90% 把握，但实际只有 65% 正确，它就是 over-confident。高风险场景里，这往往比“单纯准确率低”更危险。

6. Reliability Diagram: 把置信度和真实正确率画出来

最常见的校准可视化是 Reliability Diagram: 把预测按置信度分桶, 例如 0.5-0.6、0.6-0.7……, 每个桶比较:

```
average confidence vs empirical accuracy
```

如果点落在 $y=x$ 附近, 说明比较校准; 如果明显在对角线下方, 通常表示过度自信。

7. ECE: 把“偏离对角线”压成一个数字

ECE = Expected Calibration Error。一个常见定义是:

```
ECE = sum_b (n_b / N) * |acc(b) - conf(b)|
```

每个 bin 的置信度与实际准确率差多少, 再按样本量加权。

注意

ECE 会受分桶方式影响, 也不是唯一校准指标。它适合入门和对比, 但不能被当成绝对真理。

8. Brier Score: 概率预测还能怎样评?

如果系统直接给出事件概率 q , 真实标签 $y \in \{0,1\}$, Brier Score 可以写成:

```
Brier = mean((q - y)^2)
```

它同时惩罚错误和过度自信。越小通常越好。

9. Self-reported Confidence: 让模型自己说“我有 80% 把握”可靠吗?

模型可以被 Prompt 要求输出置信度, 例如 0-100%。这种信号有时有用, 但它也是生成文本的一部分, 会受到 Prompt、风格和训练偏好影响。

信号	优点	风险
Self-reported %	易获取	可能只是语言风格
Token probability	底层可量化	不等于事实概率
Sampling disagreement	反映生成不稳定	同源错误时可能全都一致
Verifier score	可直接针对任务	Verifier 本身会错
External evidence	最接近事实约束	成本和工具依赖更高

10. Selective Prediction: 不要求模型每题都答

如果系统能估计不确定性, 就可以只回答高置信样本, 把低置信样本交给工具、人工或拒答。

```
if confidence >= threshold: answer else: verify_or_abstain
```

这叫 Selective Prediction / Selective Classification 的基本思想。

系统思维

可靠性不一定来自“让模型所有题都更强”，也可以来自“把最危险的那部分题识别出来，不强行回答”。

11. Coverage 与 Accuracy / Risk 的权衡

阈值提高	通常发生什么
Coverage	下降：回答的题变少
Selective Accuracy	上升：留下的更容易
Risk	下降：错误率更低
Escalation Cost	上升：更多样本需要验证/人工

这可以画成 Risk-Coverage Curve：横轴是覆盖率，纵轴是错误风险。好的不确定性信号应该能优先过滤掉容易出错的样本。

12. Abstention: 什么情况下应该说“不知道”？

Abstention 不是简单拒绝，而是决策策略。典型触发条件包括：

触发	动作
置信度过低	弃答或请求更多信息
证据冲突	调用检索/Verifier
工具状态未知	先查询环境
多 Agent 严重分歧	升级到独立 Judge / 人工
高风险动作	需要更高阈值和明确确认

风险敏感

不同任务的阈值不能一刀切。低风险聊天和高风险真实操作应该使用不同的 Abstention / Verification 策略。

13. Self-Consistency: 多次采样一致，可以当置信度吗？

一个常见思路：同一问题采样 N 次，如果大多数都得出同一答案，就把 `agreement` 当成较高置信信号。

```
agreement = max_answer_count / N
```

但它有一个大问题：如果模型存在系统性错误， N 次采样可能高度一致地错。

所以
Sampling Agreement
是不确定性信号，不是真值。它必须结合外部验证、已知正确率或错误相关性来解释。

14. Multi-Agent Disagreement: 分歧是否意味着“不确定”？

多个 Agent 对同一问题分歧，常常说明问题更难、信息状态不同或策略不同，因此 Disagreement 可以作为不确定性信号。

现象	可能含义
高度一致 + 正确	大家都掌握了信息
高度一致 + 错误	共享系统性盲点
高度分歧	任务困难 / 信息不对称 / 真实不确定
少数 Agent 持正确证据	聚合机制能否识别 minority truth 成为关键

15. 为什么 Error Correlation 再次出现？

如果多个 Agent 使用同一个模型、同一个 Retriever、同一个 Memory 和同一个 Judge，那么它们的“独立意见”可能并不独立。

```
low observed disagreement != low uncertainty
```

因为低分歧可能只是共同偏差。

与你的研究连接
真正有价值的 Agent disagreement 研究，要同时测 disagreement、error correlation、evidence diversity 和最终 correctness。

16. Epistemic vs Aleatoric: 可以这样理解，但别过度套用

在机器学习里常区分：

类型	通俗理解	LLM/Agent 例子
Epistemic	系统自己“知识不足”	冷门事实、没见过的新 API
Aleatoric	任务本身有随机/模糊性	问题歧义、多个都合理的答案

对现代 LLM，这个划分并不总能干净分解，但作为直觉有用：前者更适合通过数据/检索/工具降低，后者可能需要澄清问题或输出分布。

17. Uncertainty 在 Agent 系统里应该触发什么动作？

不确定性信号	可触发动作
Retriever score 低	扩大检索 / 换关键词
多个证据冲突	调用 verifier / source check
Tool result 异常	重试 / 换工具 / 停止
Plan 分支差异大	搜索更多候选 / 请求帮助
Agent disagreement 高	独立 adjudicator / 人工
State confidence 低	先 Observe, 不要直接 Act

关键

Uncertainty 最有价值的用法，是参与控制策略，而不是只作为论文里一个漂亮的附加分数。

18. Calibration for Actions: 高风险动作为什么需要更高阈值？

一个聊天回答错了，损失可能很小；一个 Agent 删除文件、付款或修改数据库，错误后果可能很大。因此决策阈值应与 action risk 相关：

required confidence / verification strength ↑ as action risk ↑

这也是把模型校准真正接到系统安全上的方式。

19. 小实验 A: Reliability Diagram + ECE

材料包中的 Python 实验先合成一批“系统自报置信度”和真实 0/1 正误标签。系统故意设计成过度自信。

脚本会：

```
1) 置信度 2) confidence 3) empirical accuracy 4) ECE 5) Reliability Diagram
```

你会直观看到：很多点落在 $y=x$ 下方，也就是模型说得比实际更有把握。

20. 小实验 B: Risk–Coverage

同一批样本按 confidence 从高到低排序，逐渐只保留高置信样本。

脚本会计算：

```
coverage = answered / total risk = errors_among_answered / answered
```

如果置信度信号有用，随着 Coverage 降低，Risk 应总体下降。

21. 小实验 C: Agent Disagreement 不是万能真值

实验还模拟两个场景：

场景	现象
Independent-ish agents	分歧更能暴露困难样本
Shared systematic error	Agent 高度一致，但仍然可能一起错

这会再次说明：Agreement / Disagreement 本身只是信号，必须和 correctness、error correlation 一起分析。

22. 常见误区汇总

误区	更准确的理解
模型说 90% = 真有 90% 正确率	必须做 calibration 验证
低 entropy = 正确	可能是稳定的错误
多次采样一致 = 正确	可能共享系统性错误
多 Agent 一致 = 高置信	也可能 groupthink
弃答越多越可靠	Coverage 也会下降，需权衡
ECE 越低一切都好	ECE 只测校准的一部分
不确定性只是分析指标	更重要的是用于触发验证/工具/停止

23. 练习题

- 1) Confidence、Correctness 和 Calibration 三者有什么区别？
- 2) Entropy 高/低分别代表什么？为什么它不等于事实正确率？
- 3) 什么叫 Reliability Diagram？

- 4) ECE 的基本计算思想是什么？
- 5) 什么叫 Selective Prediction？
- 6) Coverage 与 Risk/Accuracy 为什么存在权衡？
- 7) 为什么多次采样一致仍可能稳定地错？
- 8) Multi-Agent Disagreement 什么时候是有用的不确定性信号？
- 9) 为什么低 disagreement 不一定表示低 uncertainty？
- 10) 如果 Agent 要执行高风险 Tool Action，你会怎样把 uncertainty 接到控制策略？

答案见材料包《03_第32讲_练习题与答案.pdf》。

24. 本讲总结

一句话总纲
可靠系统不是要求模型永远“有答案”，而是让它在不确定时能够被识别、校准，并触发验证、检索、工具、人工或弃答。

概念	最短记法
Entropy	分布有多散
Confidence	系统自认为有多把握
Calibration	把握与真实正确率是否匹配
ECE	把分桶校准误差压成一个数
Selective Prediction	只回答高置信样本
Abstention	低置信时不强行回答
Disagreement	多个采样/Agent 的分歧信号
Risk-Coverage	少回答一些，能否更可靠

下一讲：第33讲《Fine-tuning、LoRA、QLoRA：什么时候需要真正修改模型？》。