

第32讲：练习题与答案

建议先独立作答，再看参考答案。

1. Confidence、Correctness 和 Calibration 三者有什么区别？

你的答案：_____

参考答案：Confidence 是系统自认为的把握；Correctness 是样本真实对错；Calibration 是长期统计上 confidence 与实际 correctness 是否匹配。

2. Entropy 高/低分别代表什么？为什么它不等于事实正确率？

你的答案：_____

参考答案：高 entropy 表示概率分布更分散，低 entropy 表示更集中；但集中到错误答案时仍然会稳定地错，因此它不是事实真值概率。

3. 什么叫 Reliability Diagram？

你的答案：_____

参考答案：把样本按置信度分桶，比较每个桶的平均置信度与真实准确率；理想情况下点应接近 $y=x$ 。

4. ECE 的基本计算思想是什么？

你的答案：_____

参考答案：计算每个置信度 bin 的 $|\text{accuracy}-\text{confidence}|$ ，再按 bin 样本占比加权平均。

5. 什么叫 Selective Prediction？

你的答案：_____

参考答案：系统只对高置信样本给出直接答案，对低置信样本弃答、验证或升级处理。

6. Coverage 与 Risk/Accuracy 为什么存在权衡？

你的答案：_____

参考答案：提高阈值会过滤更多困难样本，Coverage 下降；若 uncertainty signal 有效，剩余样本的错误率会下降、准确率上升。

7. 为什么多次采样一致仍可能稳定地错？

你的答案：_____

参考答案：因为同一个模型可能存在共享的系统性偏差，多次采样只是重复同一错误分布。

8. Multi-Agent Disagreement 什么时候是有用的不确定性信号？

你的答案：_____

参考答案：当 Agent 的信息、模型、工具或经历具有足够独立性，分歧往往能指示困难样本；必须同时检查 error correlation。

9. 为什么低 disagreement 不一定表示低 uncertainty?

你的答案: _____

参考答案: 多个 Agent 可能共享同一错误来源、Retriever 或 Judge, 从而高度一致地犯同样错误。

10. 如果 Agent 要执行高风险 Tool Action, 你会怎样把 uncertainty 接到控制策略?

你的答案: _____

参考答案: 提高动作阈值, 并要求额外 verifier、外部证据或人工确认; 若 State/参数/目标不确定则先 Observe/Query, 而不是直接执行。

附加实验题

运行 `04_uncertainty_calibration_demo.py`。观察 ECE、Reliability Diagram 和 Risk-Coverage Curve。请回答：如果一个模型 Accuracy 很高但严重 over-confident，在高风险 Agent 系统中为什么仍然危险？

参考：因为系统会把错误样本误判为“足够确定”，从而跳过检索、验证或人工确认；校准差会直接破坏基于阈值的控制策略。