

第33讲：练习题与答案

建议先独立作答，再看答案。

1. Prompt、RAG、Memory、Fine-tuning 的最根本区别是什么？

你的答案：_____

参考答案：Prompt/RAG/Memory 主要改变当前或未来 Context 中可见的信息；Fine-tuning 直接更新模型参数，改变长期输入到输出的映射。

2. 什么场景下优先 RAG，而不是 Fine-tuning？

你的答案：_____

参考答案：知识经常更新、需要私有/最新文档、需要来源可追溯时，RAG 更自然。

3. SFT 与 Continued Pretraining 有什么区别？

你的答案：_____

参考答案：SFT 使用结构化输入-理想输出教任务行为；Continued Pretraining 继续用语言建模目标吸收领域语料分布。

4. Full Fine-tuning 为什么显存成本高？

你的答案：_____

参考答案：除了权重，还要保存梯度、优化器状态和激活；训练内存远高于仅推理加载模型。

5. LoRA 的核心低秩思想是什么？

你的答案：_____

参考答案：假设任务适配所需的 ΔW 可由两个低秩矩阵 $B @ A$ 表示，冻结原 W ，只训练 A/B 。

6. 为什么 LoRA 的可训练参数量远小于完整矩阵？

你的答案：_____

参考答案：完整矩阵需要 $d_{out} * d_{in}$ ；LoRA 只需 $r * d_{in} + d_{out} * r$ ，且 r 通常远小于维度。

7. QLoRA 为什么更节省显存？

你的答案：_____

参考答案：基础模型权重以低比特量化形式冻结加载，同时只训练 LoRA adapter。

8. 什么叫 Catastrophic Forgetting？

你的答案：_____

参考答案：模型在新任务/领域上适配后，原有通用能力或旧任务性能明显下降。

9. 为什么 Fine-tuning 也必须严格划分 Train/Validation/Test？

你的答案: _____

参考答案: 因为同样会过拟合; 如果在测试集上反复调 rank、学习率、数据等, 结论会失真。

10. 如果研究 Agent 功能性异质性, LoRA 可以怎样作为实验变量?

你的答案: _____

参考答案: 给不同 Agent 用不同经历/数据训练 LoRA adapter, 控制 base model 与推理预算, 再测行为差异、错误相关性和集体收益。

附加实验题

运行 04_lora_low_rank_demo.py。比较 Full ΔW 与 rank=1/2/4 的低秩近似。观察 trainable parameter ratio 与 reconstruction error。

参考：当目标变化本身接近低秩时，小 rank 可以用很少参数逼近；若任务需要更复杂变化，rank 太小会留下明显误差。