

第34讲：Open-source / Open-weight LLM 速查卡

一句话：“模型” = 架构 + 权重 + tokenizer + 配置；“跑模型” 还要 runtime + hardware。

模型包是什么？

对象	作用
config	搭模型骨架
weights/checkpoint	训练后的参数
tokenizer	文字 -> token
chat template	对话 -> token 格式
model card	用途/限制/许可证

常见格式

Safetensors = 张量存储格式；GGUF = ggml/llama.cpp 生态模型格式。两者都不是推理引擎。

Runtime 怎么选？

工具	典型定位
Transformers	研究/训练/本地推理
vLLM	GPU serving / 高吞吐 API
llama.cpp	GGUF / CPU+GPU / 本地

科研复现

repo_id + revision + tokenizer + chat template + runtime/version + quantization + hardware + generation params

API vs Local

API：供应商托管底层栈；Local：你控制权重、runtime、硬件和数据路径。

研究提醒：“同一个模型名” 不等于同一个实验对象；revision、quantization、runtime、chat template 和 sampling 都要记录。