

第34讲：练习题与答案

建议先独立作答，再看答案。

1. Architecture、Checkpoint、Weights 三者有什么区别？

你的答案：_____

参考答案：Architecture 定义模型结构；Weights 是具体参数张量；Checkpoint 是某个训练阶段保存的一整套权重状态，通常对应一个可加载版本。

2. 为什么 Tokenizer 必须和模型匹配？

你的答案：_____

参考答案：模型的 embedding 和词表是按训练时 tokenizer 学到的。错误 tokenizer 会产生不同 token IDs，使输入表示失真。

3. Safetensors 与 GGUF 分别是什么层次的东西？

你的答案：_____

参考答案：二者都是模型文件/张量格式，不是模型架构。Safetensors 是通用安全张量格式；GGUF 是 ggml/llama.cpp 生态常用模型格式并携带 metadata。

4. Transformers、vLLM、llama.cpp 的定位有什么不同？

你的答案：_____

参考答案：Transformers 是通用 Python 模型库；vLLM 更偏 GPU 高吞吐 serving；llama.cpp 是 C/C++ 跨硬件本地 inference runtime，常使用 GGUF。

5. 为什么 `from\_pretrained()` 不等于调用商业 API？

你的答案：_____

参考答案：它通常会把模型配置、tokenizer 和权重下载/加载到本地进程，由本地 CPU/GPU 计算；商业 API 的推理发生在远程供应商服务器。

6. 本地部署与 API 的系统边界有什么不同？

你的答案：_____

参考答案：本地由你管理权重、runtime、KV Cache、硬件和数据；API 由供应商托管这些底层部分，你主要控制请求和应用逻辑。

7. 为什么模型 revision / commit 对科研复现很重要？

你的答案：_____

参考答案：仓库 main 可能更新权重、tokenizer 或模板；固定 revision 能确保未来加载到同一版本。

8. 为什么同一 checkpoint 在不同 runtime 下可能略有不同？

你的答案：_____

参考答案: 量化、数值精度、kernel、采样实现、chat template、默认 generation config 和 runtime bugfix 都可能造成差异。

9. 做 Agent Systems 论文时, 本地模型实验至少应记录哪些部署变量?

你的答案: _____

参考答案: checkpoint/revision、tokenizer/chat template、runtime/version、精度/量化、硬件、context length、sampling 参数、batch/concurrency 等。

10. 什么情况下优先 API, 什么情况下优先本地模型?

你的答案: _____

参考答案: 快速验证/使用最强模型优先 API; 需要固定版本、量化/LoRA、serving 机制研究、大量重复运行或数据完全本地时优先本地。

附加实验题

运行 `04_local_deployment_memory_estimator.py`。比较 1B/7B/14B/32B 模型在 BF16、INT8、理想 INT4 下的纯权重内存。然后回答：为什么这仍然不能直接告诉你需要多大显存？

参考：真实推理还需要 KV Cache、runtime workspace、量化 metadata、临时 buffer、并发请求等；权重大小只是第一数量级。