

第35讲：LLM 实验可复现性

为什么同一个 Prompt

重跑结果会变？——Seed、Sampling、重复实验、置信区间与统计显著性


本讲目标

学完后你应该能解释：为什么相同 Prompt 也可能得到不同结果；固定 seed

能做什么、不能做什么；为什么 API

模型和本地模型都要做重复实验；怎样用均值、标准差、置信区间、paired comparison 和 effect size 判断“方法真的更好”还是“只是一次跑赢”。

实验结果 = 多个随机与确定性因素共同作用



复现性不是只固定 seed，而是固定“整个实验协议”。

先记住一句：科研复现性不是“我把 temperature=0

就行了”，而是把模型版本、Prompt、数据、采样、Runtime、工具环境和评测协议都固定并记录。

1. 为什么同一个 Prompt 重跑会变?

LLM/Agent 结果可能同时受随机性和环境变化影响。

来源	例子
Sampling	Temperature / Top-p 导致随机 token 选择
Seed	随机数序列不同
Model Version	API 模型或 checkpoint 更新
Runtime	kernel / quantization / precision 差异
Tool / Web	外部搜索、API、数据库结果变化
Agent State	Memory、历史轨迹、共享状态不同
Evaluation	LLM Judge 自身也可能有随机性

关键

“输入文字一样”并不意味着整个实验状态一样。必须记录系统的完整状态与协议。

2. Temperature=0 是不是就完全确定?

Temperature=0 通常意味着 greedy / near-greedy 解码，能显著降低 sampling randomness。

但“低随机”不等于跨机器、跨版本、跨服务绝对 bit-for-bit 一致。

即使 temperature=0 也可能变化	原因
API 模型升级	底层权重或 serving 变化
不同硬件/数值精度	浮点计算顺序和 kernel 不同
Tool / Retrieval 变化	外部输入变了
并行/服务实现差异	运行时路径可能变化

3. Seed：它到底控制什么?

Seed（随机种子）用于初始化伪随机数生成器。相同代码、相同随机算法、相同执行路径下，同一个 seed 通常会产生相同随机序列。

<code>random.seed(42)</code> <code>np.random.seed(42)</code>
不要神化 Seed Seed 只是控制一部分随机来源。模型版本、CUDA kernel、外部工具、并发调度等仍可能让结果变化。


4. Seed 在科研里应该怎么用?

用途	做法
Debug	固定 seed，方便重现一次错误
A/B 公平比较	A/B 使用同一组 seed

用途	做法
最终结论	不要只用一个 seed，应跨多个 seed/重复运行
随机训练	报告所有或预先指定的 seeds

固定一个 seed 适合定位问题；证明方法稳定则需要多个 seed。

5. 一次实验为什么不够？



一次跑赢可能只是随机波动；重复实验才能估计稳定效应。

假设方法真实平均准确率只有 78%，一次 100 题实验完全可能偶然跑到 82%。

如果你只挑这一次报告，就会把随机波动误认成算法改进。

科研纪律
不要“跑很多次只报最好一次”。这相当于选择性报告，会严重高估方法效果。

6. 重复实验到底重复什么？

实验类型	重复单位
Sampling-heavy LLM	同一题多次采样
Agent trajectory	同一任务独立 episode
Fine-tuning	不同训练 seed / 初始化
Multi-Agent	不同系统 seed / agent sampling
API 实验	跨请求重复并记录时间/版本

你需要根据随机来源决定重复层级，而不是机械地说“重复三次”。

7. Mean 和 Standard Deviation: 先学会描述波动

如果 5 次运行准确率是:

```
0.77, 0.80, 0.76, 0.81, 0.79
```

平均值 `mean` 表示中心水平; 标准差 `std` 表示不同 `run` 之间的波动。

报告成:

```
Accuracy = 0.786 ± 0.021 (mean ± std)
```

区别

标准差描述“数据有多散”; 置信区间描述“我们对平均效应估计有多不确定”。两者不是一回事。

8. 95% Confidence Interval: 到底是什么意思?

置信区间不是说“真实值有 95%

概率落在这一个具体区间里”这么简单。更严谨的频率学解释是: 如果重复使用同样构造方法, 约 95% 的区间会覆盖真实参数。

对入门阶段, 你可以把它理解成: 估计值周围的不确定范围。

```
mean ± 1.96 * SE
```

其中 SE (Standard Error) 大致随样本数增加而下降。

9. Bootstrap: 不想推复杂公式时的通用方法

Bootstrap 的直觉非常简单: 从已有样本中“有放回地重复抽样”, 每次重新计算你关心的统计量。

```
repeat B times: resample data with replacement compute metric use percentiles as CI
```

它特别适合 Accuracy difference、Agent success rate difference 等复杂统计量。

注意

Bootstrap 也不是万能的; 样本独立性、数据规模、层级结构都会影响是否合理。这里先掌握直觉。

10. Statistical Significance: p-value 到底在问什么?

一个典型显著性检验问的是:

如果“真实没有差异”这个零假设成立, 观察到当前这么大或更极端差异有多罕见?

p-value 小, 不等于“方法有 95% 概率是真的”; 它也不告诉你效果有多大。

不要迷信

Statistical significance $\neq$ practical significance。一个 0.2%

提升在超大样本上可能显著, 但科研价值仍可能很小。

11. Effect Size: 差异到底有多大?

Effect Size 关注“提升幅度”, 而不是仅关注是否显著。

例如:

Method A = 72.1% Method B = 72.4% Difference = +0.3 percentage points

即使统计显著，也要问：+0.3 个百分点是否值得额外 3 倍 token 和 10 倍工具调用？

12. Paired Comparison: 为什么同一批题上比较更好？

Paired comparison: 同一批题直接比较 A 和 B

Item	Method A	Method B	Difference
1			0
2			+1
3			-1
4			+1

配对设计利用“同一题”的信息，比只比较两个总体均值更直接。

A 和 B 如果都在同一批 benchmark 样本上测试，结果天然是 paired 的。

你可以直接分析每个样本：

情况	信息
A对 B对	两者都能做
A错 B对	B真正修复了一个错误
A对 B错	B引入了回归
A错 B错	共同失败

这比只比较两个总体平均准确率更能解释方法机制。

13. McNemar / Paired Bootstrap: 为什么适合 Benchmark 对比?

对于同一批二元对错结果, McNemar 检验关注的正是:

```
A□B□ vs A□B□
```

如果 B 真更强, 通常希望前者显著多于后者。

如果指标更复杂, 也可以对样本做 paired bootstrap, 直接估计 B-A 的置信区间。

入门重点

你不必现在背统计检验公式, 但要形成意识: 同样本比较应该利用配对结构。

14. Multiple Comparisons: 为什么试 50 个配置, 总能碰到 “最好一个” ?

如果你试很多 prompt、rank、temperature、agent roles、communication rounds, 总会有某个配置因为随机波动显得特别好。

```
try many configs -> pick best on test -> optimistic bias
```

所以超参数选择应该在 validation set 上完成, 最终 test set 尽量只用来一次性报告。

15. Researcher Degrees of Freedom: 不是作弊, 也会不知不觉产生偏差

常见自由度包括:

自由度	例子
Prompt	换措辞直到结果变好
Seed	挑最好 seed
Metric	只报有利指标
Subset	删掉难例/异常例
Stopping	看到显著就停止继续收样本
Judge	换到偏好自己方法的 Judge

解决思路

尽可能预先固定 protocol; 记录所有主要实验; 把 exploratory 与 confirmatory 分开。

16. API 模型为什么更需要记录日期和版本?

商业 API 可能在后台升级 serving 或模型版本; 即使公开 model id 不变, 行为也可能出现漂移。因此至少记录:

```
provider + model id + date/time + sampling params + repeated trials + raw outputs
```

如果供应商提供更具体的版本或 snapshot, 则优先固定。

17. 本地模型为什么也不是天然可复现？

即使 checkpoint 固定，也可能因为：

变量	影响
Runtime version	kernel/实现变化
Quantization	数值近似变化
GPU/CPU	硬件和精度路径变化
Chat template	输入 token 改变
Seed	采样路径改变
Batching / concurrency	服务执行路径变化

所以第34讲的部署清单，也是 reproducibility 清单的一部分。

18. Agent 实验：随机性比普通问答更复杂

Agent 一次 episode 中有很多随机节点：

```
plan -> tool select -> tool result -> memory -> replan -> ...
```

一个早期随机 token 就可能让整个 trajectory 分叉。因此 Agent 实验通常要重复多个 episode，而不是每个任务只跑一次。

Agent 随机来源	例子
Planning	选择不同子目标
Tool Use	调用不同工具/参数
Retrieval	不同候选被选中
Environment	网页/服务状态变化
Communication	多 Agent 消息顺序变化
Judge	聚合/评分存在随机性

19. Multi-Agent：为什么“3% 提升”尤其值得怀疑？

多 Agent 引入更多模型调用和交互，方差可能更大。

如果 Single Agent = 71%，Multi-Agent = 74%，先不要立刻说“协作机制提升 3%”。

至少还要看：

要看什么	原因
重复 runs 的分布	3% 是否稳定
paired per-item results	到底修了哪些样本
CI of difference	提升区间是否跨 0
total tokens/calls	是否靠更多 compute
error correlation	是否真的改变依赖结构

20. 一套适合 Agent Systems 的最低重复实验模板

阶段	建议
Development	固定少量 seed 快速调试
Validation	多个 seed / repeated episodes 选方案
Final Test	冻结方法后重复运行并报告 mean/CI
Comparison	同样本 paired comparison
Resource	每次记录 tokens/calls/tool calls
Failures	保留轨迹与 failure type

不是机械数字
“重复 3 次/5 次/10 次”没有万能答案。任务数量、随机性强度、成本和期望效应大小共同决定需要多少重复。

21. 小实验 A：一次跑赢为什么可能骗人？

材料包 Python 实验模拟两个方法：

方法	真实成功率
A	0.70
B	0.73

每次 benchmark 只有 100 题。脚本重复很多次，会显示：虽然 B 真实更好，但某些单次实验中 A 仍会跑赢 B。

22. 小实验 B：Bootstrap Difference CI

脚本还会在同一批 paired 样本上，计算：

```
difference = accuracy_B - accuracy_A
```

并用 paired bootstrap 重采样样本，得到 difference 的 95% CI。

如果区间很宽或跨过 0，就说明当前样本下“B 更好”的证据仍不稳定。

23. 小实验 C：Seed 对随机生成的影响

同一个离散概率分布，用 seed=1 和 seed=2 采样 20 次，会得到不同序列；重复使用 seed=1 则会重现同一序列。

这个实验帮助你把“seed 控制伪随机序列”和“整个 LLM 系统完全确定”区分开。

24. 常见误区汇总

误区	更准确的理解
Temperature=0 = 完全可复现	只能显著减少 sampling randomness
固定 seed 就够了	还要固定模型、runtime、数据、工具等
重复 3 次一定够	没有万能次数
均值更高就一定更好	要看方差/CI/配对结果
p<0.05 = 方法很有价值	统计显著不等于实际效应大
只报最好 seed	会高估方法
多 Agent 高 3% 就证明协作有效	还需 CI、paired、compute-matched

25. 练习题

- 1) 为什么同一个 Prompt 重跑结果可能不同？
- 2) Temperature=0 能解决哪些随机性，不能解决哪些？

- 3) Seed 的作用是什么？为什么最终论文不能只用一个 seed？
- 4) Standard Deviation 和 Confidence Interval 有什么区别？
- 5) Bootstrap 的直觉是什么？
- 6) Statistical Significance 和 Effect Size 有什么区别？
- 7) 为什么同一 benchmark 上比较两个方法应该优先考虑 paired analysis？
- 8) 什么叫 Multiple Comparisons / 选择最好配置偏差？
- 9) Agent 实验为什么比单轮 LLM 更需要 repeated episodes？
- 10) 如果 Multi-Agent 比 Single-Agent 高 3%，你会要求哪些证据后才相信它是机制效应？

答案见材料包《03_第35讲_练习题与答案.pdf》。

26. 本讲总结

一句话总纲 可靠的 LLM/Agent 结论，不来自某一次漂亮结果，而来自固定协议下的重复实验、方差估计、配对比较、置信区间和透明的资源/失败报告。	
概念	最短记法
Seed	控制一部分伪随机序列
Repeated Trials	估计结果波动
Mean / Std	中心 + 离散程度
Confidence Interval	平均效应估计的不确定范围
Bootstrap	重复重采样估计统计量分布
Effect Size	提升到底有多大
Paired Analysis	同一批样本逐项比较
Compute Matching	别把多花预算当方法进步
下一讲：第36讲《LLM 科研实验最小闭环：从研究问题到论文表格》。	