

第35讲：LLM 实验可复现性速查卡

一句话：一次结果是样本；重复实验和统计分析才让它变成证据。

复现要固定什么？

层	至少记录
Model	id / revision / date
Prompt	system / template
Sampling	temperature/top-p/seed
Data	split / benchmark
Runtime	version / quantization
Tools	external state
Judge	model/prompt/version

报告什么？

mean · std · 95% CI · paired difference · effect size · tokens/calls/cost

研究原则：开发期可以固定 seed 方便调试；最终结论必须跨重复运行，报告波动和效应大小。

核心区别

概念	一句话
Std	不同 run 有多散
CI	均值估计有多不确定
p-value	零差异下结果有多极端
Effect Size	实际提升有多大
Paired	同一题上逐项比较

Agent Systems

同一任务要重复 episode; Multi-Agent 比较必须看 CI、paired errors、error correlation 和 compute-matched baseline。

禁止习惯

只报最好 seed · 测试集反复调参 · 只看均值 · 把更多 calls 当算法提升