

第35讲：练习题与答案

建议先独立作答，再看答案。

1. 为什么同一个 Prompt 重跑结果可能不同？

你的答案：_____

参考答案：Sampling、seed、模型版本、runtime 数值差异、外部工具/网页状态、Agent memory/state、Judge 随机性等都可能改变轨迹。

2. Temperature=0 能解决哪些随机性，不能解决哪些？

你的答案：_____

参考答案：主要减少 sampling randomness；不能保证 API 版本、runtime、硬件、外部工具和并发执行路径完全相同。

3. Seed 的作用是什么？为什么最终论文不能只用一个 seed？

你的答案：_____

参考答案：Seed 固定伪随机序列，便于 debug 和公平配对；但一个 seed 可能偶然有利，不能代表平均性能和稳定性。

4. Standard Deviation 和 Confidence Interval 有什么区别？

你的答案：_____

参考答案：Std 描述 runs 本身的离散程度；CI 描述对总体平均效应估计的不确定范围。

5. Bootstrap 的直觉是什么？

你的答案：_____

参考答案：从已有样本中有放回重采样很多次，重复计算统计量，用得到的经验分布估计不确定性和置信区间。

6. Statistical Significance 和 Effect Size 有什么区别？

你的答案：_____

参考答案：显著性问差异是否难以用随机波动解释；effect size 问差异实际有多大、是否值得成本。

7. 为什么同一 benchmark 上比较两个方法应该优先考虑 paired analysis？

你的答案：_____

参考答案：同一题的难度被共享，可以直接分析 A错B对、A对B错，减少样本难度差异的干扰。

8. 什么叫 Multiple Comparisons / 选择最好配置偏差？

你的答案：_____

参考答案：尝试大量配置后只挑最好结果，会因为随机波动把最幸运配置选出来，使效果被高估。

9. Agent 实验为什么比单轮 LLM 更需要 repeated episodes?

你的答案: _____

参考答案: 多步 trajectory 有更多随机分叉点, 早期微小差异会放大到最终结果, 方差通常更大。

10. 如果 Multi-Agent 比 Single-Agent 高 3%, 你会要求哪些证据后才相信它是机制效应?

你的答案: _____

参考答案: 重复 runs、difference CI、paired per-item analysis、error correlation、相同 model/calls/tokens/tools 的 compute-matched baseline, 以及 failure/trajectory 分析。

附加实验题

运行 `04_reproducibility_statistics_demo.py`。观察 A/B 的单次比较、100 次重复实验、paired bootstrap CI 和 seed 序列。

参考：你会看到：真实 B 更好，但某些单次实验 A 仍可能胜出；重复实验才能看到长期优势。paired bootstrap 则把“不确定性”直接加到差异本身上。