


第36讲：LLM / Agent 科研实验最小闭环

从 Research Question、Hypothesis、Variables、Baseline、Ablation 到最终论文表格

本讲目标

把前35讲真正转成科研能力。学完后你应该能把一个观察到的现象，变成可证伪 Research Question；定义变量、baseline、control、ablation、repeated trials 和统计指标；并最终做出一张能同时说明 Outcome、Mechanism、Cost 的论文主表。



研究不是一条直线：证据可以让假设被修正、缩小，甚至被否决。

先记住一句：科研不是“先想一个方法，再想办法证明它有效”；科研更像“先把现象和问题定义清楚，再设计一个可能证明你错的实验”。

1. 科研的起点: Phenomenon, 不是 Method

一个常见错误流程是:

```
观察 ->  benchmark ->  baseline  ->  
```

更稳妥的流程是:

```
观察 -> 观察 -> 观察 -> 观察 -> 观察 -> 观察
```

与你之前确定的科研原则一致
先观察真实现象/失败模式，再提出研究问题；方法只是用来解释、控制或利用该现象的工具，而不是科研起点。

2. Phenomenon 和 Idea 有什么区别?

Phenomenon	Idea
在数据/系统里真实观察到的规律或异常	你觉得可能有效的做法
例如: Agent 数增加但投票收益很小	例如: 给 Agent 分配不同 persona
需要验证是否稳定、普遍、可重复	需要验证是否真的改变目标机制
可以支持多个不同方法	通常只是一个候选干预
例子 “多 Agent 经常形成错误共识”是现象；“加一个 Critic Agent”是方法 idea。不要把二者混成一个东西。	

3. 从现象变成 Research Question

好的 Research Question 应该具体、可测、可被实验否定。

模糊问题:

```
Do diverse agents improve collective intelligence?
```

更具体的问题:

```
Under matched inference budget, does reducing pairwise error correlation among equally accurate agents increase majority-vote collective gain?
```

后者已经明确: 预算要匹配、单体准确率要控制、核心机制是 error correlation、结果指标是 collective gain。

4. Hypothesis: 必须允许自己被证明错

一个可证伪假设可以写成:


```
H1: At matched individual accuracy and compute, lower pairwise error correlation leads to higher collective gain.
```

相应的零假设:

```
H0: After controlling individual accuracy and compute, error correlation has no systematic relationship with collective gain.
```

科学味从这里开始
如果无论实验结果怎样你都能说“我的理论是对的”，那它就很难被检验。

5. Variables: 研究问题怎样变成可操作实验？



Model · Prompt · Data · Budget · Tools · Judge · Runtime

否则你看到的“效果”可能来自别的变量。

变量类型	本案例
Independent Variable	Agent experience / information assignment, 或人为控制共享错误强度
Dependent Variable	Collective Gain、system accuracy
Mechanism Variable	Pairwise Error Correlation / Error Overlap
Control Variables	Base model、task set、prompt、tools、number of agents、total calls/tokens
Nuisance / Confound	Judge bias、不同上下文长度、不同工具权限、不同模型强度

6. Control Variables: 为什么“只改一个变量”如此重要？

假设 Diverse Agent 组用了更强模型、更长 Prompt、更多 Tool Calls，那么最后更强时你无法知道原因。

因此在一个机制实验里，要尽量固定：

model + prompt length + task + tool access + total calls + token budget + judge

现实世界很难完全只改一个变量
所以科研不是追求绝对纯净，而是尽量减少混杂、记录剩余混杂，并通过消融/附加实验验证解释。

7. Baseline: Baseline 不是随便找一个弱方法

Baseline 的作用是排除其他更简单解释。

Baseline	排除什么解释
Single Agent	是否根本不需要多 Agent
Single Agent Self-Consistency x3	收益是否只是多个采样

Baseline	排除什么解释
Homogeneous Multi-Agent x3	收益是否来自“多 Agent”本身
Compute-matched Single Agent	收益是否来自更多 token/calls
Oracle / Upper Bound (可选)	理论上还能提升多少

审稿人思维
一个好的 baseline 就是在问：有没有更简单、更便宜的解释也能得到同样收益？

8. Compute-matched Baseline: Agent 论文里最容易漏掉的一项

如果 3 Agent 每题共调用模型 3 次，而 Single Agent 只调用 1 次，那么比较并不公平。
至少应该有：

Single Agent x1 Single Agent Self-Consistency x3 Multi-Agent x3

这样才能问：Multi-Agent 的结构是否超过“同一个模型多试几次”。

9. Treatment Conditions: 不要一次改五个机制

本讲示例把条件简化成：

条件	设计意图
Single Agent	最低成本基线
Self-Consistency x3	同模型、同预算的多次采样
Homogeneous Multi-Agent x3	多 Agent，但高度同质
Experience-Diverse Multi-Agent x3	相同单体平均能力，但在不同任务子类型上互补

这样最终可以把“数量”“预算”“同质/异质”几个因素逐步拆开。

10. Primary Metric: 论文必须先知道主指标是什么

本案例主指标可以是：

Collective Gain = System Accuracy - Mean Individual Accuracy
--

机制指标：


Mean Pairwise Error Correlation

成本指标：

Model Calls + Tokens (+ Tool Calls / Latency if applicable)

避免指标漂移 实验出来以后再挑“最好看的指标”作为主指标，会增加选择性报告风险。最好提前定义 primary / secondary metrics。
--

11. 为什么只看最终 Accuracy 不够？



可信结论通常需要 Outcome + Mechanism + Cost 三角同时成立。

可信的机制论文至少要回答三个问题：

层	问题
Outcome	系统最后真的更好吗？
Mechanism	你声称的机制真的发生了吗？
Cost	是不是只是多花了资源？

只证明 Outcome，往往只能说“这个配置有效”；同时证明 Mechanism，才更接近科学解释。

12. Ablation：把系统拆开，问“谁真正贡献了效果？”

假设完整系统包含：Private Memory + Communication + Majority Vote。可以做：

Ablation	问题
No private memory	长期经历差异是否必要？
Shared memory only	信息同步是否消除异质性？
No communication	通信是否提供额外收益？
No aggregation / single delegate	聚合机制是否必要？
Random persona diversity	真实经历异质性是否优于表面 persona 差异？

Ablation 的逻辑

完整方法有效后，移除一个组件。如果效果消失或显著下降，才说明该组件可能贡献了机制。

13. Positive Control / Negative Control：让实验更有解释力

控制	用途	示例
Negative Control	理论上不应产生目标机制	随机改 Agent 名字/无关 persona
Positive Control	已知会改变机制	人为制造低/高共享错误

如果连 Positive Control 都测不出差异，说明你的指标或实验设计可能不敏感。

14. Manipulation Check: 你真的操纵到了想操纵的东西吗?

例如你说“我让 Agents 更异质”，不能只看 Prompt 不一样。应该直接测：

Behavior Divergence / Tool-use Divergence / Memory Divergence / Error Correlation

这叫 manipulation check：确认实验操纵确实改变了目标中间变量。

15. Repeated Trials: Agent 系统不能每题只跑一次

第35讲已经说明多步 Agent trajectory 方差较大。本案例至少需要跨 run 重复，报告：

mean + std / 95% CI + paired per-item comparison

并保存 raw trajectory 以便失败分析。

16. Sample Size: 不是越大越好，也不是随便 100 题

样本量由预期效应大小、方差、统计功效、任务成本共同决定。

入门阶段至少要形成两个原则：

1) 1-2 2) Agent pilot

17. Failure Taxonomy: 失败分析不是附录装饰

失败类型	例子
Shared Knowledge Error	所有 Agent 都缺同一事实
Communication Cascade	一个错误传播成共识
Retrieval Failure	关键证据未召回
Tool Failure	调用/参数/权限错误
Aggregation Failure	少数正确意见被多数错误压制
Budget Exhaustion	尚未收敛就用完 token/calls

科学价值
失败分类能帮助你从“平均分提高”进一步发现新的稳定现象，这往往又是下一篇论文的起点。

18. 实验矩阵：真正开始跑之前先把表画出来

Condition	Agents	Calls/item	Experience	Communication
Single	1	1	shared/general	none
SC-x3	1 (3 samples)	3	same	none
Homogeneous MA	3	3	same/shared	limited
Experience-Diverse MA	3	3	different/complementary	limited

在实验开始前画出这张矩阵，你会立刻看到哪些变量没有控制。

19. 本讲 Toy Experiment: 它到底在演示什么?

为了不把代码变成复杂 Agent 框架，我们直接模拟 correctness pattern。关键不是模拟得像真实 LLM，而是训练科研思维：

条件	机制
Single	每题 70% generalist
SC-x3	同一模型 3 次采样，共享 item difficulty
Homogeneous MA	3 Agent 平均 70%，但有较强共同正确/错误事件
Experience-Diverse MA	3 Agent 平均仍约 70%，但各自在一种任务类型上专长

于是我们能在单体平均准确率近似相同的前提下观察错误相关性与集体收益。

20. 结果应该怎样写成“论文主表”？

本讲材料包自动生成 `05\_toy\_paper\_style\_main\_table.txt`，表里同时放：

Individual Accuracy System Accuracy 95% CI Collective Gain Error Correlation Calls Tokens

这比只放一列 Accuracy 更有解释力。

主表设计原则
主表优先呈现回答研究问题必须的信息；其他超参数、额外 benchmark、详细失败案例可以放次表或附录。

21. 结果出来以后，怎样避免“强行讲故事”？

结果	正确处理
Outcome ↑, mechanism ↓	机制解释可能不对，寻找其他原因
Mechanism ↑, outcome 不变	机制发生了，但没转化成实际收益
Outcome ↑, cost 暴涨	讨论效率/实用性，不只写性能提升
CI 跨 0	证据不足，不能强断言提升
Ablation 无变化	该组件可能并非必要
结果和假设相反	报告并重新解释，不要删掉

科研最重要的能力之一
让数据有权否定你的想法。假设被否决不是实验失败；无法区分假设真假的实验才更接近失败。

22. Discussion: 论文结论应该有多大？

如果实验只在一个 benchmark、一个模型家族、三个 Agent 上完成，就不要写成“diversity universally improves collective intelligence”。

更合适的是：

Under our controlled setting, lower error correlation is associated with larger collective gain at matched compute.

也就是让 claim 范围与证据范围匹配。

23. Threats to Validity: 主动告诉审稿人哪些地方还不确定

类型	本案例可能问题
Internal Validity	异质性操纵是否还改变了其他变量?
External Validity	结果能否扩展到别的模型/任务?
Construct Validity	Error Correlation 是否充分代表功能异质性?
Statistical Validity	样本量/重复次数是否足够?

写局限并不会自动削弱论文。相反，它说明你知道证据能支持到哪里。

24. 从实验结果到论文结构

论文部分	应该回答什么
Introduction	现象为什么重要? 现有研究缺什么?
Research Question	你到底问了什么可验证问题?
Method / Setup	你如何操纵变量和控制混杂?
Results	Outcome、Mechanism、Cost 分别怎样?
Ablation	哪个组件真的必要?
Failure Analysis	系统在什么条件下失效?
Discussion	结果意味着什么，不意味着什么?
Limitations	证据边界在哪里?

25. 一套你以后可以固定使用的实验模板

每个新课题先写一页：

Phenomenon: Research Question: Hypothesis: Independent Variable: Dependent Variable: Mechanism Variable: Control Variables: Baselines: Ablations: Primary Metric: Secondary Metrics: Compute Budget: Repeated Trials: Failure Taxonomy: Falsification Condition: Expected Paper Table:

建议长期固定

以后你每发现一个论文中的异常现象，先填这张表。填不出来，说明问题还没有被操作化，不应该马上开始大规模实验。

26. 最低科研闭环能力：你现在真正需要掌握什么？

能力	最低要求
看现象	能从表格/失败案例发现稳定异常
提问题	可测、具体、可证伪
查文献	知道别人是否已经研究
做控制	知道哪些变量必须固定

能力	最低要求
搭 baseline	有强且公平的比较
跑重复	不相信单次结果
读机制	不只看最终分数
做失败分析	知道何时/为什么失效
写结论	claim 不超过证据范围

27. 对个人研究者最重要的策略

资源有限时，最有杠杆的不是做最大实验，而是做最能排除替代解释的实验。

一个 4-condition、控制清晰、重复充分、机制指标明确的小实验，往往比 20 个 baseline + 10 个模型但混杂严重的实验更有科学价值。

个人研究者优势
大团队更容易堆规模；个人研究者更应该通过问题选择、机制拆解、实验控制和失败分析建立差异化。

28. 常见误区汇总

误区	更准确的做法
先想办法再找问题	先确认现象和研究问题
Baseline 越弱越好赢	Baseline 应排除简单解释
最终分数高就够了	同时测机制和成本
Ablation 只是论文格式	它是因果解释的重要证据
多跑 benchmark 就是更强论文	先保证变量控制和问题一致
假设被否决 = 项目失败	否决本身也是科学结果/方向筛选
复杂实验更有价值	能区分假设的最小实验更有价值

29. 练习题

- 1) Phenomenon、Research Question、Method 三者有什么区别？
- 2) 什么叫“可证伪 Hypothesis”？
- 3) Independent、Dependent、Mechanism、Control Variable 分别是什么？
- 4) 为什么 Baseline 的作用不是“找一个弱方法来赢”？
- 5) 什么叫 Compute-matched Baseline？
- 6) Ablation 和普通 baseline 有什么区别？
- 7) 什么叫 Manipulation Check？为什么研究异质性特别需要它？
- 8) 为什么主结果表应该同时考虑 Outcome、Mechanism、Cost？
- 9) 如果实验结果与假设相反，科研上应该怎样处理？

10) 请用本讲模板，自己设计一个“通信强度如何影响错误相关性”的最小实验。

答案见材料包《03_第36讲_练习题与答案.pdf》。

30. 本讲总结

一句话总纲 一个完整科研闭环，不是“方法 -> 分数”，而是“现象 -> 可证伪问题 -> 变量与控制 -> 公平 baseline -> 重复实验 -> Outcome/Mechanism/Cost 证据 -> 消融与失败分析 -> 与证据范围匹配的结论”。	
阶段	最短记法
Phenomenon	发生了什么
RQ	我到底要问什么
Hypothesis	什么结果会证明我错
Variables	改什么、测什么、固定什么
Baseline	排除哪些简单解释
Experiment	最小但能区分假设
Statistics	结果是否稳定
Mechanism	为什么发生
Cost	付出了什么
Claim	只说证据支持的范围

到这里，31-36 讲的“科研桥梁模块”完成。你已经具备从 LLM 基础知识进入 Agent Systems 科研实验的最低闭环。