

第36讲：练习题与答案

建议先独立作答，再看参考答案。

1. Phenomenon、Research Question、Method 三者有什么区别？

你的答案：_____

参考答案：Phenomenon 是观察到的真实规律/失败；Research Question 是对该现象提出的可测问题；Method 是解释、干预或利用该现象的一种手段。

2. 什么叫可证伪 Hypothesis？

你的答案：_____

参考答案：必须存在一种可能观察到的结果会让你承认假设不成立。例如“控制单体准确率和计算预算后，降低错误相关性会提高集体收益”可以被数据否定。

3. Independent、Dependent、Mechanism、Control Variable 分别是什么？

你的答案：_____

参考答案：IV 是主动操纵的变量；DV 是最终结果指标；Mechanism Variable 是解释因果链的中间变量；Control Variables 是为排除替代解释而保持固定的变量。

4. 为什么 Baseline 的作用不是找一个弱方法来赢？

你的答案：_____

参考答案：Baseline 应帮助排除更简单解释，例如“只是多采样”“只是多用 token”“只是多一个 verifier”。强 baseline 才能证明方法真正增加了什么。

5. 什么叫 Compute-matched Baseline？

你的答案：_____

参考答案：比较方法时让总 model calls、tokens、tool calls、时间等主要推理预算尽量相同，避免把更多 test-time compute 当成结构贡献。

6. Ablation 和普通 baseline 有什么区别？

你的答案：_____

参考答案：Baseline 是外部参照；Ablation 是从完整系统中移除/替换某组件，判断该组件是否对效果或机制必要。

7. 什么叫 Manipulation Check？为什么研究异质性特别需要它？

你的答案：_____

参考答案：直接测实验操纵是否真的改变了目标中间变量。例如不同 persona 不代表真异质，必须检查行为、memory、tool use 或 error correlation 是否真的变化。

8. 为什么主结果表应该同时考虑 Outcome、Mechanism、Cost？

你的答案: _____

参考答案: Outcome 告诉你是否更好, Mechanism 告诉你为什么, Cost 告诉你是否只是更贵。三者缺一都容易产生错误解释。

9. 如果实验结果与假设相反, 科研上应该怎样处理?

你的答案: _____

参考答案: 保留结果, 检查设计和数据质量; 若实验有效, 就修正/否决假设, 缩小 claim, 分析失败机制, 而不是删掉不利实验。

10. 如何设计“通信强度影响错误相关性”的最小实验?

你的答案: _____

参考答案: 可设置 no communication / evidence-only / full communication, 固定模型、Agent 数、总 tokens/calls、工具和任务; 主测 error correlation 与 collective gain, 另测 communication tokens, 并做重复运行和 paired analysis。

综合作业：把一个想法变成可执行实验

任选一个你感兴趣的 Agent Systems 现象，用下面模板填满一页：

Phenomenon: Research Question: Hypothesis: Independent Variable: Dependent Variable: Mechanism Variable: Control Variables: Baselines: Ablations: Primary Metric: Compute Budget: Repeated Trials: Failure Taxonomy: Falsification Condition: Expected Main Table:

最低合格标准：你必须能明确写出“什么结果会让我承认假设不成立”，以及至少一个 `compute-matched baseline`。