

面向 LLM / Agent Systems 科研的深度学习零基础课

第 04 讲

Matrix Multiplication 核心概念速查卡

只保留以后读神经网络、Transformer 与 PyTorch 代码时最常用的规则。

核心概念速查卡

本课程采用 Just-in-Time Math：数学只讲到足以理解深度学习，并通过手算 + NumPy + 后续 PyTorch 建立底层直觉。

1. 一句话定义

核心概念

若 $C = AB$ ，则 C 的每个元素都是： A 的一行与 B 的一列做 Dot Product。

2. Shape 规则

$$(m,n)@(n,p) \rightarrow (m,p)$$

记忆：中间维必须相等，外侧维留下来。

左矩阵	右矩阵	输出
(2, 3)	(3, 4)	(2, 4)
(32, 768)	(768, 3072)	(32, 3072)
(4, 3)	(3, 2)	(4, 2)

常见误区 / 风险

$(2,3)@(2,4)$ 不能算，因为左矩阵列数 3 与右矩阵行数 2 不相等。

3. 一个输出格子怎么来

$$C_{ij} = \sum_k A_{ik} B_{kj}$$

翻译：输出第 i 行第 j 列 = 左边第 i 行 dot 右边第 j 列。

例：

$$[1, 2, 3] \cdot [7, 9, 11] = 1 \times 7 + 2 \times 9 + 3 \times 11 = 58$$

4. 不要混淆两种乘法

	逐元素乘法	矩阵乘法
NumPy	$A * B$	$A @ B$
规则	对应位置相乘	行 dot 列
Shape	通常需可广播	内部维度匹配
含义	保留局部对应关系	做线性组合 / 特征变换

5. 神经网络最常见的 XW

若：

$$X : (B, D_{in}), \quad W : (D_{in}, D_{out})$$

则：

$$XW : (B, D_{out})$$

含义： B 个样本共享同一套权重，把每个样本从 D_{in} 维映射到 D_{out} 维。

6. Transformer 连接

$$Q = XW_Q, \quad K = XW_K, \quad V = XW_V$$

若：

$$X : (T, D), \quad W_Q : (D, d_k)$$

则：

$$Q : (T, d_k)$$

Attention score：

$$QK^T : (T, d_k) @ (d_k, T) \rightarrow (T, T)$$

第 i, j 个元素表示：第 i 个 Query Token 与第 j 个 Key Token 的 Dot Product。

7. 代码速查

```
import numpy as np

A = np.array([[1, 2, 3],
              [4, 5, 6]], dtype=float)
B = np.array([[7, 8],
              [9, 10],
              [11, 12]], dtype=float)

C = A @ B
print(A.shape)  # (2, 3)
print(B.shape)  # (3, 2)
print(C.shape)  # (2, 2)
```

8. 调试口诀

1. 先写出左右两个 Shape；
2. 圈出“左列数”和“右行数”；

3. 它们不等：不能乘；
4. 它们相等：删掉中间两个维度，保留外侧维；
5. 如果结果数值不对，再检查是否把 $*$ 写成 $@$ 或反之。

本节检查点

看到 $X : (32, 768)$ ， $W : (768, 3072)$ ，应该不计算任何数字就能回答：输出 $\text{Shape} = (32, 3072)$ 。