

面向 LLM / Agent Systems 科研的深度学习零基础课

第 06 讲

核心概念速查卡

Batch、 (B, D) 、 (B, T, D) 、三维 Linear、Broadcasting 与 Transformer Shape。

速查卡

本课程采用 Just-in-Time Math：数学只讲到足以理解深度学习，并通过手算 + NumPy + 后续 PyTorch 建立底层直觉。

1. 一眼看懂核心符号

符号	含义	常见 Shape
B	Batch Size，一次处理多少个样本	32、64、128
T	Sequence Length，每个样本多少 Token	128、512、4096
D	输入/hidden 特征维	768、4096
O	Linear 输出特征维	256、3072、11008

2. 二维 Batch 公式

$$X : (B, D), \quad W : (D, O), \quad b : (O,)$$

$Y = XW + b : (B, O)$

所有样本共享同一套 W, b 。

3. LLM 最常见的三维 Tensor

$X : (B, T, D)$

读作：**B 条序列，每条 T 个 Token，每个 Token 是 D 维向量。**

若 Linear：

$$D \rightarrow O$$

则：

$(B, T, D) \rightarrow (B, T, O)$

前面的 B, T 保留，只改变最后一维。

4. 一个必须掌握的等价关系

$$(B, T, D)$$

可以临时 reshape 为：

$$(B \times T, D)$$

对每个 Token 使用相同 Linear，再 reshape 回：

$$(B, T, O)$$

与直接三维 Linear 数值等价。

5. Bias Broadcasting

$$(B, T, O) + (O,) \rightarrow (B, T, O)$$

直觉：每一个样本的每一个 Token，都加上同一个输出 Bias 向量。

6. 参数量

Linear $D \rightarrow O$:

$$D \times O + O$$

参数量与 B, T 无关。

不要混淆

B, T 增大通常增加计算量、激活显存；但不会把 Linear 的 Weight/Bias 变成更多可学习参数。

7. PyTorch 规则

```
layer = nn.Linear(D, O)
X = torch.randn(B, T, D)
Y = layer(X)
# Y.shape == (B, T, O)
```

一般规律：

$$(*, D_{in}) \rightarrow (*, D_{out})$$

8. Transformer 连接

$$X : (B, T, D_{model})$$

$$Q = XW_Q, \quad K = XW_K, \quad V = XW_V$$

若 $W_Q, W_K, W_V : (D_{model}, D_{model})$ ，则：

$$Q, K, V : (B, T, D_{model})$$

一句话记忆

Linear 改 “每个 Token 里面的特征”；Attention 才负责 “不同 Token 之间的信息交互”。

9. 调试时固定问 4 个问题

1. 当前 Tensor 的 Shape 是什么？
2. 每个轴的业务/语义含义是什么？
3. 这一步操作作用在哪个轴？
4. 操作前后哪个轴变了，哪个轴应该保持？