

面向 LLM / Agent Systems 科研的深度学习零基础课

第 06 讲

练习题与答案

目标：通过 Shape 推理、手工判断和代码阅读，确保真正掌握 Batch 与 (B, T, D) 。

练习题 + 详解

本课程采用 Just-in-Time Math：数学只讲到足以理解深度学习，并通过手算 + NumPy + 后续 PyTorch 建立底层直觉。

1 基础题

题 1

有：

$$X : (16, 128), \quad W : (128, 64), \quad b : (64,)$$

求 $Y = XW + b$ 的 Shape。

题 2

一个 Tensor Shape 为 $(8, 256, 768)$ 。请解释三个数字在典型 LLM hidden states 中分别可能表示什么。

题 3

有：

$$X : (8, 256, 768)$$

使用 `nn.Linear(768, 3072)` 后，输出 Shape 是什么？

题 4

若上题把 Batch Size 从 8 改成 32，Linear 的参数量会不会增加 4 倍？

2 理解题

题 5

判断正误并解释：

“一个 Batch 有 64 个样本，所以模型内部实际上有 64 份独立的 Weight。”

题 6

判断正误并解释：

“对 (B, T, D) 直接执行 Linear 后，第 t 个 Token 会自动融合第 $t - 1$ 个 Token 的信息。”

题 7

为什么：

$$(B, T, D) \rightarrow (B \times T, D)$$

后做相同 Linear，再 reshape 回去，与直接做三维 Linear 等价？

题 8

为什么 $(O,)$ 的 Bias 可以加到 (B, T, O) 上? 这一步有什么潜在风险?

3 计算题

题 9

若 Linear 为 $D = 4 \rightarrow O = 3$:

1. Weight Shape 是什么?
2. Bias Shape 是什么?
3. 总参数量是多少?
4. 若输入改为 $(B, T, D) = (128, 4096, 4)$, 参数量是多少?

题 10

给出:

$$X : (2, 5, 4), \quad W : (4, 7)$$

求:

1. XW 的 Shape;
2. 如果再加 $b : (7,)$, 最终 Shape;
3. 总共有多少个 Token 向量被这套 Weight 处理?

4 LLM / Transformer 连接题

题 11

hidden states:

$$X : (4, 512, 768)$$

Q 投影矩阵:

$$W_Q : (768, 768)$$

求 Q 的 Shape, 并解释每个轴含义。

题 12

Transformer FFN 中有:

$$(B, T, 768) \rightarrow (B, T, 3072) \rightarrow (B, T, 768)$$

请说明：

1. 哪两个轴一直不变？
2. 哪个轴被 Linear 改变？
3. 这一阶段是否仅凭 Linear 就让不同 Token 彼此交流？

5 代码阅读题

题 13

阅读：

```
X = np.zeros((2, 3, 4))
W = np.zeros((4, 5))
b = np.zeros(5)
Y = X @ W + b
```

不运行代码，写出 Y 的 Shape，并说明推理过程。

题 14

阅读：

```
X = torch.randn(6, 100, 512)
layer = nn.Linear(512, 2048)
Y = layer(X)
```

解释为什么不需要手动写循环遍历 6 个样本和 100 个 Token。

6 答案与解析

题 1 答案

$$(16, 128) @ (128, 64) \rightarrow (16, 64)$$

加 $(64,)$ Bias 后仍为 $(16, 64)$ 。

题 2 答案

典型解释： $B = 8$ 个样本， $T = 256$ 个 Token/样本， $D = 768$ 维 hidden representation/Token。

题 3 答案

$$(8, 256, 768) \rightarrow (8, 256, 3072)$$

只改变最后一个特征维。

题 4 答案

不会。参数量只由 $768 \times 3072 + 3072$ 决定，与 Batch Size 无关。

题 5 答案

错误。64 个样本共享同一套 Weight/Bias。Batch 是并行处理数据，不是复制模型参数。

题 6 答案

错误。普通 Linear 逐位置作用于最后一维，不自动混合 Token。Token 间信息交换要依赖 Attention、RNN 状态传播等机制。

题 7 答案

因为总共有 $B \times T$ 个 Token 向量，每个都是 D 维。把 B, T 合并，只是把这些 Token 排成一个更长的“样本列表”；只要顺序保持，每个 Token 使用同一个 W, b ，结果恢复 Shape 后完全一致。

题 8 答案

Broadcasting 把 $(O,)$ 当作最后一个轴的 Bias，等价于在每个 (b, t) 位置重复相加。风险是：某些错误 Shape 也可能“碰巧能广播”，程序不报错却在错误轴上计算。

题 9 答案

1. Weight: $(4, 3)$;
2. Bias: $(3,)$;
3. 参数量: $4 \times 3 + 3 = 15$;
4. 即使输入是 $(128, 4096, 4)$, 参数量仍为 15。

题 10 答案

1. $(2, 5, 7)$;
2. $(2, 5, 7)$;
3. $2 \times 5 = 10$ 个 Token 向量。

题 11 答案

$$Q : (4, 512, 768)$$

4 个样本; 每个 512 个 Token; 每个 Query 向量 768 维。

题 12 答案

1. B, T 不变;
2. 最后一维特征从 768 变 3072, 再回到 768;
3. 仅凭这些逐 Token Linear 不会让不同 Token 交互。

题 13 答案

$$Y : (2, 3, 5)$$

最后维 4 与 W 第一维 4 对齐, 输出维变为 5; 前面的 2、3 保留。

题 14 答案

`nn.Linear` 支持输入规则 $(*, D_{in}) \rightarrow (*, D_{out})$ 。它会对前面 6×100 个位置自动应用相同的 Linear 运算, 框架底层用高效张量运算完成, 无需 Python 循环。

自测标准

如果题 3、7、11、14 能独立解释，而不只是写出答案，说明你已经建立了本讲最重要的 Shape 心智模型。