

面向 LLM / Agent Systems 科研的深度学习零基础课

## 第 07 讲

### 实验设计：拆开一个人工神经元

实验目标：通过控制变量与实现等价性实验，验证 Weight、Bias、加权贡献、多个神经元和 Batch 的数值含义。

实验设计文档

本课程采用 Just-in-Time Math：数学只讲到足以理解深度学习，并通过手算 + NumPy + 后续 PyTorch 建立底层直觉。

## 1 实验背景

理论上，一个神经元在激活函数之前计算：

$$z = x \cdot w + b$$

但本讲不要求“记住公式就算掌握”。我们要通过实验验证每个组成部分改变时， $z$  到底怎样变化。

## 2 实验研究问题

1. 手工逐项相乘、求和，与 `np.dot` 是否完全一致？
2. 只改变一个输入  $x_i$ ， $z$  的变化是否等于  $\Delta x_i w_i$ ？
3. Weight 的正负号是否决定单位输入变化推动  $z$  的方向？
4. Bias 改变时，是否表现为整体平移？
5. 多个神经元单独计算，是否等价于一次矩阵乘法？
6. Batch 中不同样本是否共享同一套参数？
7. 为什么不能直接把 Weight 大小解释为现实因果重要性？
8. PyTorch `nn.Linear` 是否与 NumPy 的  $xW + b$  一致？

## 3 实验假设

- H1：逐项贡献求和与 Dot Product 一致；
- H2：若只有  $x_i$  改变， $\Delta z = \Delta x_i w_i$ ；
- H3：正 Weight 对单位输入增加产生正的  $\Delta z$ ，负 Weight 产生负的  $\Delta z$ ；
- H4：Bias 对所有输入状态增加相同的平移量；
- H5：O 个神经元可以写成  $xW + b$ ；
- H6：Batch 只复制数据位置，不复制模型参数；
- H7：Weight 需要结合输入尺度和网络上下文解释；
- H8：PyTorch 与 NumPy 数值一致。

## 4 实验环境

最低要求：

- Python 3.x；

- NumPy;
- PyTorch 可选，仅用于最后一个对照实验。

运行：

```
python lesson07_neuron_experiment.py
```

## 5 实验 1：一个神经元的透明计算

设置：

$$x = [2, -1, 3], \quad w = [0.5, -2, 1], \quad b = 0.2$$

### 5.1 运行前预测

先不用代码，手写：

$$x \odot w = ?$$

$$z = ?$$

预期：

$$x \odot w = [1, 2, 3]$$

$$z = 6.2$$

程序同时比较：

```
(x * w).sum() + b  
np.dot(x, w) + b
```

## 6 实验 2：单变量干预

把  $x_1$  从 2 改到 4：

$$\Delta x_1 = 2$$

因为：

$$w_1 = 0.5$$

所以预测：

$$\Delta z = 2 \times 0.5 = 1$$

这是一个典型的“只改变一个变量，其余保持不变”的控制变量实验。

## 7 实验 3: Weight 的符号与单位响应

分别只让  $x_1, x_2, x_3$  增加 1。

由于：

$$w = [0.5, -2, 1]$$

预测  $z$  的变化分别为：

$$+0.5, -2, +1$$

### 科研视角

这不是完整的“特征重要性实验”，只是验证线性单元中的直接局部响应。深层网络解释远比这里复杂。

## 8 实验 4: Bias 平移

固定  $x, w$ ，只把 Bias 改为：

$$-2, 0, 0.2, 3$$

观察输出。预期每次  $z$  只改变与 Bias 相同的量。

## 9 实验 5: 多个神经元与矩阵乘法

构造两个神经元：

$$W : (3, 2), \quad b : (2, )$$

一方面直接：

$$z_{layer} = xW + b$$

另一方面分别计算：

$$z_1 = x \cdot w^{(1)} + b_1$$

$$z_2 = x \cdot w^{(2)} + b_2$$

最后比较两者是否一致。

### 通过标准

若 `np.allclose` 返回 `True`，就验证了“多个神经元并排 = 一次矩阵乘法”。

## 10 实验 6: Batch 参数共享

输入：

$$X : (3, 3)$$

仍使用同一个：

$$W : (3, 2), \quad b : (2,)$$

得到：

$$Z : (3, 2)$$

检查第一个 Batch 样本是否与实验 5 的单样本结果完全一致。

## 11 实验 7：为什么 Weight 大小不能直接当因果重要性

设计：

$$x = [1000, 1], \quad w = [0.001, 0.8]$$

虽然：

$$0.001 \ll 0.8$$

但当前样本加权贡献：

$$x \odot w = [1, 0.8]$$

因此，仅比较 Weight 数值大小可能受到输入尺度影响。

### 常见误区 / 风险

这个实验只证明“直接比较 Weight 可能误导”，并没有提供一个完整的模型解释方法。真正的可解释性、因果推断需要另外的方法与实验设计。

## 12 实验 8：PyTorch 对照

创建：

```
layer = nn.Linear(3, 2)
```

将其 Weight/Bias 手动设置成与 NumPy 一致。

注意 PyTorch：

$$\text{weight.shape} = (2, 3)$$

而本课程 NumPy 记法：

$$W : (3, 2)$$

所以复制参数时用：

```
layer.weight.copy_(torch.tensor(W.T))
```

通过标准：PyTorch 输出与 NumPy  $x @ W + b$  一致。

### 13 实际运行结果摘要

本材料包已实际运行，得到：

- 单神经元  $z = 6.2$ ；
- $x_1$  增加 2 时， $z$  正好增加 1；
- 三个单位输入变化对应  $\Delta z = 0.5, -2, 1$ ；
- 改变 Bias 只改变整体基线；
- 两个神经元单独算与矩阵一次算：**True**；
- Batch 第一个样本与单样本结果一致：**True**；
- 输入尺度实验显示小 Weight 仍可能产生较大贡献；
- PyTorch 与 NumPy：**True**。

### 14 实验记录模板

| 实验          | 运行前预测 | 实际结果 | 解释 |
|-------------|-------|------|----|
| 单神经元手算      |       |      |    |
| 改单个输入       |       |      |    |
| Weight 正负号  |       |      |    |
| Bias 平移     |       |      |    |
| 多个神经元       |       |      |    |
| Batch 共享参数  |       |      |    |
| Weight 解释风险 |       |      |    |
| PyTorch 对照  |       |      |    |

### 15 实验结论

#### 核心概念

一个人工神经元的底层并不神秘：每个输入乘一个可学习 Weight，得到逐项贡献；贡献求和再加 Bias 得到 pre-activation  $z$ 。多个神经元只是把多个 Weight 向量组织为矩阵，从而一次执行大量 Dot Product。

### 16 科研方法迁移

本实验训练的研究习惯可以继续沿用：

1. 先写理论预测，而不是直接运行；
2. 设计一个极小、可手算案例；
3. 每次只改变一个变量；
4. 使用数值对照验证“实现等价性”；
5. 对参数解释保持克制，区分数值关联与因果结论。