

面向 LLM / Agent Systems 科研的深度学习零基础课

第 07 讲

练习题与答案

目标：能手算一个神经元，解释 Weight/Bias，理解从单神经元到 Linear Layer 的过渡。

练习题 + 详解

本课程采用 Just-in-Time Math：数学只讲到足以理解深度学习，并通过手算 + NumPy + 后续 PyTorch 建立底层直觉。

1 基础题

题 1

给定：

$$x = [1, 2, 3], \quad w = [2, -1, 0.5], \quad b = 1$$

计算 $z = x \cdot w + b$ 。

题 2

在题 1 中，三个 $x_i w_i$ 分别是多少？哪一项对当前 z 的直接数值贡献最大？

题 3

一个神经元有 8 个输入特征。若带 Bias，它有多少个可学习参数？

题 4

判断：Bias 是模型预测错误的一部分，因此训练得越好 Bias 就应该越接近 0。对还是错？解释。

2 理解题

题 5

若某个 Weight 为负数，能否直接解释为“这个特征是坏特征”？为什么？

题 6

若：

$$z = x_1(0.2) + x_2(-3.0) + b$$

当 x_1 增加 1、其他不变时， z 怎样变化？当 x_2 增加 1 时呢？

题 7

为什么说多个神经元并排以后，可以用一次矩阵乘法表示？

题 8

解释为什么“Weight 绝对值最大”不一定意味着该特征最重要。至少给出两个理由。

3 Shape 与参数题

题 9

输入维度 $D = 4$ ，这一层有 $O = 3$ 个神经元。

1. W 的 Shape 是什么？
2. b 的 Shape 是什么？
3. 一个样本 $x : (4,)$ 输出 Shape 是什么？
4. 总参数量是多少？

题 10

若 Batch:

$$X : (32, 4)$$

仍使用题 9 的层，输出 Shape 是什么？参数量是否变成 32 倍？

4 代码阅读题

题 11

阅读：

```
x = np.array([2., -1., 3.])
w = np.array([0.5, -2., 1.])
b = 0.2
z = (x * w).sum() + b
```

不运行，写出 $x*w$ 和 z 。

题 12

阅读：

```
W = np.zeros((5, 7))
b = np.zeros(7)
x = np.zeros(5)
z = x @ W + b
```

写出 z 的 Shape，并解释“7”代表什么。

5 LLM / Transformer 连接题

题 13

若某 Transformer hidden state 的每个 Token 是 768 维，Q projection 输出仍是 768 维。那么对应一个线性投影矩阵（按本课程 NumPy 记法）Shape 是什么？如果有 Bias，参数量是多少？

题 14

为什么说 Q/K/V projection 虽然很大，但其底层仍然可以理解为“很多神经元并排做加权和”？

6 科研判断题

题 15

某论文声称：“某个输入变量对应的 Weight 最大，所以证明这个变量对现实结果具有最强因果作用。”仅根据这句话，你认为论证是否充分？指出至少三个需要警惕的点。

7 答案与解析

题 1 答案

$$1 \times 2 + 2 \times (-1) + 3 \times 0.5 + 1 = 2 - 2 + 1.5 + 1 = 2.5$$

题 2 答案

三个贡献为：

$$2, -2, 1.5$$

若只比较当前样本贡献绝对值，前两项绝对值并列最大，都是 2。注意这仍不等价于现实世界“重要性”。

题 3 答案

8 个 Weight + 1 个 Bias，共 9 个参数。

题 4 答案

错。Bias 是可学习参数，不是“错误量”。训练可能得到非零甚至数值较大的 Bias，这取决于数据和模型结构。

题 5 答案

不能。负 Weight 只表示在当前线性计算、其他因素不变时，该输入增加会使 pre-activation 朝负方向变化。它不是价值判断，也不自动表示因果方向。

题 6 答案

x_1 增加 1： z 增加 0.2。 x_2 增加 1： z 减少 3.0。

题 7 答案

每个神经元都有一个 D 维 Weight 向量。把 O 个 Weight 向量作为矩阵的 O 列，就得到 $W : (D, O)$ 。一次 xW 会同时产生 O 个 Dot Product，也就是 O 个神经元的加权和。

题 8 答案

例如：

1. 输入特征的数值尺度不同；
2. 后续层和 Activation 会改变影响；

3. 特征之间可能高度相关；
4. Weight 反映模型拟合结果，不自动等于因果关系。

题 9 答案

1. $W : (4, 3)$;
2. $b : (3,)$;
3. 输出 $(3,)$;
4. $4 \times 3 + 3 = 15$ 。

题 10 答案

输出：

$$(32, 3)$$

参数量仍是 15。Batch 只是让 32 个样本共享同一套参数。

题 11 答案

$$x * w = [1, 2, 3]$$

$$z = 6.2$$

题 12 答案

$z : (7,)$ 。7 表示这一层有 7 个输出单元/神经元，每个都接收 5 维输入。

题 13 答案

按 NumPy 记法：

$$W_Q : (768, 768)$$

若有 Bias，参数量：

$$768 \times 768 + 768 = 590592$$

题 14 答案

矩阵乘法 XW_Q 可以分解成很多 Dot Product。矩阵的每一列都对应一个输出方向/线性单元，因此底层仍是“输入与许多 Weight 向量做加权求和”。

题 15 答案

论证不充分。至少应警惕：

1. 不同特征尺度会影响 Weight 大小；
2. 相关特征会造成参数解释困难；
3. 深层网络中后续层和非线性会改变最终影响；
4. 预测关联不等于因果关系；
5. 需要更严格的解释方法和干预/因果设计。

自测标准

如果你能不看答案完成题 1、6、7、9、13，并能解释题 8 和 15 的逻辑，就说明你已经真正把“神经元 = 加权和 + Bias”建立起来了。