

面向 LLM / Agent Systems 科研的深度学习零基础课

第 08 讲

核心概念速查卡

多层 Linear/Affine 若中间没有非线性操作，函数上仍可折叠为一个 affine。

速查卡

1. 一维最小例子

$$h = 2x + 1$$

$$y = 3h - 4$$

代入：

$$y = 3(2x + 1) - 4 = 6x - 1$$

两层与一层对所有 x 完全一致。

2. 两层矩阵折叠公式

$$H = XW_1 + b_1$$

$$Y = HW_2 + b_2$$

则：

$$Y = X(W_1W_2) + (b_1W_2 + b_2)$$

所以：

$$W_{eq} = W_1W_2$$

$$b_{eq} = b_1W_2 + b_2$$

3. 为什么 Bias 也救不了？

$$y = Wx + b$$

严格说是 affine，而不是 pure linear，但多个 affine 复合以后仍然是 affine。Bias 只负责平移，不提供真正非线性。

4. 为什么需要 Activation？

若加入：

$$a = f(XW_1 + b_1)$$

再：

$$y = aW_2 + b_2$$

只要 f 是非线性函数，就通常不能再把整个模块折成一个单一 $XW + b$ 。

ReLU 预告：

$$\text{ReLU}(z) = \max(0, z)$$

5. 关键区分

概念	正确理解
层数增加	不自动等于非线性表达能力增加
函数可折叠	固定参数后的输入-输出函数等价
训练过程	参数化不同，梯度动力学可能不同
Bias	平移项，不是非线性
ReLU	分段线性，但整体非 affine
Bottleneck	仍线性，但可能带 rank 约束

6. 与 Transformer 的连接

简化 FFN：

$$X \rightarrow Linear \rightarrow GELU/SiLU \rightarrow Linear$$

如果删掉 Activation，两层 Linear 本身可以折叠成一层。

7. 本讲一句话

核心概念

深度神经网络的“深”不是简单把矩阵乘法重复很多次。真正让多层组合获得复杂函数表达能力的关键之一，是层与层之间加入非线性操作。