

面向 LLM / Agent Systems 科研的深度学习零基础课

第 08 讲

练习题与答案

目标：会手算 affine 折叠，能解释非线性为什么必要，并能把结论迁移到 Transformer FFN。

练习题 + 详解

本课程采用 Just-in-Time Math：数学只讲到足以理解深度学习，并通过手算 + NumPy + 后续 PyTorch 建立底层直觉。

1 基础题

题 1

第一层 $h = 4x + 2$ ，第二层 $y = 5h - 3$ 。把两层合并为 $y = ax + b$ 。

题 2

判断：只要神经网络有 Bias，它就是非线性网络。对还是错？解释。

题 3

若 $x = 2$ ，用原两层与折叠后的单层分别计算题 1 输出，验证一致。

2 矩阵与 Shape 题

题 4

若：

$$X : (32, 4), \quad W_1 : (4, 8), \quad b_1 : (8,)$$

$$W_2 : (8, 3), \quad b_2 : (3,)$$

写出： H 、 Y 、 W_{eq} 、 b_{eq} 的 Shape。

题 5

按 row-vector 记法，写出两层 affine 折叠的 W_{eq} 和 b_{eq} 。

题 6

如果网络是 $100 \rightarrow 10 \rightarrow 100$ ，中间没有 Activation，这个网络是否获得非线性？中间 10 维可能带来什么额外限制？

3 理解题

题 7

为什么“10 层 Linear”并不自动比“1 层 Linear”拥有更复杂的函数类别？

题 8

解释为什么 ReLU 虽然由两段直线组成，却仍然属于神经网络中的非线性函数。

题 9

用三个点 $(-1, 1), (0, 0), (1, 1)$ 说明为什么单一 affine 函数不能精确表达 $y = x^2$ 。

4 代码阅读题

题 10

阅读：

```
H = X @ W1 + b1
Y = H @ W2 + b2
W_eq = W1 @ W2
b_eq = b1 @ W2 + b2
Y_eq = X @ W_eq + b_eq
```

为什么理论上 Y 与 Y_{eq} 应该一致？

题 11

如果在两层之间加入：

```
H = np.maximum(0, H)
```

为什么上面的 W_{eq}, b_{eq} 公式通常不再成立？

5 LLM / Transformer 连接题

题 12

简化 Transformer FFN：

$$XW_1 \rightarrow GELU \rightarrow W_2$$

如果删除 GELU，这个 FFN 的两层 Linear 在函数上会发生什么？

题 13

判断：“Transformer 的非线性只来自 GELU/SiLU。”对还是错？至少举出另外一种使系统非线性的操作。

6 科研判断题

题 14

某论文提出 “Linear -> ReLU -> Linear” 模块。Ablation 删除 ReLU 后性能下降。为什么不能只得出 “ReLU 这个具体函数最好” 的结论？还需要哪些对照？

题 15

为什么 “深层线性网络可折叠” 不等于 “训练一个深层线性网络和训练一个单层线性网络完全相同”？

7 答案与解析

题 1 答案

$$y = 5(4x + 2) - 3 = 20x + 10 - 3 = 20x + 7$$

所以 $a = 20, b = 7$ 。

题 2 答案

错。Bias 让 pure linear 变成 affine，但 affine 的复合仍是 affine。它不是神经网络所需的非线性来源。

题 3 答案

原两层： $h = 4 \times 2 + 2 = 10$ ， $y = 5 \times 10 - 3 = 47$ 。折叠后： $20 \times 2 + 7 = 47$ 。

题 4 答案

$$H : (32, 8), \quad Y : (32, 3)$$

$$W_{eq} : (4, 3), \quad b_{eq} : (3,)$$

题 5 答案

$$W_{eq} = W_1 W_2$$

$$b_{eq} = b_1 W_2 + b_2$$

题 6 答案

没有获得非线性。因为两个 affine 的复合仍为 affine。但中间 10 维 bottleneck 会限制等效矩阵的 rank，形成结构约束。

题 7 答案

因为 affine 函数集合对函数复合是封闭的：多次 affine 复合仍可写成一个新的 $XW + b$ 。

题 8 答案

ReLU 无法用一个全局 affine 函数表示。在 $z = 0$ 两侧斜率不同，因此整体函数不是单一 affine，即使每一段分别是直线。

题 9 答案

通过 $(0, 0)$ 要求 $b = 0$ ；再通过 $(1, 1)$ 要求 $a = 1$ ；此时 $x = -1$ 预测 -1 ，而目标为 1 ，矛盾。

题 10 答案

利用矩阵乘法分配律和结合律：

$$(XW_1 + b_1)W_2 + b_2 = X(W_1W_2) + (b_1W_2 + b_2)$$

因此两种写法是同一个函数。

题 11 答案

$\text{maximum}(0, H)$ 会根据 H 的数值选择保留还是置零，不能简单吸收到一个固定矩阵和固定 Bias 里，因此全局折叠通常失败。

题 12 答案

会退化成为两个 affine 的复合，因此可以合并成一个等效 affine 映射；FFN 失去这一部分非线性表达能力。

题 13 答案

错。Softmax Attention 是明显的非线性；LayerNorm/RMSNorm 也依赖输入统计量，不是固定线性映射；门控结构同样可引入非线性。

题 14 答案

至少需要比较：其他 Activation（如 GELU/SiLU）、无 Activation、参数量/计算量是否一致、训练稳定性是否改变。性能下降只说明“删除该非线性操作有影响”，不能单凭一次 Ablation 证明 ReLU 是最优选择。

题 15 答案

固定参数后的函数类别可以相同，但深层参数分解会改变优化空间、梯度路径、隐式偏置、rank 约束等，因此训练动力学可以不同。

自测标准

如果你能独立完成题 1、4、5、9、12，并能解释题 14、15，就说明你已经真正理解“为什么仅有 Linear 不够”。