

面向 LLM / Agent Systems 科研的深度学习零基础课

第 09 讲

Activation Function 速查卡

ReLU、Sigmoid、Tanh、GELU、SiLU：输入输出、Shape、直觉与 LLM 连接。

核心概念速查卡

本课程采用 Just-in-Time Math：数学只讲到足以理解深度学习，并通过手算 + NumPy + 后续 PyTorch 建立底层直觉。

1. 一句话总纲

核心概念

Linear/Affine 负责“加权混合”，Activation 负责“引入非线性”。常见激活函数逐元素作用，通常**改变数值，不改变 Shape**。

2. 五种常见 Activation

函数	公式/范围	负数行为	记忆点
ReLU	$\max(0, x)$	全部截为 0	最直观的硬截断非线性
Sigmoid	$1/(1 + e^{-x})$, $(0, 1)$	压到接近 0	常用于 0–1 门控；会饱和
Tanh	$(-1, 1)$	保留负号并压缩	以 0 为中心；会饱和
GELU	$x\Phi(x)$	平滑保留小负值	Transformer 常见
SiLU	$x\sigma(x)$	平滑保留小负值	现代 LLM / SwiGLU 常见

3. 必须记住的 Shape 规则

若：

$$Z : (B, T, D)$$

则：

$$\text{ReLU}(Z), \text{GELU}(Z), \text{SiLU}(Z) : (B, T, D)$$

逐元素激活通常不改变维度。

4. 数字直觉

对 $x = [-1, 0, 1]$ ：

$$\text{ReLU}(x) = [0, 0, 1]$$

$$\sigma(x) \approx [0.269, 0.5, 0.731]$$

$$\tanh(x) \approx [-0.762, 0, 0.762]$$

$$\text{GELU}(x) \approx [-0.159, 0, 0.841]$$

$$\text{SiLU}(x) \approx [-0.269, 0, 0.731]$$

5. 为什么 Activation 必不可少？

$$(XW_1 + b_1)W_2 + b_2$$

仍可合并成一个 affine。

但：

$$\phi(XW_1 + b_1)W_2 + b_2$$

一般不能把 ϕ 吸收到一个固定矩阵里。

与 LLM / Transformer / Agent Systems 的连接

Transformer FFN 的核心模板：

$\text{Linear} \rightarrow \text{GELU/SiLU} \rightarrow \text{Linear}$

Activation 就是上一讲所缺失的“非线性”。

6. 常见误区

- Activation 不是必须输出 0/1 的“开关”。
- 输出在 0-1 的 Sigmoid 不等于天然就是校准概率。
- GELU/SiLU 常见，不代表任何任务都一定胜过 ReLU。
- Activation 通常改变数值，不负责改变特征维度。

7. 读论文时问什么？

1. 论文使用什么 Activation？
2. 替换 Activation 时是否保持参数量和训练预算一致？
3. 是否连 FFN 结构一起改了，例如 SwiGLU？
4. 性能变化能否真正归因于 Activation？

本节检查点

看到 `GELU(hidden)` 或 `F.silu(x)` 时，你应该立刻知道：逐元素非线性，Shape 基本不变，但每个数字的映射规则发生变化。