

面向 LLM / Agent Systems 科研的深度学习零基础课

第 09 讲

练习题与答案

Activation Function：从手算、Shape 到 Transformer FFN。

练习题与答案

本课程采用 Just-in-Time Math：数学只讲到足以理解深度学习，并通过手算 + NumPy + 后续 PyTorch 建立底层直觉。

1 练习题

题 1 【基础】ReLU 手算

给定：

$$x = [-4, -0.5, 0, 2, 7]$$

写出 $\text{ReLU}(x)$ 。

题 2 【基础】Sigmoid 关键点

不使用计算器，回答：

1. $\sigma(0)$ 等于多少？
2. 当 $x \rightarrow +\infty$ ，Sigmoid 趋近多少？
3. 当 $x \rightarrow -\infty$ ，Sigmoid 趋近多少？

题 3 【Shape】Activation 会改变什么？

若：

$$Z : (32, 128, 4096)$$

那么经过 GELU 后 Shape 是什么？为什么？

题 4 【理解】为什么两层 Linear 之间需要 Activation？

用自己的话解释：为什么

$$\text{Linear}_1 \rightarrow \text{Linear}_2$$

在函数表达能力上仍可折叠，而加入 ReLU/GELU 后通常不能简单折叠？

题 5 【对比】ReLU 与 GELU

输入 $x = -1$ 。ReLU 输出是多少？GELU 的输出大约是 -0.159 。这个差异说明两者对负值采取什么不同策略？

题 6 【代码阅读】

阅读：

```
Z = X @ W + b
A = np.maximum(0.0, Z)
```

回答：

1. 第一行是什么操作?
2. 第二行是什么 Activation?
3. 如果 $Z.shape = (10, 64)$, $A.shape$ 是什么?

题 7 【LLM 连接】

某 Transformer FFN:

$$(B, T, 768) \rightarrow (B, T, 3072) \rightarrow \text{GELU} \rightarrow (B, T, 768)$$

回答:

1. 哪一步改变特征维度?
2. GELU 前后的 Shape 分别是什么?
3. GELU 的主要作用是什么?

题 8 【科研判断】

论文 A 把 GELU 换成 SwiGLU, 同时把 hidden dimension、参数量和训练 token 数都改变了, 最后性能提高。能否直接得出 “SwiGLU 本身导致提升”? 为什么?

题 9 【辨析】

判断对错并说明:

1. Sigmoid 输出 0.9, 因此一定表示真实事件发生概率为 90%。
2. ReLU 是非线性函数, 因此能打破多层 affine 的简单折叠。
3. 常见逐元素 Activation 会把 (B, T, D) 自动变成 (B, D) 。
4. SiLU 可写成 $x\sigma(x)$ 。

题 10 【综合】

请用不超过 100 字解释下面这条计算链:

$$X \rightarrow Z = XW + b \rightarrow A = \phi(Z)$$

要求同时出现: Weight、Bias、Linear/Affine、Activation、非线性、Shape。

2 参考答案

题 1

$[0, 0, 0, 2, 7]$

题 2

1. $\sigma(0) = 0.5$;
2. 趋近 1;
3. 趋近 0。

题 3

仍为：

$(32, 128, 4096)$

因为 GELU 通常逐元素工作：每个元素被重新映射，但轴和元素位置没有被删除或重排。

题 4

没有 Activation 时，多个 affine 的复合仍然是 affine，可以把权重和 Bias 合并为新的等效权重和 Bias。加入 ReLU/GELU 等非线性后，输入在不同数值区域遵循不同/弯曲的映射规则，不能一般性地吸收到一个固定矩阵中。

题 5

ReLU：

$$\text{ReLU}(-1) = 0$$

GELU 仍保留一个较小负值。说明 ReLU 对负值是硬截断；GELU 是平滑削弱。

题 6

1. Linear/Affine：矩阵乘法加 Bias；
2. ReLU；
3. $(10, 64)$ 。

题 7

1. 两个 Linear/Projection 改变最后一个特征维；

2. GELU 前后均为 $(B, T, 3072)$;
3. 对逐元素数值施加非线性, 使 FFN 不再等价于一个简单 Linear。

题 8

不能。因为同时改变了多项变量, 存在混杂因素。若要归因于 Activation/门控结构, 应尽可能控制参数量、数据、训练预算、优化设置等变量, 或设计专门 Ablation。

题 9

1. 错。0-1 输出不自动等于校准后的真实概率;
2. 对;
3. 错。逐元素 Activation 通常保持 (B, T, D) ;
4. 对。

题 10 【示例答案】

$XW + b$ 用 Weight 对输入特征做 Linear/Affine 加权混合, Bias 提供平移; 随后 Activation ϕ 对每个结果施加非线性。常见逐元素 Activation 通常不改变 Tensor Shape, 只改变其中数字的映射关系。

本节检查点

建议先独立做完题 1-10, 再看答案。尤其题 4、7、8 是以后阅读 Transformer/LLM 论文最重要的三类判断。