

第 10 讲核心概念速查卡

MLP / Feed-Forward Neural Network

- 一页一类信息：结构、Shape、参数量、Transformer 连接。
- 用于课后快速复习，不替代完整讲义。

学习方法：先看懂每一步数字和 Shape，再让 NumPy / PyTorch 帮我们自动计算。

1. 最小两层 MLP

A minimal MLP / Feed-Forward Network



Linear mixes features; activation introduces nonlinearity.

```
z1 = x @ W1 + b1  
a1 = activation(z1)  
y = a1 @ W2 + b2
```

记忆句

Linear 混合特征；Activation 引入非线性；下一层再组合隐藏特征。

2. Shape 与参数量

对象	Shape
x	(D_in,)
W1	(D_in, D_hidden)
b1	(D_hidden,)
a1	(D_hidden,)
W2	(D_hidden, D_out)
b2	(D_out,)
y	(D_out,)

$$\text{参数量} = D_{in} \times D_{hidden} + D_{hidden} + D_{hidden} \times D_{out} + D_{out}$$

Batch / LLM：只要矩阵作用在最后一个维度，就有 $(B,T,D_{in}) \rightarrow (B,T,D_{hidden}) \rightarrow (B,T,D_{out})$ 。

3. Transformer FFN 连接

```
X: (B,T,D)
-> Linear / projection
-> activation (GELU / SiLU / gated form)
-> Linear / projection
-> output: (B,T,D)
```

普通 FFN/MLP 主要逐 Token 处理最后一个特征维；Attention 负责跨 Token 交互。

读论文时优先检查：D_ff、Activation、gating、Bias、参数量、FLOPs/latency、是否做公平 Ablation。

最小验收

看到一个 MLP 结构图，先写 Shape，再算参数量，再判断 Activation 放在哪里。