

第 10 讲练习题与答案

MLP / Feed-Forward Neural Network

- 先独立完成，再看答案。
- 每题都优先写 Shape，不要只写最后数字。

学习方法：先看懂每一步数字和 Shape，再让 NumPy / PyTorch 帮我们自动计算。

练习 1：Shape 基础

输入 X 的 Shape 为 $(32, 128)$ ，第一层 $W1$ 为 $(128, 512)$ ， $b1$ 为 $(512,)$ 。经过 Linear + ReLU 后， $A1$ 的 Shape 是什么？

第二层 $W2$ 为 $(512, 10)$ ，最终输出 Y 的 Shape 是什么？

练习 2：参数量

一个 $128 \rightarrow 512 \rightarrow 10$ 的两层 MLP，两层都带 Bias。请计算总参数量。

练习 3：手算 ReLU

若第一层得到 $z1=[2,-3,0.5,-0.1]$ ，写出 $\text{ReLU}(z1)$ 。

练习 4：完整 Forward

给定 $x=[1,2]$, $W1=[[1,-1],[0.5,2]]$, $b1=[0,1]$, 激活函数 ReLU, $W2=[[1],[2]]$, $b2=[-0.5]$ 。请手算最终输出。

练习 5：LLM Shape

某 Transformer FFN 输入 X 的 Shape 是 $(B=4,T=128,D=768)$ 。第一层投影到 $D_{ff}=3072$ ，激活后再投影回 768。请写出每一步 Shape。

练习 6：判断

判断并说明原因：① ReLU 通常会把 (B,T,D) 改成 $(B,T,D/2)$ 。② MLP 中所有 Token 会自动相互交流。
③ 把隐藏宽度加倍通常会改变参数量。

练习 7：代码阅读

```
model = nn.Sequential(  
    nn.Linear(16, 64),  
    nn.GELU(),  
    nn.Linear(64, 16),  
)
```

回答：输入最后一维必须是多少？隐藏宽度是多少？输出最后一维是多少？若两层都有 Bias，总参数量是多少？

练习 8：科研阅读

论文 A 把 FFN hidden dimension 从 2048 改成 4096，并报告性能提升。为什么不能立刻得出“作者的新 FFN 结构更优”的结论？至少写出两个需要控制或检查的因素。

答案 1-3

- 1) $(32,128) @ (128,512) \rightarrow (32,512)$, ReLU 不改 Shape, 所以 $A1=(32,512)$ 。再乘 $(512,10)$, $Y=(32,10)$ 。
- 2) 第一层: $128*512+512=66,048$; 第二层: $512*10+10=5,130$; 总计 71,178。
- 3) $\text{ReLU}([2,-3,0.5,-0.1])=[2,0,0.5,0]$ 。

答案 4-6

4) 第一层： $z1 = [1*1+2*0.5+0, 1*(-1)+2*2+1] = [2,4]$ 。ReLU 后仍为 $[2,4]$ 。输出 $= 2*1+4*2-0.5 = 9.5$ 。

5) $(4,128,768) \rightarrow (4,128,3072) \rightarrow$ 激活后仍 $(4,128,3072) \rightarrow (4,128,768)$ 。

6) ①错：逐元素 ReLU 通常保持 Shape。②错：普通 token-wise MLP 并不负责跨 Token 交互。③对：Linear 的 Weight 大小直接依赖隐藏维度。

答案 7-8

7) 输入最后一维 16；隐藏宽度 64；输出最后一维 16。参数量： $(16*64+64)+(64*16+16)=2,128$ 。

8) 至少要检查：参数量是否增加；FLOPs/训练计算是否增加；训练步数和学习率是否一致；数据和随机种子是否可比；是否仅因为更宽模型带来容量提升。公平 Ablation 要尽量拆开“结构改变”和“资源增加”。

自检标准

如果做错 Shape 题，回看第 4-6 讲；如果不理解 ReLU 的作用，回看第 8-9 讲；如果能手算完整 Forward，说明已经具备进入第 11 讲 Computational Graph 的基础。