


第18讲核心概念速查卡

Cross Entropy / Next-token Prediction

核心概念：速查卡

本讲不是让你背公式，而是让你能从 logits 亲手算出概率、正确类别概率、Cross Entropy，并能把这一过程重新放回 LLM 的 next-token prediction。



建议学习顺序：先看讲义 → 手算示例 → 运行实验代码 → 做练习 → 用速查卡复盘。

1. 最核心公式

$$p = \text{Softmax}(\text{logits})$$

$$L = -\log(p_{\text{correct}})$$

$$H(y,p) = -\sum_i y_i \log(p_i)$$

核心概念：单标签 one-hot 情况

因为真实 y 只有正确类别位置等于 1，其余都等于 0，所以完整公式直接化简成 $-\log(p_{\text{correct}})$ 。

2. 数值直觉

p_{correct}	$CE = -\log(p_{\text{correct}})$	含义
0.99	0.010	非常自信地压在正确类上
0.90	0.105	较高正确概率
0.50	0.693	正确类只拿到一半概率
0.10	2.303	正确类概率很低
0.01	4.605	非常自信地错

3. Shape 模板

场景	logits Shape	target Shape	CE 的类别维
普通分类	(B,C)	(B,)	C
单序列 LM	(T,V)	(T,)	V
Batch LLM	(B,T,V)	(B,T)	V
flatten 后	(B*T,V)	(B*T,)	V

4. PyTorch


```
# 正确
loss = F.cross_entropy(logits, targets)

# 常见错误: 不要先 softmax
prob = torch.softmax(logits, dim=-1)
loss_wrong = F.cross_entropy(prob, targets)
```

核心概念: 记忆口诀

CrossEntropyLoss 吃 logits; 类别轴要保留; target 告诉它哪一类是真的。

5. LLM Next-token Prediction



input: [A, B, C, D]

target: [B, C, D, E]

每个位置都做一次 V 类分类。最后对有效 token 的 token loss 聚合。

6. 数值稳定

$$\text{Softmax}(z) = \text{Softmax}(z - \max(z))$$

框架通常直接使用稳定的 $\log\text{-softmax}$ / $\log\text{-sum-exp}$ 实现，避免 $\exp(\text{大数})$ 溢出。

7. 研究判断

更低 CE $\neq$ 一定更高事实正确率。

更低 CE $\neq$ 一定更好 calibration。

更低 LM loss $\neq$ 一定更高 Agent success rate。

训练 loss 必须和 validation / downstream metrics 一起看。