


第19讲：Partial Derivative（偏导数）

当一个 Loss 同时受很多参数影响时怎么办？

核心概念：【必须真正掌握】

本讲不要求你系统学习多元微积分。目标只有一个：当 Loss 同时受很多参数影响时，能够读懂“对某一个参数的偏导数”究竟在问什么，并能用小实验验证它。



建议学习顺序：先看讲义 → 手算两个参数例子 → 运行实验 → 做练习 → 用速查卡复盘。

一、本讲学习目标

从第13讲的单变量导数扩展到多变量函数，理解为什么神经网络必须使用偏导数。

能够把 L/w 读成一句自然语言：其他变量暂时不变时， w 轻微变化会让 L 怎样变化。

理解“partial”不是只算一部分公式，而是一次只观察一个输入变量的局部影响。

能够手算一个简单二维函数的两个偏导数，并用数值差分验证。

能够对一个含 w_1 、 w_2 、 b 的单样本 Loss 分别求偏导，并解释正负号和大小。

知道很多偏导数之后会被组织成 Gradient，但本讲暂不展开向量形式。

能把偏导数重新连接到 Linear、Loss、LLM 参数训练和后续 Backpropagation。

核心概念：和第13讲的关系

第13讲研究 $y=f(x)$ 时，一个 x 的小变化怎样影响 y 。神经网络里 Loss 往往同时依赖百万、十亿甚至更多参数，因此问题变成：在其他参数暂时固定时，某一个参数改一点，Loss 会怎样变化？

二、【原理】为什么普通导数不够了？

单变量函数只有一个自变量，例如：

$$y = x^2$$

此时写 dy/dx 很自然，因为只有 x 可以变化。


但神经网络里的一个最小线性模型已经可能是：

$$\hat{y} = w_1 x_1 + w_2 x_2 + b$$

再加上平方损失：

$$L = (\hat{y} - y)^2$$

此时 Loss 同时受 w_1 、 w_2 、 b 影响。我们不能只写一个含糊的 dL/dw ，因为到底是 w_1 、 w_2 ，还是 b ？




数学直觉：偏导数的核心问题

“当其他变量暂时保持不变时，只让这个变量轻微移动，函数值会以多快的速度变化？”

三、【通俗解释】把 Loss 想成一张山地地图

如果 Loss 只由一个参数 w 决定，你可以把它画成一条曲线；当前位置只有“向左/向右”一个方向。

如果 Loss 由两个参数 w_1 、 w_2 决定，就可以想成一张二维地图上的海拔：每个 (w_1, w_2) 坐标都有一个 Loss 高度。



等高线图把“Loss 高度相同”的点连起来。当前参数固定以后，偏导数分别问：只沿 w_1 轴走一点，海拔怎样变？只沿 w_2 轴走一点，海拔又怎样变？

常见误区 / 风险：不要提前把它等同于 Gradient

偏导数一次回答一个坐标轴方向的局部变化。下一讲才会把所有偏导数收集到一起形成 Gradient。

四、【必要公式】偏导数符号怎么读？

$\partial f / \partial x$

读作：“f 对 x 的偏导数”。符号 ∂ 用来提醒你：f 还有别的自变量，但当前只研究 x。

写法	自然语言	暂时固定什么
f / x	f 对 x 的局部敏感度	其他自变量，例如 y
f / y	f 对 y 的局部敏感度	其他自变量，例如 x
$L / w1$	Loss 对参数 w1 的局部敏感度	w2、b 以及当前样本都固定
L / b	Loss 对 bias 的局部敏感度	所有 weight 暂时固定

核心概念：“固定”不是永远不训练

这里只是在计算某一个偏导数的那一瞬间，把别的变量视作常数。真实训练时，下一步还会计算别的参数各自的偏导数。

五、【具体数字例子1】二维函数手算两个偏导数

设：

$$f(x,y) = x^2 + 3xy + y^2$$

我们研究点：

$$(x,y) = (2,1)$$

先对 x 求偏导。此时把 y 当作常数：

$$\partial f / \partial x = 2x + 3y$$

$$\partial f / \partial x \big|_{(2,1)} = 2 \cdot 2 + 3 \cdot 1 = 7$$


再对 y 求偏导。此时把 x 当作常数：

$$\partial f / \partial y = 3x + 2y$$

$$\partial f / \partial y \big|_{(2,1)} = 3 \cdot 2 + 2 \cdot 1 = 8$$

问题	答案	直觉
只增加一点 x , y 固定	局部变化率约为 7	x 每增加 0.01, f 约增加 0.07
只增加一点 y , x 固定	局部变化率约为 8	y 每增加 0.01, f 约增加 0.08

六、【图解】“一次只动一个变量”到底是什么意思？



当前点是 $(2, 1)$ 。水平线表示 $y=1$ 保持不变，只改变 x ；竖直线表示 $x=2$ 保持不变，只改变 y 。偏导数就是分别研究这两个一维切片在当前点附近的斜率。

数学直觉：从二维问题退回一维问题

求偏导数的核心技巧，就是把“其他变量固定”，让原本的多变量问题暂时变成一个熟悉的一维局部斜率问题。

七、【具体数字例子2】Loss 对 w_1 、 w_2 、 b 的偏导

考虑一个只有两个输入特征的线性模型：

$$y_{\text{hat}} = w_1 * x_1 + w_2 * x_2 + b$$

取：

$$x_1=2, x_2=-1, w_1=1.5, w_2=-0.5, b=0.2, \text{target}=3$$

先 Forward：

$$y_{\text{hat}} = 1.5 * 2 + (-0.5) * (-1) + 0.2 = 3.7$$

$$\text{error} = 3.7 - 3 = 0.7$$

$$L = \text{error}^2 = 0.49$$

分别求偏导得到：

$$\partial L / \partial w_1 = 2.8$$

$$\partial L / \partial w_2 = -1.4$$

$$\partial L / \partial b = 1.4$$

偏导	符号	如果该参数轻微增加，Loss 倾向
$L / w_1 = 2.8$	正	上升
$L / w_2 = -1.4$	负	下降
$L / b = 1.4$	正	上升

核心概念：先理解符号，不急着背推导

正偏导表示“向正方向增加这个参数，会让 Loss 局部上升”；负偏导表示“增加这个参数，会让 Loss 局部下降”。优化器以后会利用这个方向信息。

八、偏导数为什么还能预测“小扰动后的 Loss 变化”？

导数和偏导数都是局部线性近似。对很小的 Δw ，可以近似写成：

$$\Delta L \approx (\partial L / \partial w) * \Delta w$$

本讲实际实验把 w_1 增加 0.01：

$$\square\square \Delta L \approx 2.8 * 0.01 = 0.0280$$

$$\square\square \Delta L = 0.0284$$

把 w_2 增加 0.01：

$$\square\square \Delta L \approx -1.4 * 0.01 = -0.0140$$

$$\square\square \Delta L = -0.0139$$

数学直觉：为什么不是完全相等？

因为偏导数描述当前点的瞬时局部斜率。函数若有弯曲，走出一个有限的小距离后，真实变化还包含二阶及更高阶效应。 Δ 越小，一阶近似通常越准确，直到浮点误差开始显著。

九、【代码实验】怎样用数值差分估计偏导数？

对 x 的偏导可以用中心差分：

$$\partial f / \partial x \approx [f(x+eps, y) - f(x-eps, y)] / (2 * eps)$$

```
def central_partial_x(func, x, y, eps=1e-5):  
    # 只改变 x, y 保持不变  
    return (func(x + eps, y) - func(x - eps, y)) / (2 * eps)  
  
def central_partial_y(func, x, y, eps=1e-5):  
    # 只改变 y, x 保持不变  
    return (func(x, y + eps) - func(x, y - eps)) / (2 * eps)
```

实验结果：


$$\square\square \partial f / \partial x = 7.000000, \square\square = 7.000000$$

$$\square\square \partial f / \partial y = 8.000000, \square\square = 8.000000$$

科研连接：数值差分的科研用途

即使以后框架会自动求梯度，数值差分仍常用于 Gradient Check：拿一个很小的模型或少数参数，验证解析/自动求导结果是否合理。

十、Loss Surface 的“切片”直觉



$$\partial L / \partial w_1 \approx -0.666667$$

$$\partial L / \partial w_2 \approx +0.666667$$

数学直觉：这就是“partial”的本质

同一个二维 Loss Surface，可以沿不同坐标轴切出不同的一维曲线。每条切片在当前点的斜率，就是对应参数的偏导数。

十一、【常见误区】

常见误区 / 风险：误区1：偏导数是“只把公式算一半”

不是。`partial` 的含义是“多变量函数中，一次只允许一个自变量变化，其余暂时固定”。

常见误区 / 风险：误区2：偏导数为 0 就说明这个参数永远没用

只能说明在当前点、当前数据与当前函数状态下，沿该参数方向的一阶局部变化率为 0。换位置、换样本、换网络状态都可能不同。

常见误区 / 风险：误区3：偏导绝对值大就能直接解释现实特征重要性

偏导受输入尺度、参数化、Normalization、后续层和当前样本影响。训练敏感度不自动等于现实因果重要性。

常见误区 / 风险：误区4：只要偏导为负，就应该无限增加这个参数

偏导只描述局部。走远以后斜率会改变；优化器也会同时处理大量参数、学习率、Momentum 等。


常见误区 / 风险：误区5：数值差分就是实际大模型训练的方法

不是。对数十亿参数逐个扰动成本极高。真实深度学习使用 Backpropagation / Autograd 高效计算大量偏导数。

常见误区 / 风险：误区6：Loss 对某个参数的偏导只由这个参数自己决定

通常不是。偏导是在其他变量当前取值固定的条件下得到的，因此数值依赖整个计算图的当前状态。

十二、【与 LLM / Transformer / Agent Systems 的关系】



一个 Transformer 里有大量 Weight、Bias、Embedding 参数。训练得到一个标量 Loss 后，需要回答的不是“Loss 对一个 w 的导数”，而是：Loss 对所有可训练参数分别有多敏感。

科研连接：与 LLM Pretraining 的关系

Next-token Cross Entropy 产生标量 Loss；随后训练系统需要计算例如 L / w_Q 、 L / w_K 、 L / w_V 、 L / w_{FFN} 、 $L / \text{Embedding} \dots$ 。这里每一个“对参数的导数”本质上都是偏导。

科研连接：与 Agent Systems 的关系

你研究 Agent Systems 时通常不会自己训练基础模型，但论文可能涉及 SFT、LoRA、Router、Reward Model 或轻量可训练模块。能读懂“哪些参数被训练、Loss 对哪些参数求梯度”，是判断实验设置的最低模型基础。

核心概念：下一讲的桥

当偏导数不再只有 3 个，而是成千上万个甚至十亿个时，我们需要把它们组织起来。这个对象就是 Gradient。

十三、本讲最低验收标准

看到 $f(x,y)$ 能解释为什么要用 ∇ 而不是普通 d 。

能把 L/w_1 翻译成一句自然语言。

能说清“求 w_1 偏导时，把 w_2 、 b 暂时当常数”是什么意思。

能手算 $f=x^2+3xy+y^2$ 在 $(2,1)$ 的两个偏导：7 和 8。

能解释偏导数正、负、零分别表示什么局部含义。

知道 $\Delta L \approx (\nabla L/w) \Delta w$ 只是小范围一阶近似。

知道数值差分可以用于验证偏导，但不会用于逐参数训练大模型。

知道下一步要把所有偏导数组织成 Gradient。

核心概念：下一讲

第20讲将正式学习 Gradient：它不是新的神秘计算，而是“把所有参数的偏导数按顺序收集成一个向量/张量结构”，从而告诉我们 Loss 在多维参数空间里的局部变化方向。