


第20讲 实验设计

Gradient: 方向、范数、步长与参数 Shape

核心概念：实验设计文档

本讲只要求建立 Gradient 的必要直觉：它不是一个神秘的新公式，而是把第19讲得到的很多偏导数组织成与参数结构对应的一组数，并用来描述 Loss 在当前点附近最敏感的方向。



建议学习顺序：先看讲义 -> 手算二维例子 -> 运行方向实验 -> 做练习 -> 用速查卡复盘。

一、实验目标与研究问题

本实验延续“概念 -> 假设 -> 实验 -> 结果 -> 解释”的结构，不把 Gradient 当成只需记忆的定义。

RQ	研究问题	对应实验
RQ1	多个偏导数组成的 Gradient，能否被数值差分独立验证？	实验1
RQ2	Gradient 是否真的是当前点局部上升最快方向？	实验2
RQ3	Negative Gradient 是否自动意味着任意步长都下降？	实验3
RQ4	连续小步更新时，Loss 和 gradient norm 怎样变化？	实验4
RQ5	矩阵参数的 Gradient 是否与参数保持同 Shape？	实验5

二、可检验假设

- H1: 对 $L=(w1-2)^2+2(w2+1)^2$ ，在 $w=(0,1)$ 处，解析梯度 $[-4,8]$ 与中心差分结果一致。
- H2: 在足够小的固定移动距离下，遍历大量单位方向，Loss 增长最快的方向应与单位梯度方向几乎重合。
- H3: 沿负梯度更新时，小步长会让 Loss 下降，但过大步长可能让 Loss 反而高于更新前。
- H4: 在本简单凸二次函数和合适学习率下，连续更新会让 Loss 与 gradient norm 逐步下降。
- H5: 若 W 是 2×2 参数矩阵，则 $grad_W$ 也应为 2×2 ，并且每个元素与对应 W_{ij} 一一对齐。

三、实验变量与控制

项目	设置	为什么这样设计
Loss 函数	$L=(w_1-2)^2+2(w_2+1)^2$	简单、可手算、可画二维等高线。
初始参数	$w=(0,1)$	距离最低点 $(2,-1)$ 足够远，梯度方向明显。
数值差分 eps	$1e-5$	足够小，同时避免极端浮点误差。
方向搜索	$0\sim 2\pi$ 共721个方向	近似穷举单位圆上的局部方向。
局部移动步长	$1e-3$	让一阶局部近似更有效。
学习率	0.01/0.10/0.25/0.50/1.00	展示“方向”和“走多远”是两个不同问题。

科研连接：控制变量思想

实验2中每个方向都走相同距离，才能公平比较“方向”本身；否则走得更远的方向可能因为步长不同而造成混淆。

四、实验1：解析 Gradient 与数值 Gradient

手算：

$$\nabla L = [2(w_1-2), 4(w_2+1)]$$

$$w=(0,1) \rightarrow \nabla L=[-4,8]$$

代码使用中心差分逐个参数估计：

```
for i in range(w.size):  
    w_plus = w.copy()  
    w_minus = w.copy()  
    w_plus[i] += eps  
    w_minus[i] -= eps  
    grad[i] = (L(w_plus)-L(w_minus))/(2*eps)
```

实际结果：

项目	结果
解析 Gradient	$[-4, 8]$
数值 Gradient	$[-4, 8]$
最大绝对误差	约 $1e-10$
参数 Shape	$(2,)$
Gradient Shape	$(2,)$


五、实验2：721 个方向的局部搜索

对每个单位方向 d ，都从相同的当前点出发，移动相同的小距离 ϵ ：

$$\text{rate}(d) \approx [L(w+\epsilon d)-L(w)] / \epsilon$$

然后比较所有方向的 rate 。

量	实验结果
单位 Gradient	$[-0.447214, 0.894427]$
搜索到最快上升方向	$[-0.446198, 0.894934]$
方向余弦	0.999999
单位 Negative Gradient	$[0.447214, -0.894427]$
搜索到最快下降方向	$[0.446198, -0.894934]$




具体例子：解释

这不是数学证明，但它把“梯度方向”变成了可观察现象：在同样的小步长下，遍历大量方向，最陡方向与梯度几乎重合。

六、实验3：方向正确，步长为什么仍会出错？

使用最简单更新：

$$w_{\text{new}} = w - \eta \nabla L$$





η	新参数	新 Loss	相对原 Loss=12
0.01	[0.04,0.92]	11.2144	下降
0.10	[0.4,0.2]	5.4400	下降
0.25	[1,-1]	1.0000	大幅下降
0.50	[2,-3]	8.0000	仍下降
1.00	[4,-7]	76.0000	反而暴涨

核心概念：实验结论

Gradient 解决“局部往哪边走”；learning rate 解决“一次走多远”。把二者混为一谈，是初学者理解优化最常见的问题之一。

七、实验4：连续更新轨迹

固定 $\eta=0.15$ ，连续更新 12 次。



观察：Loss $12.0 \rightarrow 0.00156$ ；gradient norm $8.944 \rightarrow 0.079$ 。这个简单二次函数中，参数逐渐靠近最低点 $(2, -1)$ ，局部坡度也逐渐变平。

八、实验5：矩阵参数与 Gradient Shape

构造：

```
X.shape=(3,2), W.shape=(2,2), Y.shape=(3,2)
```

Forward:

$$P = XW$$

MSE:

$$L = \text{mean}((P-Y)^2)$$

实验得到：

```
grad_W.shape = (2,2)
```

```
grad_W =  
[[-0.16666667,  0.06666667],  
 [ 0.16666667,  0.16666667]]
```

每个数分别对应 W 中同一位置参数的偏导数。这就是后面 PyTorch 中 ``parameter.grad`` 能逐元素配对更新的基础。

九、结果解释与科研式结论

支持 H1: 解析 Gradient 与数值差分几乎完全一致, 说明 “Gradient=偏导数组合” 可被独立验证。

支持 H2: 721方向搜索得到的最快上升/下降方向与 $\pm$ Gradient 几乎重合。

支持 H3: $\eta=1.0$ 时即使沿 $-\text{Gradient}$ 更新, Loss 也从12升至76, 说明方向与步长必须分开讨论。

支持 H4: 在这个简单函数和 $\eta=0.15$ 条件下, Loss 与 gradient norm 都平稳下降。

支持 H5: 矩阵参数 W 与 grad_W Shape 完全一致, 验证了逐参数一一对应关系。

科研连接: 研究限制

本实验使用的是光滑、凸、二维/低维函数, 远比真实深度网络简单。它的目的不是证明真实 LLM Loss Landscape 也如此规整, 而是建立后面学习 Backpropagation、Optimizer、Gradient Clipping 所必需的一阶局部直觉。

十、复现实验步骤

确认 Python 环境安装 `numpy` 与 `matplotlib`。

运行 ``python lesson20_gradient_experiment.py``。

先阅读终端输出中的实验1和实验2，核对手算 `Gradient` 与方向余弦。

再看实验3不同 `learning rate` 的一步 `Loss`，重点观察 $\eta=1.0$ 。

打开 ``lesson20_gradient_direction.png``，用等高线理解 $\pm \text{Gradient}$ 。

打开 ``lesson20_loss_descent.png`` 与 ``lesson20_gradient_norm.png``，观察连续更新。

最后阅读实验5的 ``grad_W.shape``，把“同 Shape”规则连接到未来 PyTorch 参数。

建议修改实验

把初始 `w` 改成 `[3,-2]`，先手算再运行。

把 η 增加到 1.5 或 2.0，观察发散程度。

把 `Loss` 中 `w2` 项的系数 2 改成 20，观察等高线变“更窄”以及两个方向梯度尺度如何改变。

把数值差分 `eps` 分别改成 `1e-2`、`1e-5`、`1e-9`，观察浮点误差与近似误差。