


第20讲核心概念速查卡

Gradient（梯度）一页一层地复盘

核心概念：速查卡

本讲只要求建立 Gradient 的必要直觉：它不是一个神秘的新公式，而是把第19讲得到的很多偏导数组织成与参数结构对应的一组数，并用来描述 Loss 在当前点附近最敏感的方向。



建议学习顺序：先看讲义 -> 手算二维例子 -> 运行方向实验 -> 做练习 -> 用速查卡复盘。

1. 最核心定义

$$\nabla L = [\partial L / \partial w_1, \partial L / \partial w_2, \dots, \partial L / \partial w_n]$$

核心概念：一句话

Gradient 就是把 Loss 对各个参数的偏导数按参数结构组织起来。

2. 三个必须区分的东西

概念	作用
Gradient	局部敏感度与方向信息
Negative Gradient	局部最快下降方向
Learning Rate η	决定沿这个方向一次走多远

3. 方向直觉

Gradient -> local steepest increase

-Gradient -> local steepest decrease

4. Gradient norm

$$||\nabla L|| = \text{sqrt}(g_1^2 + g_2^2 + \dots + g_n^2)$$

5. Shape 规则

参数	参数 Shape	Gradient Shape
向量 w	$(D,)$	$(D,)$
矩阵 W	(D_{in}, D_{out})	(D_{in}, D_{out})
Embedding	(V, D)	(V, D)

6. 一个数字例子

$$L = (w_1 - 2)^2 + 2(w_2 + 1)^2, w = [0, 1]$$

$$\nabla L = [-4, 8], ||\nabla L|| \approx 8.944$$


7. 更新式（先建立直觉）

$$w_{new} = w - \eta \nabla L$$

常见误区 / 风险：警告

方向正确不代表任意步长都安全。 η 太大时，Loss 可以反而上升。

8. LLM 训练闭环



9. 读论文/代码时的翻译

gradient norm → 梯度整体长度/尺度指标

gradient clipping → 对过大的梯度做限制（后面再学）

zero_grad → 清理已有梯度缓存（PyTorch 阶段再学）

frozen parameters → 参数不更新，通常不需要为其保留更新用梯度

grad accumulation → 多个 mini-batch 的梯度累积（以后按需）

10. 六个不要

不要把 gradient 当成最终参数更新量。

不要把 -gradient 当成全局最短路线。

不要把 gradient=0 自动当成最优。

不要把 gradient 大小直接解释成现实因果重要性。

不要忘记 gradient 是当前数据、当前参数和当前 Loss 下的局部量。

不要忘记参数 Tensor 与其 gradient Tensor 需要能逐元素对应。