


第20讲练习题与答案

Gradient: 从偏导集合到方向

核心概念：练习题与答案

本讲只要求建立 Gradient 的必要直觉：它不是一个神秘的新公式，而是把第19讲得到的很多偏导数组织成与参数结构对应的一组数，并用来描述 Loss 在当前点附近最敏感的方向。



建议学习顺序：先看讲义 -> 手算二维例子 -> 运行方向实验 -> 做练习 -> 用速查卡复盘。

一、练习题

1. 用一句自然语言解释 Gradient 与 Partial Derivative 的关系。
2. 若 $L/w_1=3$, $L/w_2=-4$, 写出 L , 并计算 $\|L\|$ 。
3. 上题中, 哪个方向是局部最快下降方向?
4. 参数 $W.shape=(3,5)$, 那么 $grad_W$ 通常是什么 Shape? 里面每个元素代表什么?
5. 为什么说 Gradient 提供的是“局部”信息?
6. 如果 $L=[-4,8]$, $\eta=0.1$, 根据最简单的 Gradient Descent 形式, 参数 $w=[0,1]$ 更新后是什么?
7. 沿负梯度走, 为什么 Loss 仍然可能上升?
8. $L=0$ 是否必然说明已经找到全局最优? 为什么?
9. “某个权重的梯度绝对值很大, 所以这个输入特征最重要。”这句话有什么问题?
10. LLM 的 W_Q 是一个矩阵, 为什么它的 gradient 也应该是一个矩阵而不是单个数字?
11. Gradient 和 Optimizer 分别回答什么问题?
12. 数值差分能估计 Gradient, 为什么真实大模型训练不用“每个参数分别加一点/减一点”的方法?
13. 本讲实验中梯度方向与搜索到的最快上升方向余弦 ≈ 0.999999 , 这个数值说明什么?
14. 如果所有参数都被冻结, 只做 Forward 和 Loss 评估, 还一定需要保存这些参数的训练梯度吗?

二、答案与解释

1. Partial Derivative 是一次看一个参数对 Loss 的局部影响；Gradient 把这些偏导按参数结构收集起来。
2. $L=[3,-4]$ ；范数 $\sqrt{3^2+(-4)^2}=5$ 。
3. 局部最快下降方向是 $-L=[-3,4]$ ；如果只关心方向，还可以把它归一化。
4. 通常也是 $(3,5)$ 。每个位置 (i,j) 存放 L/W_{ij} ，即该权重元素轻微变化对当前 Loss 的一阶局部影响。
5. 因为梯度描述的是当前位置附近的一阶变化。走得很远以后函数曲率可能改变，原来的梯度方向不再代表新的局部情况。
6. $w_{\text{new}}=w-0.1 \cdot L=[0,1]-0.1[-4,8]=[0.4,0.2]$ 。
7. 负梯度只保证足够小的局部步长方向正确；步长太大可能跨过低谷进入更高 Loss 区域。
8. 不必然。梯度为0只表示一阶局部坡度为0，可能是极小值、极大值、鞍点或平坦区。
9. 梯度受输入尺度、参数化、当前样本/Batch、当前 Loss 和当前参数影响，不能直接当作现实因果重要性或全局特征重要性。
10. 因为 W_Q 的每个矩阵元素都是一个独立可训练参数，每个元素都需要一个对应偏导；把它们按原位组织起来就是同 Shape 的 gradient matrix。
11. Gradient 回答“当前局部往哪里、对每个参数有多敏感”；Optimizer 回答“根据这些梯度和自己的规则，参数实际怎么更新”。
12. 参数数量巨大时，逐参数数值差分需要天文数量的 Forward。Backpropagation 能复用计算图高效得到大量参数梯度。
13. 余弦非常接近1，说明两个单位方向几乎重合，从数值实验上验证了梯度方向确实是局部最快上升方向。
14. 如果参数完全冻结且只做推理/评估，通常不需要保存这些参数用于更新的梯度；这也是减少显存/内存开销的重要原因之一。

三、动手题：先预测，再运行

打开本讲实验代码，把初始点从 $w=[0,1]$ 改成 $w=[3,-2]$ 。运行前先手算：

$$\partial L / \partial w_1 = 2(w_1 - 2)$$

$$\partial L / \partial w_2 = 4(w_2 + 1)$$

请先写出新的 Gradient、Negative Gradient 和 Gradient Norm，再运行程序核对。

具体例子：进一步观察

尝试把 `learning_rate` 列表中加入 0.75、1.5。不要先猜“越大越快”，先根据局部方向和二次函数曲率思考可能发生什么。