


## 第21讲 实验设计

Loss Landscape: 低谷、鞍点、Flat/Sharp 与 Plateau

核心概念：实验设计文档

本讲不要求你学习高维优化理论，也不要求证明复杂定理。目标是把 Loss、Gradient、Optimizer 放进一张“地形图”里：看懂低谷、鞍点、平坦区、陡峭区，并知道为什么  $\text{gradient} \approx 0$  不能单独说明训练已经成功。



建议学习顺序：先看二维图 -> 再看公式 -> 运行实验 -> 最后回到 LLM 训练日志。

## 一、实验目标与研究问题

RQ1: Gradient 是否只描述当前位置的局部坡度，而不能单独描述整个 Landscape?

RQ2: Gradient=0 是否可能出现在非最小点?

RQ3: 两个函数具有同一最低点时，局部陡峭程度能否明显不同?

RQ4: 是否可能出现 Loss 很高但 gradient 已经非常小的 plateau?

RQ5: 在简单凸 bowl 中，不同起点的负梯度轨迹是否会收敛到同一低谷?

核心概念：实验定位

这是“概念验证实验”，目的不是模拟真实 LLM 的完整高维 Landscape，而是把几个科研术语变成可观察现象。

## 二、变量与函数

| 实验           | 函数                       | 观察变量              | 预期现象                      |
|--------------|--------------------------|-------------------|---------------------------|
| 1 凸 bowl     | $(w_1-1)^2+2(w_2+0.5)^2$ | Loss、Gradient、最低点 | Gradient 指向局部上升，负梯度朝低谷    |
| 2 Saddle     | $x^2-y^2$                | 原点梯度、不同方向 Loss    | 原点 gradient=0 但不是 minimum |
| 3 Flat/Sharp | $0.2w^2$ vs $5w^2$       | 同一偏移下 Loss        | 最低点相同，局部陡峭度不同             |
| 4 Plateau    | $\tanh(w)^2$             | Loss、 gradient    | 远端高 Loss 但梯度极小            |
| 5 Trajectory | 凸 bowl                   | 不同起点轨迹            | 合适步长下汇聚到同一低谷              |

### 三、实验假设

H1: 凸 bowl 的解析 Gradient 与中心差分数值 Gradient 应一致。

H2: 鞍点原点的一阶 Gradient 为0，但沿不同方向 Loss 一升一降。

H3: Flat 与 Sharp 函数在  $w=0$  有相同最低点，但同样的参数扰动会造成不同 Loss 增量。

H4: tanh 饱和区可以出现 Loss 接近1但梯度接近0。

H5: 对于本实验严格凸函数，三个不同初始点在  $lr=0.15$  时应靠近唯一最低点。

## 四、实验步骤

步骤1: 运行 ``lesson21_loss_landscape_experiment.py``, 先记录终端输出, 不要只看图。

步骤2: 实验1比较解析 Gradient 与数值差分 Gradient, 确认最大误差。

步骤3: 实验2记录原点以及  $x/y$  轴附近点的 Loss, 判断原点属于哪种地形结构。

步骤4: 实验3在  $w=0.1、0.5、1.0$  比较 Flat 与 Sharp 的 Loss。

步骤5: 实验4记录  $w=0、1、3、5$  时的 Loss 与  $|\text{gradient}|$ , 观察 plateau。

步骤6: 实验5从三个初始点运行 25 步 Gradient Descent, 比较最终参数和 Loss。

步骤7: 查看 5 张 PNG: 先用语言描述现象, 再看代码对应哪一行产生这个现象。

## 五、关键代码与 Shape

```
point = np.array([0.0, 1.0])      # shape: (2,)
grad = bowl_grad(*point)          # shape: (2,)

X, Y = np.meshgrid(x, y)          # shape: (250, 250)
Z = bowl_loss(X, Y)               # shape: (250, 250)

w = w - learning_rate * grad      # 参数更新
```

| 对象    | Shape     | 含义           |
|-------|-----------|--------------|
| point | (2,)      | 一组二维参数       |
| grad  | (2,)      | 当前点 Gradient |
| X,Y   | (250,250) | 二维参数网格       |
| Z     | (250,250) | 每个网格点的 Loss  |

## 六、实际实验结果

本材料生成时已实际运行代码，得到：

| 项目                | 实际结果                               |
|-------------------|------------------------------------|
| Bowl 当前点 [0,1]    | Loss=5.5, Gradient=[-2,6]          |
| 解析 vs 数值 Gradient | 最大误差约 3.93e-11                     |
| Saddle 原点         | Loss=0, Gradient=[0,0]，但 y 方向可继续下降 |
| Plateau w=5       | Loss≈0.999818,  gradient ≈0.000363 |
| 三条 GD 轨迹          | 25步后均到 [1,-0.5] 附近, Loss≈1e-7      |

常见误区 / 风险：如何解读

实验支持本讲的五个概念性假设。但这些是人为构造的低维函数，只能验证概念，不应该外推成“真实 LLM Landscape 就长这样”。

## 七、科研式记录模板

| 栏目                      | 你应该写什么                                     |
|-------------------------|--------------------------------------------|
| Observation             | 客观现象：哪一个点、Loss、Gradient、曲线形状               |
| Interpretation          | 你对现象的解释，如“原点是一阶驻点但不是最低点”                   |
| Alternative explanation | 是否可能来自函数选择、尺度或步长设置                         |
| Boundary                | 哪些结论仅适用于这个玩具函数                             |
| Connection              | 它对应论文中的哪个术语：saddle / plateau / sharpness 等 |

科研连接：这一步比“图画出来了”更重要

以后做真正科研实验，同样要把 Observation 与 Interpretation 分开。图只是证据载体，不是结论本身。

## 八、扩展实验与边界条件

改变 `bow1` 第二项系数，观察等高线纵横比例与 `Gradient` 分量如何变化。

增大学习率，观察“方向没错但步长过大”如何让轨迹振荡或发散。

把 `saddle` 函数换成  $x^2 - 0.1y^2$ ，观察不同方向曲率尺度。

比较 `train loss landscape` 与 `validation loss landscape` 的概念差异，但当前不需要实现大模型实验。

未来学 PyTorch 后，可用 `autograd` 计算同样函数的 `Gradient`，再与本讲 NumPy 解析/数值结果对照。

核心概念：停止线

当前不要进入 `Hessian eigenvalues`、二阶优化、随机矩阵理论或大模型 `loss surface` 可视化工具。等真实论文问题需要时再补。