


第21讲练习题与答案

Loss Landscape: 会读地形, 不把二维图当真实世界

核心概念: 练习题与答案

本讲不要求你学习高维优化理论, 也不要求证明复杂定理。目标是把 Loss、Gradient、Optimizer 放进一张“地形图”里: 看懂低谷、鞍点、平坦区、陡峭区, 并知道为什么 $\text{gradient} \approx 0$ 不能单独说明训练已经成功。



建议学习顺序: 先看二维图 -> 再看公式 -> 运行实验 -> 最后回到 LLM 训练日志。

一、练习题

1. 用自己的话解释 Loss Landscape 中“位置”和“高度”分别代表什么。
2. Gradient 与 Loss Landscape 的关系是什么？为什么说 Gradient 只是局部信息？
3. Local Minimum 与 Global Minimum 有什么区别？
4. 对 $L(x,y)=x^2-y^2$ ，原点 Gradient 是多少？为什么原点不是局部最小值？
5. Gradient 接近 0 时，至少列出三种不同可能。
6. $L1=0.2w^2$ 与 $L2=5w^2$ 的最低点是否不同？它们的主要差别是什么？
7. 为什么“flat minimum 一定泛化好”不是一个可以直接接受的结论？
8. 对 $L(w)=\tanh(w)^2$ ，为什么 w 很大时会出现高 Loss 但小 gradient？
9. 一篇论文画出二维 loss landscape，就等于画出了整个 LLM 参数空间吗？为什么？
10. 看到论文中的 landscape 图，你至少应该追问哪四个实验细节？
11. 不同初始化为什么可能形成不同优化轨迹？在本讲凸碗实验中最后为什么又会汇聚到同一个最低点？
12. Agent Systems 研究者为什么仍然值得理解 Loss Landscape，哪怕多数实验只调用现成 API？

二、答案与解释

1. 位置代表模型参数取值，高度代表这组参数在当前 objective 下得到的 Loss。
2. Gradient 是 Landscape 在当前位置的一阶坡度信息；走到新位置后坡度会重新变化，所以它不是整张地图。
3. Local Minimum 只保证附近没有更低点；Global Minimum 是整个考虑范围内的最低点。
4. 原点 Gradient=[0,0]。但沿 x 方向 Loss 增大，沿 y 方向 Loss 减小，所以原点是鞍点而不是低谷。
5. 局部最小、局部最大、鞍点、平坦/饱和区域都可能出现零或很小的一阶梯度。
6. 最低点都在 $w=0$ 。主要差别是离开最低点后 Loss 上升速度不同，即局部曲率/陡峭程度不同。
7. sharpness/flatness 受参数化、尺度和测量方法影响；是否与泛化相关需要看具体理论定义和实验，不能只凭几何比喻。
8. tanh 在大正负输入时进入饱和区，函数输出变化很慢，因此导数很小；但 $\tanh(w)^2$ 此时接近1，并不是最小 Loss。
9. 不是。LLM 参数可能有几十亿维，二维图通常只是切片、投影或两条方向上的观察。
10. 例如：坐标轴定义、Loss 数据集/目标、二维切片方法、方向选择、参数尺度归一化、是否可跨模型比较。
11. 不同起点的局部梯度不同，因此路径不同。本讲 bowl 是简单严格凸函数，只有一个最低点，所以合适步长下最终汇聚到同一解附近。
12. 因为一旦涉及 LoRA/QLoRA、小模型训练、奖励模型、策略模型或训练稳定性分析，就会遇到 gradient、plateau、sharpness、optimization 等概念；理解地形直觉能帮助判断实验而不是只看 API 输出。

三、动手题

打开本讲代码，尝试下面三个改动。每次先预测，再运行：

把 `bow1_loss` 中 `w2` 前面的系数从 2 改成 10，观察等高线怎样变“窄”，`Gradient` 的第二个分量怎样变化。

把 `plateau` 实验里的 `w` 从 5 改成 8，观察 `Loss` 与 `gradient`；解释为什么“更平”不等于“更好”。

把 `Gradient Descent` 的 `learning rate` 从 0.15 改成 0.6，观察轨迹是否仍然稳定靠近最低点。