


第21讲：Loss Landscape

参数空间里的山谷、鞍点、平坦区域到底是什么？

核心概念：【理解即可，但直觉要扎实】

本讲不要求你学习高维优化理论，也不要求证明复杂定理。目标是把 Loss、Gradient、Optimizer 放进一张“地形图”里：看懂低谷、鞍点、平坦区、陡峭区，并知道为什么 $\text{gradient} \approx 0$ 不能单独说明训练已经成功。



建议学习顺序：先看二维图 -> 再看公式 -> 运行实验 -> 最后回到 LLM 训练日志。

一、本讲学习目标

理解 Loss Landscape 是“参数位置 $\rightarrow$ Loss 高度”的概念图，而不是神经网络里真的存在一座山。

区分 Global Minimum、Local Minimum、Saddle Point、Plateau / Flat Region、Sharp Region。

理解 Gradient 是 Landscape 在“当前位置”的局部坡度信息，而不是整张地图。

理解 $\text{gradient} \approx 0$ 的多种可能含义：最低点、最高点、鞍点、饱和平坦区。

理解“flat/sharp”首先是几何/曲率直觉，不能简单等价成“泛化一定好/坏”。

理解真实 LLM 的参数空间极高维，二维图只是切片和比喻，不能把玩具图当成真实整体形状。

核心概念：与第20讲的关系

第20讲回答“我站在当前点，哪边最陡？”；第21讲开始回答“周围地形可能是什么样？这个点是低谷、鞍点，还是高 Loss 平台？”

二、【原理】什么叫 Loss Landscape?

假设模型只有两个参数 w_1 、 w_2 ，那么每一组参数都会产生一个 Loss:

$$L = L(w_1, w_2)$$

于是可以把:

数学对象	地形类比	深度学习含义
(w_1, w_2)	地图上的位置	当前参数取值
$L(w_1, w_2)$	海拔高度	当前 Loss
Gradient	当前位置的坡度箭头	局部最敏感方向
Optimizer path	人在地形上的移动轨迹	参数更新轨迹

如果参数只有两个，我们能画二维等高线或三维曲面；如果参数有几十亿个，就已经无法直接画出完整 Landscape。

具体例子：通俗解释

Loss Landscape 可以理解成“把每一组参数的好坏画成地形”。低处通常表示 Loss 小，高处表示 Loss 大。训练就是参数在这片高维地形中不断移动。

三、【具体数字例子】一个最简单的碗形 Landscape

$$L(w_1, w_2) = (w_1 - 1)^2 + 2(w_2 + 0.5)^2$$

这个函数的最低点非常明确：

$$w_1 = 1, w_2 = -0.5, L = 0$$


在当前点：

$$w = [0, 1]$$

实验得到：

$$L = 5.5$$

$$\nabla L = [-2, 6]$$



等高线越靠近最低点，Loss 越小。Gradient 箭头描述的是“当前点附近最陡的上升方向”；负梯度则指向局部下降方向。

数学直觉：关键直觉

Landscape 是全局或大范围的几何概念；Gradient 是只在当前点成立的一阶局部信息。

四、【局部最小与全局最小】不要混为一谈

概念	通俗解释	科研阅读时怎么理解
Global Minimum	整张地形最低的地方	理论上的全局最低 Loss
Local Minimum	周围一小圈都比它高，但远处可能还有更低位置	局部低谷
Local Maximum	周围一小圈都比它低	局部山顶
Saddle Point	某些方向向上、另一些方向向下	一阶梯度可能为0，但不是最低点

在深度网络里，“是否存在大量局部最小值、它们质量怎样、优化器为什么能找到可用解”是复杂研究问题。本课只需要先建立这些几何名词。

科研连接：不要把训练简化成“找唯一最低点”

真实神经网络通常高度过参数化，存在大量等价或近似等价参数配置。即使训练 Loss 很低，也不代表只有一个参数解。

五、【鞍点】为什么 $\text{Gradient}=0$ 不等于“已经到谷底”？


$$L(x,y) = x^2 - y^2$$

在原地:

$$\nabla L(0,0) = [0,0]$$

但实验中:

位置	Loss	说明
(0,0)	0	Gradient=0
(0.2,0)	0.04	沿 x 方向离开, Loss 上升
(0,0.2)	-0.04	沿 y 方向离开, Loss 下降
(0.5,0)	0.25	x 方向继续上升
(0,0.5)	-0.25	y 方向继续下降



常见误区 / 风险: 核心结论

$\text{Gradient}=0$ 只说明一阶局部斜率为0。它可能是最低点,也可能是最高点、鞍点或某种平坦/饱和区域。

六、【Flat 与 Sharp】同一个最低点，也可以“宽窄不同”

考虑两条非常简单的一维曲线：

$$L_{\text{flat}}(w) = 0.2 w^2$$


$$L_{\text{sharp}}(w) = 5 w^2$$

它们的最低点都在：

$$w = 0, L = 0$$

但离开最低点一点点以后，上升速度完全不同：

w	Flat Loss	Sharp Loss
0.1	0.002	0.050
0.5	0.050	1.250
1.0	0.200	5.000



科研连接：科研上的重要限定

文献中常讨论 flat minima、sharp minima 与泛化的关系，但“平坦=一定泛化好、尖锐=一定泛化差”不是可以脱离参数化和测量方法直接下的普遍结论。本课先掌握几何直觉，不把它变成简单规则。


七、【Plateau / Flat Region】梯度很小，但 Loss 仍可能很高

构造一个玩具函数：

$$L(w) = \tanh(w)^2$$

它在 $w=0$ 附近最低；但当 $|w|$ 很大时，曲线接近水平。实验得到：

w	Loss	gradient
0	0.000000	0.000000
1	0.580026	0.639700
3	0.990134	0.019634
5	0.999818	0.000363



在 $w=5$ 附近，Loss 接近 1，并不好，但梯度已经非常小。

常见误区 / 风险：为什么这很重要


以后遇到“gradient 很小”“训练几乎不动”，不能只说“模型收敛了”。还要看 Loss 水平、任务指标、激活饱和、学习率、归一化和其他训练状态。

八、【Loss Landscape 与 Optimizer Path】参数到底怎样在地形里移动？

最简单的 Gradient Descent 形式：

$$w_{\text{new}} = w - \eta \nabla L$$

可以把它想成：每一步重新观察当前位置坡度，然后走一小步，再重新测坡度。



本讲实验从三个不同起点出发，在这个简单凸函数上都逐渐靠近同一个最低点。25步后 Loss 都降到 10^{-7} 量级。

常见误区 / 风险：只在简单凸例子里这么整齐

真实深度网络不是一个漂亮的二维碗：它高维、非凸、存在参数对称性、mini-batch 噪声以及复杂曲率。这里仅用来理解“优化轨迹是在 Landscape 上不断重新计算局部方向”。

九、【必要公式】Landscape、Gradient、Curvature 的层次

对本课当前层次，可以把三类信息分开：

层次	代表信息	本课程要求
Loss $L(w)$	当前位置有多高	必须掌握
Gradient L	当前点的一阶坡度/方向	必须掌握
Curvature 曲率	坡度本身怎样变化、地形有多弯	先理解直觉
Hessian	多变量二阶导数组成的矩阵	以后按需再学

在一维里，二阶导数可以帮助判断“弯曲方向”；在多维里会出现 Hessian 等工具。但你的 Agent Systems 科研当前不需要系统学习 Hessian 推导。

核心概念：Just-in-Time Math 到此为止

这一讲知道“Flat/Sharp 与曲率有关”即可。不要为了理解一个术语，停下来学完整多元微积分和二阶优化。

十、【代码实验】怎样用 NumPy 观察 Landscape?

二维 Loss 的基本写法:

```
def loss(w1, w2):  
    return (w1 - 1.0)**2 + 2.0*(w2 + 0.5)**2  
  
x = np.linspace(-2.5, 3.5, 250)  
y = np.linspace(-2.5, 2.5, 250)  
X, Y = np.meshgrid(x, y)  
Z = loss(X, Y)  
  
plt.contour(X, Y, Z, levels=18)
```

这里:

变量	Shape / 含义
x	一组 w1 候选值
y	一组 w2 候选值
X, Y	二维网格, 每个格点代表一组参数
Z	每组参数对应的 Loss 高度

所以画 Loss Landscape, 本质上就是“枚举许多参数位置 → 计算 Loss → 把相同高度连成等高线”。

科研连接: 真实 LLM 为什么不能这样画?

如果模型有几十亿参数, 不可能为每个轴铺网格, 也不存在人能直接看到的几十亿维图。论文里的 Landscape 图通常是二维切片、投影、插值路径或其他降维观察。

十一、【与 LLM / Transformer 的关系】你以后会在哪里遇到这些词？

你可能看到的术语	先怎样理解
optimization landscape	参数空间中 objective 的几何结构
loss basin	一片相对较低的区域/低谷
saddle point	某些方向上升、某些方向下降的驻点
flat region / plateau	局部变化很慢、梯度可能很小
sharp / flat minima	最低点附近对参数扰动的敏感程度不同
loss barrier	两组参数之间插值路径上出现较高 Loss
linear mode connectivity	不同解之间某些低 Loss 路径的研究主题

这些术语不仅存在于基础深度学习论文，也会出现在模型微调、模型合并、LoRA、持续学习和多任务训练等工作中。

科研连接：Agent Systems 连接

Agent Systems 本身常以 API 或现成 LLM 为底座，不一定直接研究 Landscape。但一旦你做 LoRA/QLoRA、训练小模型、学习策略模型、奖励模型，或分析训练不稳定，这套直觉会直接帮助你理解日志与论文。

十二、【常见误区】

常见误区 / 风险：误区1: Loss Landscape 是真实可见的二维山地
不是。二维图只是低维函数或高维参数空间的某种切片/投影。

常见误区 / 风险：误区2: Gradient=0 就是训练成功
不一定，鞍点和高 Loss 平台都可能出现很小甚至为0的一阶梯度。

常见误区 / 风险：误区3: 训练就是寻找唯一的全局最低点
真实深度网络可能存在大量等价、近似等价或功能相似的参数解。

常见误区 / 风险：误区4: Flat minimum 一定泛化好
不能脱离参数化、尺度、测量方式和具体研究证据直接下结论。

常见误区 / 风险：误区5: Sharp minimum 一定是坏模型
同样不能机械判断。先看论文具体怎样定义 sharpness，以及它与实验指标之间的证据。

常见误区 / 风险：误区6: 二维图看起来简单，所以大模型优化也简单
真实模型维度和训练噪声远高于二维玩具函数。二维图只负责建立最低必要直觉。

十三、【科研阅读方法】看到 Landscape 图时先问什么？

图中的两个轴到底是什么？是真实两个参数，还是随机方向、PCA 方向、模型插值系数？

Loss 是 train loss、validation loss，还是其他 objective？

图是完整空间还是二维切片？切片方向怎样选的？

参数有没有做 normalization / filter normalization？不同尺度会不会改变“sharpness”视觉结果？


论文声称 flat/sharp 与某个性能相关时，是相关性、机制证据，还是只是一张示意图？

比较不同模型的 Landscape 时，参数化和尺度是否可比？

科研连接：这就是科研最低闭环能力

不是看到一张“山谷图”就接受作者叙事，而是先搞清楚坐标、Loss 定义、切片方法和比较条件。

十四、本讲知识闭环



现在把第19-21讲连起来:

Partial Derivative -> Gradient -> Loss Landscape

下一讲将进入真正的 Backpropagation 数学入口:

核心概念: 下一问

神经网络的 Loss 并不是直接写成 $L(w_1, w_2)$, 而是通过很多层中间变量间接依赖早期参数。怎样把“后面的变化”传回到“前面的参数”? 答案是 Chain Rule。