


第25讲 实验设计

两层 MLP Backpropagation: 手工矩阵推导、Gradient Check 与 Autograd

核心概念: 实验设计

本讲把上一讲的单神经元 Backpropagation 升级为真正的两层 MLP。目标是看懂每一层的 Tensor、Gradient、Transpose 和 Shape 怎样配合, 让最终 Loss 一层一层传回 $W2$ 、 $b2$ 、 $W1$ 、 $b1$, 最终还能继续传给输入。



建议学习方式: 先跟着固定的 3->2->1 数字例子手算, 再理解矩阵公式, 最后运行 Numerical Gradient Check 与 PyTorch Autograd 对照。

一、实验目标

构造一个固定的 3→2→1 两层 MLP，并记录每个中间 Tensor。

用 NumPy 手工实现完整矩阵 Backpropagation。

验证所有参数 Gradient Shape 与参数 Shape 完全一致。

逐元素对 $W1$ 、 $b1$ 、 $W2$ 、 $b2$ 、 x 做 Numerical Gradient Check。

观察 ReLU 关闭一个 hidden unit 时，对 $W1$ 对应整列梯度的影响。

做一次小步负梯度更新并重新 Forward，验证 Loss 下降。

把单样本公式扩展到 Batch + mean MSE。

用 PyTorch Autograd 验证 NumPy 手工梯度。

二、实验问题与假设

实验问题	可检验假设
Q1 矩阵 Backprop 公式是否正确?	所有 Numerical Gradient Check 误差应远小于 $1e-6$
Q2 Gradient Shape 是否匹配?	$dW1/W1$ 、 $dW2/W2$ 、 db/b 、 dx/x Shape 应逐一相同
Q3 ReLU gate 会影响哪部分?	关闭 hidden unit 后, 进入该单元的第一层 Weight 梯度整列为0
Q4 一小步更新是否降 Loss?	足够小 learning rate 下当前 Loss 应下降
Q5 Batch 公式是否改变?	Linear backward 结构不变, 只多 batch 聚合
Q6 Autograd 是否等价?	PyTorch 与 NumPy 手工梯度应一致

三、固定网络与参数

对象	数值 / Shape
x	[[1,2,-1]] ; (1,3)
W1	[[0.5,-1],[1,0.5],[-0.5,2]] ; (3,2)
b1	[0,0] ; (2,)
W2	[[2],[-1]] ; (2,1)
b2	[0.5] ; (1,)
target	[[5]] ; (1,1)
Activation	ReLU
Loss	sum((y_hat-target)^2)
Gradient Check eps	1e-5
一步更新 lr	0.01

四、实验1：完整 Forward 与中间缓存

记录: $z1$ 、 $a1$ 、 y_hat 、 $error$ 、 $Loss$ 。预期:


$z1=[3,-2]$

$a1=[3,0]$

$y_hat=6.5$, $error=1.5$, $Loss=2.25$


为什么要 cache 中间量? 因为 Backward 需要用到 Forward 时的 x 、 W 、 z 、 $activation$ 等。

两层 MLP: 上方 Forward, 下方 Backward



五、实验2：手工矩阵 Backward

按固定顺序执行：



量	预期结果
dy_hat	[[3]]
dW2	[[9],[0]]
db2	[3]
da1	[[6,-3]]
dz1	[[6,0]]
dW1	[[6,0],[12,0],[-6,0]]
db1	[6,0]
dx	[[3,6,-3]]

六、实验3：Gradient Shape Check

参数 / 输入	原 Shape	Gradient Shape	预期
W1	(3,2)	(3,2)	一致
b1	(2,)	(2,)	一致
W2	(2,1)	(2,1)	一致
b2	(1,)	(1,)	一致
x	(1,3)	(1,3)	一致

科研连接：为什么单独做这个实验

科研代码里 Shape 错误往往比公式概念错误更常见。把 Shape invariant 写进测试，可以尽早发现广播、转置、batch 维处理错误。


七、实验4: Numerical Gradient Check

对每个参数元素 q :

$$g_numeric = [L(q+eps)-L(q-eps)]/(2eps)$$

逐元素比较 analytic 与 numeric。预期最大绝对误差约:

1.9e-10



数学直觉: 重点

矩阵梯度不是“整体检查一次”，而是矩阵中每个元素都对应一个偏导数。Numerical check 正是在逐元素验证。

八、实验5：ReLU gate 对梯度矩阵的影响


本例：

$z1=[3,-2]$, $mask=[1,0]$

$da1=[6,-3] \rightarrow dz1=[6,0]$

因此 $W1$ 第二列：

$$dW1[:,1] = 0$$



核心概念：实验解释

第二个 hidden unit 没有把当前样本的误差信号继续传给它的 incoming weights。这是当前样本、当前参数状态的局部现象。


九、实验6：一次参数更新

同步更新四组参数：

$W1 \leftarrow lr * dW1$; $b1 \leftarrow lr * db1$; $W2 \leftarrow lr * dW2$; $b2 \leftarrow lr * db2$

$lr=0.01$ ，预期：

Loss 2.25 -> 0.158245



十、实验7: Batch + mean MSE 预览

构造两个样本:

$$X:(2,3), Y:(2,1)$$

Forward 后 $Z1:(2,2)$, 不同样本可以产生不同 ReLU mask。mean MSE 下:

$$dY_hat = (2/B)*(Y_hat-Y)$$

然后仍使用:

$$dW2=A1^T@dY_hat; dW1=X^T@dZ1$$

实际实验输出:

$$\text{batch Loss} = 3.125$$

$$dW1=[[3,0],[2,2],[-7,2]]$$

$$dW2=[[3.5],[-5]]$$

科研连接: 科研连接

当论文改变 Batch Size、Gradient Accumulation 或 Loss reduction 时, 即使模型结构不变, 单步梯度尺度也可能改变。

十一、实验8：PyTorch Autograd 对照

```
z1 = x @ W1 + b1
a1 = torch.relu(z1)
y_hat = a1 @ W2 + b2
loss = torch.sum((y_hat - target) ** 2)
loss.backward()
```

检查 `W1.grad`、`b1.grad`、`W2.grad`、`b2.grad`、`x.grad`。预期最大 NumPy-vs-PyTorch 差异：

0.0

核心概念：目的

这里使用 PyTorch 不是为了省略原理，而是用工业级 Autograd 作为独立实现对照，增强实验正确性证据。

十二、实验记录模板

记录项	必须记录
Forward	每个 Tensor 数值 + Shape
Backward	每个 upstream / parameter grad / input grad
Shape test	参数 Shape 与 Gradient Shape 是否一致
Gradient Check	analytic / numeric / abs error / max error
ReLU gate	z1 / mask / 对应 dW1 列范数
Update	lr / 更新前 Loss / 更新后 Loss
Batch	B / reduction / batch loss / dW Shape
Autograd	NumPy 与 PyTorch 最大差异

十三、常见实验错误与排查顺序

dW Shape 不对：先检查是否忘记 X^T 或 A^T 。

dX Shape 不对：检查是否用了 W 而不是 W^T 。

ReLU 后仍向负区间传梯度：检查 mask 是否按 Forward 的 z 计算。

Gradient Check 只在某些位置失败：检查广播、索引、reduction 或参数是否被原地修改后未恢复。

Batch 梯度整体差一个常数倍：优先检查 mean/sum reduction 和 batch size。

PyTorch 与 NumPy 不一致：先确保 loss 定义完全相同，包括 sum/mean、dtype、bias 和 activation。

十四、实验结论模板

完成实验后，应能用自己的话填写：

问题	结论
为什么 $dW2=A1^T@dY$?	_____
为什么 $dA1=dY@W2^T$?	_____
ReLU gate 对前层梯度有什么影响?	_____
为什么 $dW1$ 与 $W1$ Shape 一样?	_____
Batch 后公式为什么仍成立?	_____
Autograd 实际替我们做了什么?	_____

核心概念：最低闭环标准

如果你能不看讲义解释上面六个问题，并能读懂实验代码中每一行的输入、输出与 Shape，这一讲就达标。