


第25讲练习题与答案

两层 MLP 的 Backpropagation

核心概念：练习题与答案

本讲把上一讲的单神经元 Backpropagation 升级为真正的两层 MLP。目标是看懂每一层的 Tensor、Gradient、Transpose 和 Shape 怎样配合，让最终 Loss 一层一层传回 $W2$ 、 $b2$ 、 $W1$ 、 $b1$ ，最终还能继续传给输入。



建议学习方式：先跟着固定的 3->2->1 数字例子手算，再理解矩阵公式，最后运行 Numerical Gradient Check 与 PyTorch Autograd 对照。

一、练习题

1. 对 $Y=X@W$, 若 $X:(1,3)$ 、 $W:(3,2)$, Y 的 Shape 是什么?
2. 为什么 dW 的 Shape 必须与 W 一样?
3. 对 Linear 层 $Y=X@W+b$, 写出 dW 、 db 、 dX 的矩阵公式。
4. 本讲 $dy_hat=3$, $a1=[3,0]$, 求 $dW2$ 。
5. $W2=[[2],[-1]]$, $dy_hat=3$, 求 $da1$ 。
6. $z1=[3,-2]$ 、 $da1=[6,-3]$, 经过 ReLU 后 $dz1$ 是多少?
7. $x=[1,2,-1]$ 、 $dz1=[6,0]$, 求 $dW1$ 。
8. 为什么 $W1$ 的第二列梯度在本例全部为0?
9. 若 Batch size 从1变成32, $dW = X^T@dY$ 这个结构是否改变?
10. mean reduction 与 sum reduction 为什么可能导致梯度尺度不同?
11. 为什么 dX 对训练深层网络必不可少?
12. 一句话解释: 两层 MLP Backpropagation 的本质是什么?

二、答案与解释

1. (1,2)。内维3消掉，保留样本维1和输出维2。
2. 因为需要告诉 W 中每一个元素自己的局部敏感度，才能逐元素更新参数。
3. $dW=X^T@dY$; $db=\text{沿 batch 维对 } dY \text{ 求和}$; $dX=dY@W^T$ 。
4. $dW2=a1^T@dy_hat=[3], [0]] \times 3=[9], [0]]$ 。
5. $da1=dy_hat@W2^T=3 \times [2, -1]=[6, -3]$ 。
6. $\text{ReLU mask}=[1, 0]$ ，所以 $dz1=[6, 0]$ 。
7. $dW1=x^T@dz1=[[6, 0], [12, 0], [-6, 0]]$ 。
8. 第二个 hidden unit 的 $z1=-2$ ，ReLU 局部导数为0，因此 $dz1_2=0$ ，所有进入该单元的 $W1$ 梯度都被乘成0。
9. 不改变，仍是 $X^T@dY$ ；只是 X 与 dY 的第一维变成 B ，矩阵乘法会自动把样本贡献聚合。
10. mean 会除以样本/元素数量， sum 不除，因此 $d\text{Loss}/d\text{Output}$ 的整体尺度不同，后续所有梯度也会随之缩放。
11. 因为当前层输入通常是上一层输出； dX 就是继续传给上一层的上游梯度。
12. 从 Loss 逆序经过第二层 Linear 、 Activation 、第一层 Linear ，用局部梯度规则同时计算参数梯度并把误差信号继续传向更前面。

三、Shape 训练

请不看答案先补齐：

表达式	结果 Shape
$A1^T (H,B) @ dY (B,O)$	?
$dY (B,O) @ W2^T (O,H)$	?
$X^T (Din,B) @ dZ1 (B,H)$	?
$dZ1 (B,H) @ W1^T (H,Din)$	?

答案依次为：

(H,O), (B,H), (Din,H), (B,Din)