

第 26 讲核心概念速查卡

1. 最小训练闭环

$$\boxed{Forward \rightarrow Loss \rightarrow Backward \rightarrow Update \rightarrow Repeat}$$

参数更新：

$$\boxed{\theta \leftarrow \theta - \eta \nabla_{\theta} L}$$

θ : 参数; η : learning rate; ∇L : Gradient。

2. 两层 MLP Forward

$$Z_1 = XW_1 + b_1$$

$$A_1 = ReLU(Z_1)$$

$$\hat{Y} = A_1W_2 + b_2$$

本讲 Shape:

$$X : (20, 1), W_1 : (1, 8), A_1 : (20, 8), W_2 : (8, 1), \hat{Y} : (20, 1)$$

3. MSE 与输出梯度

$$L = \frac{1}{N} \sum_i (\hat{y}_i - y_i)^2$$

$$\boxed{d\hat{Y} = \frac{2}{N}(\hat{Y} - Y)}$$

4. Linear Backward 三公式

若 $Y = XW + b$:

$$\boxed{dW = X^T dY}$$

$$\boxed{db = \sum dY}$$

$$\boxed{dX = dYW^T}$$

5. ReLU Backward

$$\boxed{dZ = dA \odot \mathbf{1}(Z > 0)}$$

$Z < 0$ 的位置梯度会被门控为 0。

6. 一个 step 到底做什么？

1. 用当前参数 Forward；
2. 算标量 Loss；
3. 反向算所有参数 Gradient；
4. 用 learning rate 更新参数；
5. 下一个 step 重新计算。

7. Gradient Check

$$\frac{\partial L}{\partial \theta} \approx \frac{L(\theta + \epsilon) - L(\theta - \epsilon)}{2\epsilon}$$

用途：检查手写 backward 的符号、转置、Shape、归一化是否可能写错。

8. Learning Rate 直觉

情况	典型表现
太小	Loss 方向正确但下降慢
合适	相对稳定、较快下降
太大	震荡、跨过低点、甚至发散

9. 本讲实际结果

主实验： $lr = 0.03$ ，2000 steps。

$$Loss : 1.3763 \rightarrow 6.50 \times 10^{-5}$$

$$Gradient Norm : 2.636 \rightarrow 0.00177$$

最终 MAE ≈ 0.00499 。

10. 绝对不能混淆

- Training Loss 下降 $\neq$ Generalization 好；
- Gradient 小 $\neq$ 一定到达好 minimum；
- Gradient 决定局部方向，Learning Rate 决定步长；
- Forward 重复很多次但不 Update $\neq$ Training；
- mean / sum reduction 会改变梯度尺度。

11. 与 LLM 的连接

Token Batch $\rightarrow$ Transformer $\rightarrow$ Logits $\rightarrow$ CrossEntropy $\rightarrow$ Backprop $\rightarrow$ AdamW Step

数学骨架与本讲完全相同，只是模型、Loss 和 Optimizer 更复杂。