

## 第 26 讲练习题与答案

### A. 基础概念

1. Forward、Loss、Backward、Update 各自负责什么？
2. “训练 1000 step” 与 “Forward 1000 次” 为什么不是同一句话？
3. Gradient Descent 为什么是  $\theta \leftarrow \theta - \eta g$ ，而不是加号？
4. learning rate 是参数吗？训练过程中它是否像 Weight 一样由 Backprop 自动求梯度？
5. 参数更新以后，为什么下一 step 必须重新 Forward？

### B. Shape 训练

设：

$$X : (32, 10), W_1 : (10, 20), b_1 : (20, ), W_2 : (20, 3), b_2 : (3, )$$

6.  $Z_1 = XW_1 + b_1$  的 Shape？
7.  $A_1 = ReLU(Z_1)$  的 Shape？
8. 最终  $\hat{Y} = A_1W_2 + b_2$  的 Shape？
9. 如果  $d\hat{Y} : (32, 3)$ ， $dW_2 = A_1^T d\hat{Y}$  的 Shape？
10.  $dA_1 = d\hat{Y}W_2^T$  的 Shape？
11.  $dW_1 = X^T dZ_1$  的 Shape？

### C. 数字题

12. 当前  $w = 3$ ， $dL/dw = 4$ ， $lr = 0.1$ 。更新后  $w$ ？
13. 当前  $b = -1$ ， $dL/db = -0.5$ ， $lr = 0.02$ 。更新后  $b$ ？
14. Batch size  $N = 10$ ，某样本  $\hat{y} - y = 2$ 。MSE 的  $dL/d\hat{y}$  是多少？
15. 某次训练 Loss 从 2.0 降到 1.2，能否说明 backward 一定完全正确？为什么？

### D. Debug 思维

下面代码存在什么核心问题？

```
for step in range(1000):  
    pred, cache = forward(X, params)  
    loss = mse(pred, Y)  
    grads = backward(pred, Y, cache)  
    params = params + lr * grads
```

再看：

```
for step in range(1000):  
    pred, cache = forward(X, params)  
    loss = mse(pred, Y)  
    print(loss)
```

为什么它不会训练？

## E. 科研判断

16. 一个论文方法 Training Loss 更低，能否直接说明 Test performance 更好？
17. 比较两种 learning rate 时，为什么应该尽量固定数据、初始化和训练步数等其他条件？
18. Gradient Check 为什么不是正式训练时每一步都做？
19. 如果 Gradient Norm 很小但 Loss 仍然很高，你会想到哪些可能性？至少写两条。

## 答案

1. Forward 算预测；Loss 量化错误；Backward 算 Loss 对参数的梯度；Update 修改参数。
2. Training step 通常包含一次参数更新；只 Forward 不改变参数，不会学习。
3. Gradient 指向 Loss 局部上升最快方向，所以要沿负梯度下降。
4. Learning rate 是超参数，不是普通 Weight；基本 Gradient Descent 中不会通过 Backprop 自动学习。
5. 因为参数已经变了，预测、Loss 和当前局部 Gradient 都会随之变化。
6. (32, 20)。
7. (32, 20)。
8. (32, 3)。
9.  $(20, 32) @ (32, 3) = (20, 3)$ 。
10.  $(32, 3) @ (3, 20) = (32, 20)$ 。
11.  $(10, 32) @ (32, 20) = (10, 20)$ 。
12.  $w_{new} = 3 - 0.1 \times 4 = 2.6$ 。
13.  $b_{new} = -1 - 0.02 \times (-0.5) = -0.99$ 。
14.  $2(2)/10 = 0.4$ 。
15. 不能。即使某些梯度写错，某一步也可能偶然降低 Loss；应结合 gradient check、对照实现、更多 step 等验证。
16. 更新方向写反了。普通 Gradient Descent 应该减去  $lr \times grad$ 。
17. 缺少 Backward 和参数 Update；每次都在用同一组参数，因此只是重复评估同一个模型。
18. 不能。还需要 Validation/Test；更低 Training Loss 可能伴随 overfitting。
19. 这是控制变量，否则无法把结果差异归因给 learning rate。
20. 数值梯度需要对参数元素重复额外 Forward，成本很高，只适合小规模 Debug。
21. 可能接近 stationary point；可能处在 plateau；可能 vanishing gradient；也可能 ReLU 路径被关闭等。必须结合 Loss、激活、参数和验证指标分析。