

第 28 讲练习题与答案

PyTorch Linear 与 Activation

练习题

1. `nn.Linear(5,3)` 的 `weight.shape`、`bias.shape` 分别是什么？总参数量是多少？
2. 已知 PyTorch 保存：

$$W = \begin{bmatrix} 1 & 2 \\ -1 & 0.5 \end{bmatrix}, \quad b = [0.5, -0.5]$$

输入：

$$x = [2, -1]$$

请手算 `nn.Linear(2,2)` 的输出。

3. 输入 Tensor Shape 为 $(32, 128, 768)$ ，经过 `nn.Linear(768, 3072)` 后 Shape 是什么？哪个维度发生了变化？
4. 为什么 PyTorch 的 `Linear(3,2)` 保存 `weight.shape=(2,3)`，但前面课程常写 $X : (B, 3)$ 、 $W : (3, 2)$ ？这是否矛盾？
5. 输入 $z = [-2, 0, 3]$ ，经过 ReLU 后是什么？Shape 会不会变化？
6. 一个 MLP: `Linear(4,8) -> GELU -> Linear(8,4)`。请计算总参数量。
7. 判断正误：普通 `nn.ReLU()` 有自己的 Weight 和 Bias，所以会增加模型参数量。
8. 判断正误：如果输入为 (B, T, D) ，普通 `nn.Linear(D,0)` 会自动让不同 Token 之间交换信息。
9. 为什么实验中人为给 `linear.weight` 赋固定值时使用 `torch.no_grad()`？
10. 写出下面 PyTorch 代码所代表的数学/结构过程：

```
x = linear1(x)
x = gelu(x)
x = linear2(x)
```

并说明哪些步骤通常改变最后一维 Shape，哪些通常不改变。

答案与解释

1. `weight.shape=(3,5)`, `bias.shape=(3,)`。参数量：

$$5 \times 3 + 3 = 18$$

2. 第一输出：

$$2 \times 1 + (-1) \times 2 + 0.5 = 0.5$$

第二输出：

$$2 \times (-1) + (-1) \times 0.5 - 0.5 = -3.0$$

所以：

$$y = [0.5, -3.0]$$

3. 输出 Shape：

$$(32, 128, 3072)$$

Batch 维 32 和 Token 维 128 保留，最后一维 768 被映射到 3072。

4. 不矛盾。PyTorch 把每个输出神经元的 Weight 存成一行，因此保存 (out, in) 。批量输入每个样本按行存放时，前向等价于：

$$XW^T + b$$

如果课程把 Weight 写成 (in, out) ，则写作 $XW + b$ 。只是记法/存储约定不同。

5. ReLU 输出：

$$[0, 0, 3]$$

逐元素 ReLU 通常不改变 Shape，所以仍然是 $(3,)$ 。

6. 第一层参数：

$$4 \times 8 + 8 = 40$$

第二层参数：

$$8 \times 4 + 4 = 36$$

总计：

$$76$$

GELU 没有普通 Weight/Bias，不增加这里的可训练参数。

7. 错。普通 ReLU 没有可训练 Weight 与 Bias。

8. 错。Linear 主要对每个 Token 的最后一维独立应用同一套映射。Token 之间的直接信息交互通常由 Attention 等机制完成。

9. 因为 Weight/Bias 是需要梯度的 Parameter。实验只是想把参数替换成已知值进行数值核对，不希望这个赋值动作被 Autograd 记录。

10. 对应：

$$X \xrightarrow{\text{Linear}_1} Z_1 \xrightarrow{\text{GELU}} A_1 \xrightarrow{\text{Linear}_2} Y$$

Linear 通常可以改变最后一维；GELU 通常只逐元素改变数值，Shape 不变。

自测标准

如果你能不看答案完成第 1、2、3、4、6、10 题，并能解释“为什么”，说明本讲核心已经掌握。