

第 31 讲实验设计文档

PyTorch Training Loop：五步闭环与缺失步骤对照实验

一、实验目的

本实验不是比较模型性能，而是验证标准 PyTorch Training Loop 中每一步的职责：zero_grad 是否清旧梯度，Forward 是否只计算预测，Backward 是否只计算梯度，Optimizer Step 是否才真正修改 Parameter，以及省略某一步会发生什么。

二、研究问题 (RQ)

1. RQ1: Backward 后 Parameter 本身是否变化?
2. RQ2: Optimizer Step 是否会根据已存在的 .grad 修改 Parameter?
3. RQ3: 标准 Training Loop 能否让最小 Linear 模型学会 $y = 2x + 1$?
4. RQ4: 不执行 zero_grad 时 Gradient 是否发生累加?
5. RQ5: 不执行 backward 时, step 是否拥有新的 Gradient 信息?
6. RQ6: 不执行 step 时, 仅重复 Forward/Backward 能否让 Loss 下降?
7. RQ7: torch.no_grad() 是否保持 Forward 数值但关闭梯度跟踪?

三、实验对象与控制变量

数据:

$$X \in [-2, 2], \quad N = 41, \quad Y = 2X + 1$$

模型:

$$\hat{Y} = XW^T + b, \quad \text{Linear}(1, 1)$$

设置:

- 随机种子: 31;
- Loss: MSE;
- Optimizer: SGD;
- Learning Rate: 0.05;
- 主训练 Step 数: 120;
- 对照实验尽量使用相同初始化。

四、实验假设

- H1: Backward 后 `.grad` 出现, 但 Parameter 数值不变。
- H2: Step 后 Parameter 数值改变, 且在本例中一步更新后 Loss 下降。
- H3: 标准训练最终 $w \approx 2, b \approx 1$, Loss 接近 0。
- H4: 相同 Loss 连续 backward 两次且不清梯度时, Gradient 约变成 2 倍。
- H5: grad 为 None 时直接 step, 不会得到本轮有效更新。
- H6: 只 backward 不 step 时, Parameter 不变, Loss 重复保持不变。
- H7: `no_grad()` 与普通 Forward 数值一致, 但输出不要求梯度。

五、实验 1: 拆解一次 Training Step

依次记录:

1. zero grad 前后的 `weight.grad`;
2. Forward 后 Prediction Shape 与 Loss;
3. Backward 后 `dL/dweight`、`dL/dbias`;
4. Backward 前后 Parameter 是否改变;
5. Step 后 Parameter 是否改变;
6. 更新前后 Loss。

实际关键结果:

$$L : 10.37241 \rightarrow 7.76556$$

Backward 后 Parameter 未改变; Step 后 Weight/Bias 均改变。

六、实验 2: 标准 Training Loop

核心代码:

```
for step in range(120):
    optimizer.zero_grad()
    pred = model(X)
    loss = criterion(pred, Y)
    loss.backward()
    optimizer.step()
```

实际最终:

$$w = 1.9999996, \quad b = 0.9999963, \quad L \approx 1.70 \times 10^{-11}$$




图 1: 标准 Training Loop 的 Loss 轨迹




图 2: Weight/Bias 向真实参数收敛

七、实验 3：省略 zero grad

同一模型参数不变，连续两次重新 Forward/Backward：

$$g_w^{(1)} = -7.11323$$

$$g_w^{stored} = -14.22647$$

比例：

$$2.0$$

Bias Gradient 同样为 2 倍。




图 3: 未清零时 Parameter.grad 发生累加

八、实验 4：省略 backward

先执行：

```
optimizer.zero_grad(set_to_none=True)
optimizer.step()
```

此时：

$weight.grad = None, \quad bias.grad = None$

实际 Weight 与 Bias 都未变化。

九、实验 5：省略 step

重复五轮：

$zero_grad \rightarrow forward \rightarrow loss \rightarrow backward$

但故意不 step。

实际五次 Loss 均为：

10.37240982

Weight/Bias 均未变化。

十、实验 6：no grad Evaluation

对训练后的模型，输入 $x = 0.5$ ：

- 普通 Forward：1.9999961853；

- `torch.no_grad()`: 1.9999961853;
- 数值差: 0;
- 普通输出 `requires_grad=True`;
- `no-grad` 输出 `requires_grad=False`。

十一、实验结果判定

实验	预期	实际
Backward	产生 Gradient, 不改 Parameter	符合
Step	使用 Gradient 修改 Parameter	符合
标准循环	学到 $w = 2, b = 1$	符合
无 zero grad	Gradient 累加	2 倍, 符合
无 backward	无新 Gradient Update	参数不变
无 step	有 Gradient 但不训练	Loss/参数不变
no grad	数值相同, 不跟踪 Gradient	符合

十二、科研意义与实验边界

【科研意义】这是一组训练管线 sanity checks。复杂模型出现“不收敛、效果随机、某层不学习”时，先检查 Parameter 是否注册、Gradient 是否为 None/NaN、zero grad 是否正确、step 是否执行、train/eval mode 是否正确，成本远低于直接怀疑模型结构。

【边界】本实验只验证优化闭环能在训练数据上工作。Training Loss 接近 0 并不能证明 Generalization，也不能说明 SGD/当前 Learning Rate 对其他任务最优。Optimizer 的机制将在后续课程单独学习。

十三、建议保存的最小训练日志

以后做小规模实验，至少记录：

- Step / Epoch;
- Train Loss;
- Validation Loss/Metric (当进入数据划分后);
- Learning Rate;
- 关键 Gradient norm;
- 随机种子;
- 模型/Optimizer 配置;
- checkpoint 与代码版本。