

第 32 讲实验设计

Dataset、DataLoader 与 Mini-Batch

从手工切片到真正的 PyTorch 数据管线

1 实验目标

本实验不是为了“练 API”，而是验证下面 8 个可检验问题：

1. Dataset 的一个索引是否确实对应一个 Sample？
2. shuffle=False 时，DataLoader 是否等价于顺序手工切 Batch？
3. drop_last 是否只决定是否保留最后不足 Batch 的部分？
4. shuffle=True 是否只改变顺序而不改变样本集合？
5. 自定义 Dataset 的 `__len__` / `__getitem__` 是否足以被 DataLoader 使用？
6. Epoch、Batch、Step 数量关系是否与公式一致？
7. DataLoader 是否能无缝接入第 31 讲 Training Loop？
8. Mini-Batch Training 是否会出现 Step Loss 波动但长期下降？

2 实验环境与可复现设置

代码：lesson32_dataset_data_loader_experiment.py。

实际运行环境：

- Python 3.13.5；
- PyTorch 2.10.0+cpu；
- 当前验证环境 CUDA unavailable；
- shuffle 实验使用固定 `torch.Generator().manual_seed(...)`；
- 模型训练使用 `torch.manual_seed(32)`。

固定 Seed 的目的不是让结果“更好”，而是减少随机性，使同一个实验可以复现和公平比较。

3 实验 1：Sample、Feature、Label 与 TensorDataset

设计

构造：

$$X = [0, 1, \dots, 9]^T$$

$$Y = 3X - 2$$

所以：

$$X.shape = (10, 1), \quad Y.shape = (10, 1)$$

预期

dataset[3] 应返回：

$$x = 3, \quad y = 7$$

实际结果

```
len(TensorDataset) = 10
basic_dataset[3] -> x = [3.0] y = [7.0]
```

结论

TensorDataset 把第 0 维对齐的 Tensor 按索引组织成 Sample。

4 实验 2：手工切 Batch vs DataLoader

设计

$$N = 10, \quad B = 4$$

手工：

```
for start in range(0, len(X), 4):
    xb = X[start:start+4]
```

与：

```
DataLoader(dataset, batch_size=4,
            shuffle=False, drop_last=False)
```

对照。

实际结果

两者均得到：

[0, 1, 2, 3], [4, 5, 6, 7], [8, 9]

程序判断：

手工切片与 DataLoader 完全一致：True




图 1: N=10, B=4 时最后一个 Batch 只有 2 个样本

5 实验 3: drop_last

变量

唯一改变：drop_last=False / True。

结果

```
drop_last=False batch sizes = [4, 4, 2]
drop_last=True  batch sizes = [4, 4]
```

结论

drop_last=True 会舍弃最后不足一个完整 Batch 的样本。

6 实验 4: Shuffle

固定 Dataset，分别使用两个 Seed。

实际顺序之一：

[4, 5, 7, 2, 8, 3, 1, 0, 9, 6]

顺序与原始不同，但排序以后仍然得到 0-9。

Shuffle 改变样本访问顺序，但样本集合没有改变




图 2: Shuffle 改变样本访问顺序，但没有改变样本集合

7 实验 5：自定义 Dataset

实现：

```
class ToyRegressionDataset(Dataset):
    def __len__(self):
        return len(self.x)

    def __getitem__(self, idx):
        return self.x[idx], self.y[idx]
```

DataLoader 成功得到三个 Batch：

$(5, 1), (5, 1), (2, 1)$

说明 DataLoader 不要求 Dataset 必须是 TensorDataset，只要求它遵守 Dataset 接口。

8 实验 6：Epoch / Batch / Step 精确计数

设置：

$$N = 23, \quad B = 6, \quad epochs = 3$$

理论：

$$\lceil 23/6 \rceil = 4 \text{ batches/epoch}$$

$$3 \times 4 = 12 \text{ steps}$$

实际：

```
epoch=0 ... cumulative_steps=4
epoch=1 ... cumulative_steps=8
epoch=2 ... cumulative_steps=12
```

理论与实测一致。

9 实验 7: DataLoader 接入 Training Loop

数据

$$y = 3x - 2$$

共 80 个 Sample。

DataLoader

$$batch_size = 8$$

所以：

$$len(loader) = 10$$

20 Epoch 理论 200 Step。

模型

$$\hat{y} = wx + b$$

Loss: MSE; Optimizer: SGD; Learning Rate=0.05。

实际训练轨迹

Epoch	Mean Batch Loss	Weight	Bias
0	3.74251431	2.503408	-1.459738
1	0.26123108	2.885195	-1.814344
2	0.02348245	2.973093	-1.937012
4	0.00024419	2.998541	-1.992505
9	$\approx 10^{-8}$	2.999999	-1.999963
19	$\approx 1.8 \times 10^{-13}$	3.000000	-2.000000

总 Step:

200

与理论完全一致。




图 3: 每一个 Mini-Batch Step 的 Loss




图 4: 每个 Epoch 的 Mean Batch Loss

10 实验变量与科研解释边界

项目	说明
控制变量	数据、模型、Loss、Optimizer；对照 shuffle/drop_last 时只修改目标参数
自变量	batch_size、shuffle、drop_last、Epoch 数
因变量	Batch Shape、顺序、Step 数、Loss、最终参数
可复现控制	manual seed / Generator seed
边界	本实验只说明数据管线和优化闭环工作；不能推出真实复杂任务上的泛化表现

11 建议你亲手做的三次改动

1. 把 batch_size=8 改成 16，预测每 Epoch Step 数，再运行验证；
2. 把 shuffle=True 改成 False，观察该简单线性任务是否仍能收敛；
3. 把样本数改成 83，观察最后一个 Batch Size，并自己计算总 Step。

12 实验结论

Dataset 决定“一个 Sample 是什么”；DataLoader 决定“怎样抽取并组成 Batch”；每个 Batch 驱动一次标准 Training Step；多个 Batch 构成一个 Epoch。至此，PyTorch 最小训练闭环的数据入口已经补齐。