

第 32 讲核心概念速查卡

核心链： Dataset 定义单个 Sample -> DataLoader 负责取样/打乱/组 Batch -> Mini-Batch 进入 Training Step。

1. 基本术语

术语	含义
Sample	一个训练/评估单位，例如一张图、一条文本、一条 trajectory
Feature / Input	模型输入
Label / Target	监督学习目标
Dataset	能回答 <code>len(dataset)</code> 与 <code>dataset[idx]</code>
Batch	一次同时处理的一组 Sample
Mini-Batch	比整个 Dataset 小的一批 Sample
Epoch	Dataset 被完整遍历一轮
Step	通常指一次 Optimizer Update

2. Dataset 最小接口

```
class MyDataset(Dataset):
    def __len__(self):
        return N

    def __getitem__(self, idx):
        return x, y
```

3. DataLoader

```
loader = DataLoader(
    dataset,
    batch_size=32,
    shuffle=True,
    drop_last=False,
    num_workers=0,
)
```

4. Batch 数量

若 `drop_last=False`:

$$\text{batches/epoch} = \lceil N/B \rceil$$

若 `drop_last=True`:

$$\text{batches/epoch} = \lfloor N/B \rfloor$$

5. 标准双层训练循环

```
for epoch in range(num_epochs):
    for xb, yb in loader:
        optimizer.zero_grad()
        pred = model(xb)
        loss = loss_fn(pred, yb)
        loss.backward()
        optimizer.step()
```

6. 常见 Shape

任务	单 Sample	Batch
回归	(D)	(B, D)
图像	(C, H, W)	(B, C, H, W)
Token IDs	(T)	(B, T)
Embedding	(T, D)	(B, T, D)

7. 参数含义

- `shuffle=True`: 改变 Sample 访问顺序, 不改变样本集合;
- `drop_last=True`: 丢弃最后不足一个 Batch 的部分;
- `num_workers`: 并行准备数据的 worker 数; 零基础实验先用 0;
- `collate_fn`: 定义多个 Sample 怎样组成一个 Batch。

DataLoader 默认不会自动把 Batch 放到 GPU; 通常仍需要 `xb=xb.to(device)`。

Epoch Loss 若要严格按 Sample 平均, 最后一个 Batch 较小时应按 batch size 加权, 而不是简单平均各 Batch 的 mean loss。