

第 32 讲练习题与答案

练习 1: Sample 与 Batch

一个图像分类 Dataset 中，单张 RGB 图像 Shape 为 $(3, 224, 224)$ ，Batch Size=16。问 Batch 图像 Tensor Shape 是什么？

答案：

$$(16, 3, 224, 224)$$

DataLoader 把 16 个单样本沿新的 Batch 维堆叠。

练习 2: Batch 数量

Dataset 有 $N = 100$ 个样本，Batch Size=32，drop_last=False。一个 Epoch 有多少 Batch？最后一个 Batch 多大？

答案：

$$\lceil 100/32 \rceil = 4$$

前三个 Batch 各 32，最后：

$$100 - 96 = 4$$

个样本。

练习 3: drop_last

如果上一题改为 drop_last=True，一个 Epoch 实际使用多少样本？

答案：3 个 Batch，共 $3 \times 32 = 96$ 个样本，最后 4 个被丢弃。

练习 4: Epoch 与 Step

$N = 1000$ ，Batch Size=100，训练 5 Epoch，不做 Gradient Accumulation。总 Optimizer Step 数是多少？

答案：

$$10 \text{ steps/epoch} \times 5 = 50 \text{ steps}$$

练习 5: Shuffle

判断：shuffle=True 会把 X 和 Y 分别随机打乱，因此可能破坏它们的对应关系。

答案：错误。正常 Dataset 中 (x, y) 是一个 Sample，DataLoader 打乱的是 Sample 索引，x 与其对应 y 一起移动。

练习 6: Dataset 最小职责

为什么自定义 Dataset 一般要实现 `__len__` 和 `__getitem__`？

答案：`__len__` 告诉系统样本总数；`__getitem__` 定义给定索引时如何得到一个 Sample。Dataset 不负责 backward 或 optimizer update。

练习 7: LLM Shape

一条 tokenized 序列长度 $T = 512$, Batch Size=8。问 `input_ids` 常见 Shape 是什么？进入 Embedding 后若 hidden size $D = 768$, Shape 又是什么？

答案：

$$\text{input_ids} : (8, 512)$$

Embedding 后：

$$(8, 512, 768)$$

练习 8: 找 Bug

代码：

```
loader = DataLoader(dataset, batch_size=64, drop_last=False)
for xb, yb in loader:
    assert xb.shape[0] == 64
```

为什么可能报错？

答案：如果 Dataset 大小不能被 64 整除，最后一个 Batch 小于 64。除非使用 `drop_last=True`，否则不应假设每个 Batch 的第 0 维都固定为 64。

练习 9: 科研统计口径

三个 Batch 大小分别为 $[4, 4, 2]$ ，它们的 mean loss 分别为 $[1, 1, 5]$ 。直接平均 Batch mean 得到多少？按 Sample 加权的 Epoch mean 又是多少？

答案：简单 Batch 平均：

$$(1 + 1 + 5)/3 = 2.3333$$

Sample-weighted：

$$\frac{1 \times 4 + 1 \times 4 + 5 \times 2}{10} = 1.8$$

两者不是同一个统计量。

练习 10: 思考题

为什么 Validation/Test 一般不需要 `shuffle=True`？

答案：如果最终指标是顺序无关的总体平均，`shuffle` 通常不会改变指标，但也没有必要；固定顺序更利于复现、逐样本对照和 Debug。时间序列等任务更可能明确不能随便打乱。