

第 33 讲实验设计：Gradient Descent、Learning Rate 与参数轨迹

1 实验目的

本实验不追求复杂模型，而是验证 Gradient Descent 最核心的因果链：

Gradient $\rightarrow$ Update $\rightarrow$ Parameter Change $\rightarrow$ Loss Change

并观察 Learning Rate 与局部近似的影响。

2 研究问题与假设

1. RQ1: 沿负梯度做足够小的一步，Loss 是否下降？
H1: 在平滑 Loss 的局部区域会下降。
2. RQ2: 不同 Learning Rate 会怎样改变收敛轨迹？
H2: 太小会慢，适中较快，过大会发散。
3. RQ3: `torch.optim.SGD` 的最简单一步是否等价于手工 $w \leftarrow w - \eta g$ ？
H3: 在无 Momentum、Weight Decay 等附加项时应等价。
4. RQ4: Gradient 的一阶预测为什么只在小步附近更可靠？
H4: 随着步长增大，真实曲率影响增大，一阶近似误差上升。

3 控制变量

Learning Rate 对照实验固定：

- 同一个 Loss；
- 同一个初始参数 $w_0 = 8$ ；
- 同样的 Step 数；
- 只改变 Learning Rate。

这样避免把“初始化不同”误判为“学习率不同”。

4 实验 1：一步手算 Gradient Descent

$$L(w) = (w - 3)^2, \quad w_0 = 8, \quad \eta = 0.1$$

预测：

$$\text{Gradient} = 10, \quad w_1 = 7, \quad \text{Loss} : 25 \rightarrow 16$$

实际输出与预测一致。

5 实验 2：多步下降

固定 $\eta = 0.1$ 连续 25 步。关键观测：

- 第 1 步： $w = 7, L = 16$;
- 第 10 步： $w \approx 3.5369, L \approx 0.2882$;
- 第 25 步： $w \approx 3.0189, L \approx 3.57 \times 10^{-4}$ 。




图 1: 多步更新中的 Loss

6 实验 3：Learning Rate 消融

比较：

$$\eta \in \{0.05, 0.2, 0.9, 1.1\}$$

最后结果：

η	20 步后 w	20 步后 Loss
0.05	3.607883	0.369522
0.2	3.000183	约 0
0.9	3.057646	0.003323
1.1	194.688000	36744.289199




图 2: Learning Rate 对收敛轨迹的影响

7 实验 4：二维参数轨迹

$$L = (w_1 - 2)^2 + 4(w_2 + 1)^2$$

从 $(-3, 3)$ 出发, $\eta = 0.12$, 30 步后:

$$(w_1, w_2) \approx (1.99867, -1)$$

$$L \approx 1.77 \times 10^{-6}$$




图 3: 二维 Gradient Descent 轨迹

8 实验 5: 手工更新 vs PyTorch SGD

手工:

$$8 - 0.1 \times 10 = 7$$

PyTorch:

```
optimizer = torch.optim.SGD([p], lr=0.1)
loss.backward()
optimizer.step()
```

结果同样为 7, 绝对差为 0。

9 实验 6: Full-Batch Gradient Descent

数据: 41 个样本, 真实关系:

$$y = 2x + 1$$

每个 Step 都把全部 41 个样本一次性交给模型, 因此是 Full-Batch 基线。80 步后:

$$weight \approx 2, \quad bias \approx 1, \quad Loss \approx 6.07 \times 10^{-14}$$

10 实验 7：一阶近似的有效范围

在 $w_0 = 8$ 处：

$$\text{Gradient} = 10$$

比较：

$$\Delta L_{pred} = \text{Gradient} \times \Delta w$$

与真实：

$$\Delta L_{actual} = L(w + \Delta w) - L(w)$$

结果显示步长从 -0.01 增大到 -5 时，预测误差明显增加。




图 4: 一阶局部近似与真实 Loss 曲线

11 结果解释边界

本实验可以证明：

- 手写更新规则实现正确；
- 当前简单 Loss 中负梯度可有效下降；
- Learning Rate 显著改变训练动力学；
- PyTorch SGD 的基础一步与手工公式一致。

不能据此证明：

- 深度网络总能找到全局最优；
- 任意 Learning Rate 都存在统一最优值；

- Training Loss 下降意味着 Generalization 好；
- Full-Batch GD 一定优于 Mini-Batch SGD。

12 运行方式

```
python lesson33_gradient_descent_experiment.py
```

脚本会打印实验数值，并在 figures/ 中生成所有结果图。