

## 第 33 讲核心概念速查卡

**核心公式:**  $\theta_{t+1} = \theta_t - \eta \nabla L(\theta_t)$

### 四个概念

|                  |                |
|------------------|----------------|
| Backward         | 计算 Gradient    |
| Gradient         | Loss 对参数的局部敏感度 |
| Gradient Descent | 用负梯度规定最基础更新方向  |
| Optimizer        | 自动执行参数更新规则     |

### 为什么是负号？

$\nabla L$  指向局部上升最快方向

所以：

$-\nabla L$  指向局部下降最快方向

### Learning Rate

$$\Delta\theta = -\eta \nabla L$$

- 太小：稳定但慢；
- 合适：较快下降；
- 较大：可能振荡；
- 过大：可能发散。

### PyTorch 对照

```
optimizer.zero_grad()
loss.backward()      # 计算 gradient
optimizer.step()     # 更新 parameter
```

### Full-Batch / SGD / Mini-Batch

|                |                    |
|----------------|--------------------|
| Full-Batch GD  | 每个 Step 用全部训练样本算梯度 |
| SGD (经典)       | 每个 Step 用随机单样本     |
| Mini-Batch SGD | 每个 Step 用随机小批样本    |

**Training Loss 下降只说明训练目标被优化，不能自动推出 Test / Generalization 更好。**

## 训练曲线快速诊断

| 现象             | 优先检查                     |
|----------------|--------------------------|
| 下降很慢           | LR 太小、Gradient 小、模型/数据问题 |
| 强烈震荡           | LR 偏大、Batch Noise        |
| 突然爆炸/NaN       | LR 过大、梯度爆炸、数值稳定          |
| 几乎不动           | grad=None、没 step、梯度太小、断图 |
| Train 降而 Val 升 | 过拟合 / Generalization     |

## 矩阵参数

$$W \leftarrow W - \eta \frac{\partial L}{\partial W}$$

并且：

$$W.shape = W.grad.shape$$

## 一阶近似

$$L(\theta + \Delta\theta) \approx L(\theta) + \nabla L^T \Delta\theta$$

选：

$$\Delta\theta = -\eta \nabla L$$

则局部预计：

$$\Delta L \approx -\eta \|\nabla L\|^2 \leq 0$$

## 科研比较提醒

比较 Learning Rate / Optimizer 时尽量控制：Initialization、Data split、Batch order、训练预算、Scheduler、Seed。