

第 33 讲练习题与答案

练习题

1. 若 $w = 5$, $dL/dw = 4$, Learning Rate=0.1, 一步更新后的 w 是多少?
2. 若 $dL/dw = -3$, Learning Rate=0.2, 参数会增大还是减小? 更新量是多少?
3. 为什么 Gradient Descent 公式中是负号?
4. `loss.backward()` 与 `optimizer.step()` 分别做什么?
5. $L(w) = (w - 2)^2$, 在 $w = 6$ 处求 Gradient, 并用 $\eta = 0.25$ 更新一步。
6. 为什么 Learning Rate 过大, 即使方向是负梯度也可能使 Loss 上升?
7. Full-Batch GD 和 Mini-Batch SGD 最关键的数据差别是什么?
8. 训练 Loss 一直下降, 能否证明模型 Test Accuracy 一定提高? 为什么?
9. 参数矩阵 $W.shape = (4, 3)$, 其 Gradient 的 Shape 通常是什么?
10. 论文比较两种 Optimizer, 如果初始化和 Batch order 都不同, 为什么结论可能不可靠?

参考答案

1. $w_{new} = 5 - 0.1 \times 4 = 4.6$ 。
2. $\Delta w = -0.2 \times (-3) = +0.6$ ，所以参数增大。
3. Gradient 指向当前位置 Loss 局部上升最快方向，因此降低 Loss 应沿其反方向移动。
4. `backward()` 计算并累积 Gradient；`step()` 根据 Optimizer 规则真正修改 Parameter。
5. $dL/dw = 2(w - 2) = 8$ ，更新后 $w = 6 - 0.25 \times 8 = 4$ 。
6. Gradient 是局部一阶信息。步长过大时会走出局部近似范围，可能越过谷底或进入更高 Loss 区域。
7. Full-Batch 每一步用全部训练样本计算 Gradient；Mini-Batch 每一步只用一个小批样本估计 Gradient。
8. 不能。Training Loss 描述训练集优化；Test / Generalization 还取决于未见数据上的表现、数据泄漏、过拟合等因素。
9. 通常同为 $(4, 3)$ ，因为每个参数元素需要一个对应的偏导数。
10. 因为结果差异可能来自初始化或数据顺序，而不是 Optimizer 本身。公平比较需要尽量控制其他变量。