

# 第 34 讲实验设计

## Full-Batch、SGD、Mini-Batch 与 Gradient Accumulation

《面向 LLM / Agent Systems 科研的深度学习零基础课》

### 1 实验目标

本实验不追求“哪种 Batch Size 最优”，而验证四个可观测现象：

- 1. Mini-Batch Gradient 是 Full-Batch Gradient 的随机估计；
- 2. Batch Size 增大时，Gradient Estimate 波动通常减小；
- 3. Batch Size 改变会同时改变每 Epoch 的 Optimizer Step 数与训练轨迹；
- 4. 正确缩放时，Gradient Accumulation 可以近似复现较大 Batch 的 mean gradient。

### 2 实验数据与变量

构造：

$$y = 3x - 2 + noise$$

数据量：

$$N = 64$$

模型：

$$\hat{y} = wx + b$$

Loss 使用 mean MSE。

| 变量                    | 设置                                            |
|-----------------------|-----------------------------------------------|
| Gradient Noise 实验     | $B = 1, 2, 4, 8, 16, 32, 64$ ，每个 B 随机抽样 500 次 |
| 训练轨迹实验                | $B = 1, 8, 32, 64$ ，相同初始化、相同 LR、30 Epoch      |
| Gradient Accumulation | 一次 Batch=16 vs 4 个 micro-batch=4              |
| 随机性                   | 固定 NumPy / PyTorch seed，保证可复现                 |

### 3 假设

- H1：Batch Size 越小，Mini-Batch Gradient 在 Full Gradient 周围的散布越大；
- H2：Batch Size 增大后，Gradient Estimate 标准差总体下降；

- H3: 相同 Epoch 下, 不同 Batch Size 具有不同 Step 数, 因此训练轨迹不可简单等同;
- H4: 对 4 个等大小 micro-batch 的 mean loss 分别除以 4 后累积梯度, 结果应接近一次性 Batch=16。

## 4 实验 1: Full Gradient 与单样本 Gradient

在固定:

$$w = 0, b = 0$$

处, 完整数据集得到:

$$L = 16.504467$$

$$dL/dw = -8.218764, \quad dL/db = 4.092798$$

单样本 Gradient 的标准差:

$$\text{std}(dL/dw) = 8.939261$$

$$\text{std}(dL/db) = 7.074524$$

说明单个样本给出的局部方向可以和总体 Gradient 有明显偏差。

## 5 实验 2: Batch Size 与 Gradient Noise

每个 Batch Size 随机抽 500 次, 计算 Gradient Estimate。

| B  | std(dw) | std(db) | mean $\ g_B - g_{full}\ $ |
|----|---------|---------|---------------------------|
| 1  | 8.8183  | 7.1767  | 10.2810                   |
| 2  | 6.3813  | 4.8189  | 7.1147                    |
| 4  | 4.2362  | 3.4047  | 4.7569                    |
| 8  | 2.9476  | 2.4251  | 3.4060                    |
| 16 | 2.0359  | 1.4983  | 2.2290                    |
| 32 | 1.1442  | 0.8875  | 1.2611                    |
| 64 | 0       | 0       | 0                         |




图 1: Batch=1、8、32 的 Gradient Estimate 分布。




图 2: Gradient Estimate 标准差随 Batch Size 增大而下降。

## 6 实验 3：相同 Epoch 下的训练轨迹

使用相同初始化：

$$w = -0.8, \quad b = 0.5$$

相同基础 Learning Rate：

$$\eta = 0.05$$

每种 Batch Size 训练 30 Epoch。

| B  | Step/Epoch | Total Step | Final Loss | $(w, b)$          |
|----|------------|------------|------------|-------------------|
| 1  | 64         | 1920       | 0.052726   | (2.9930, -2.0520) |
| 8  | 8          | 240        | 0.042188   | (2.9757, -2.0436) |
| 32 | 2          | 60         | 0.041232   | (2.9867, -2.0415) |
| 64 | 1          | 30         | 0.059228   | (2.9425, -1.9385) |





图 3: 不同 Batch Size 的 Epoch Mean Training Loss。

图 4: 参数  $(w, b)$  的更新轨迹。

本实验固定 Epoch，而非 Step，因此不能根据最终 Loss 排名并宣布某个 Batch Size 普遍最优。它是“现象验证”，不是超参数排行榜。

## 7 实验 4: Gradient Accumulation

取固定 16 个样本。

方案 A:

$$B = 16$$

一次 Forward/Backward。

方案 B:

$$B_{micro} = 4$$

连续 4 个 micro-batch，每次：

$$loss_{scaled} = loss/4$$

Backward 后不立即 step，等 4 次梯度累加完再更新。

结果：

$$\text{Big Batch } dw = -26.13723755$$

$$\text{Accumulated } dw = -26.13724136$$

差：

$$3.815 \times 10^{-6}$$

Bias Gradient 差：

$$1.907 \times 10^{-6}$$




图 5: 一次性大 Batch 与 micro-batch Gradient Accumulation 的对照。

## 8 实验代码结构

完整代码文件：

```
lesson34_sgd_minibatch_experiment.py
```

建议阅读顺序：

1. 先看 `grad_on_batch()`：同一参数点怎样从任意 Batch 算梯度；
2. 看随机 Mini-Batch 重复抽样：怎样估计 gradient noise；
3. 看 `train_with_batch_size()`：DataLoader 与 optimizer 怎样分工；
4. 最后看 Gradient Accumulation：为什么 backward 可以先累积、step 后执行。

## 9 实验结论与边界

1. 本数据上，Batch 越大，Gradient Estimate 的方差明显下降；

2. Mini-Batch 的随机波动是抽样造成的正常现象；
3. 相同 Epoch 不等于相同 Step；比较 Batch Size 必须定义公平预算；
4. `torch.optim.SGD` 不决定 Batch Size；
5. Gradient Accumulation 能改变 effective batch，但不会消除 Forward 本身的计算和激活成本；
6. 本实验是线性回归玩具例子，不直接外推到大型 Transformer 的最优 Batch Size。

**科研复现实验建议：**把 Batch Size、effective batch、LR、steps、epochs、total tokens、accumulation、device count 放在同一张配置表里，否则很容易发生“代码能跑，但实验条件其实不等价”。