

第 34 讲核心概念速查卡

核心问题：每次 Parameter Update，到底用多少训练样本来估计 Gradient？

方法	Batch Size	每次更新	特征
Full-Batch GD	$B = N$	全数据 Gradient	稳定，但一次更新重
SGD（严格）	$B = 1$	单样本 Gradient	更新频繁，噪声大
Mini-Batch SGD	$1 < B < N$	小批平均 Gradient	深度学习常见折中

Full Gradient：

$$g = \frac{1}{N} \sum_{i=1}^N \nabla \ell_i$$

Mini-Batch Gradient：

$$\hat{g} = \frac{1}{B} \sum_{i \in \mathcal{B}} \nabla \ell_i$$

更新公式：

$$\theta_{t+1} = \theta_t - \eta \hat{g}$$

Batch 越小，Gradient Estimate 通常越抖；Batch 越大，通常越接近 Full Gradient。但“越大越好”不是定律。

一个 Epoch 的 Step 数 (drop_last=False)：

$$\text{steps/epoch} = \left\lceil \frac{N}{B} \right\rceil$$

PyTorch 两层职责：

```
DataLoader(..., batch_size=32) # 每次给多少样本
torch.optim.SGD(...)          # 拿到 gradient 后怎么更新
```

Gradient Accumulation

若每张设备只能放 micro-batch：

$$B_{micro}$$

累积 A 次，再 step：

$$B_{effective} \approx B_{micro} \times A$$

多设备时常见：

$$B_{global} = B_{micro} \times A \times D$$

若 micro-batch loss 是 mean，常见做法：

```
loss = loss_fn(pred, y) / accumulation_steps
loss.backward()
```

科研比较时必须问

- 相同 Epoch, 还是相同 Step?
- 相同 seen samples/tokens, 还是相同 wall-clock?
- Learning Rate 是否重新调过?
- 报告的是 micro batch、global batch 还是 tokens/update?
- 是否有 gradient accumulation? 几张 GPU?

不要把“Mini-Batch Loss 抖动”自动判成训练异常；也不要把“小 Batch 有噪声”自动推成泛化一定更好。

本讲一句话

Mini-Batch SGD = 用一小批数据估计 Gradient, 并频繁更新参数。