

第 34 讲练习题

1. 训练集有 $N = 1000$ 个样本, Batch Size=64, drop_last=False。一个 Epoch 有多少个 Optimizer Step? 最后一个 Batch 有多少个样本?
2. 严格意义下, Full-Batch GD、SGD、Mini-Batch SGD 的 Batch Size 分别是什么范围?
3. 4 个样本在当前参数点的单样本 Gradient 分别为 $[2, 4, 6, 8]$ 。求 Full Gradient; 若随机 Batch 取第 1、2 个样本, 求 Mini-Batch Gradient。
4. 为什么不同 Mini-Batch 在同一组参数上会产生不同 Gradient? 这种现象一定表示代码出错吗?
5. 判断: 使用 torch.optim.SGD 时, Batch Size 一定等于 1。说明理由。
6. Dataset 有 6400 个样本。方案 A: Batch=32, 训练 10 Epoch; 方案 B: Batch=128, 训练 10 Epoch。忽略最后 Batch 问题, 两者各执行多少次 Optimizer Step? 是否可以因为 Epoch 相同就称为“训练预算完全相同”?
7. 显存只允许 micro-batch=4, 希望 effective batch=32, 单 GPU。至少需要多少次 Gradient Accumulation? 如果每个 micro-batch Loss 使用 mean reduction, 常见做法怎样缩放 Loss?
8. LLM 训练中, 为什么只报告 “batch size=32” 可能仍不够? 至少再列出三个需要确认的信息。
9. 一个实验发现 Batch=256 的 Validation Accuracy 比 Batch=32 低, 因此作者断言 “大 Batch 天然泛化差”。这个结论还缺少哪些控制或证据?

答案与解析

1.

$$\lceil 1000/64 \rceil = 16$$

所以 16 Step。前 15 批共 $15 \times 64 = 960$ 个，最后一批 40 个。

2. Full-Batch: $B = N$; 严格 SGD: $B = 1$; Mini-Batch: $1 < B < N$ 。工程语境中“SGD training”常也包含 Mini-Batch + SGD optimizer, 要看上下文。

3. Full Gradient:

$$(2 + 4 + 6 + 8)/4 = 5$$

Batch(1,2):

$$(2 + 4)/2 = 3$$

4. 因为每个 Batch 只包含训练集的一部分样本，不同样本对 Loss 的局部贡献不同，所以 Gradient Estimate 会变化。这是随机抽样带来的正常 Gradient Noise，不一定是 Bug。

5. 错。torch.optim.SGD 定义的是参数更新规则；Batch Size 通常由 DataLoader / Sampler 决定。

6. 方案 A: 每 Epoch $6400/32 = 200$ Step, 共 2000 Step。方案 B: 每 Epoch $6400/128 = 50$ Step, 共 500 Step。两者看过的样本轮数相同，但参数更新次数不同，所以不能笼统说预算完全相同。

7.

$$32/4 = 8$$

需要累积 8 个 micro-batch。若每个 micro-batch loss 是 mean，常见写法是：

$$loss_{scaled} = loss/8$$

再逐次 backward，最后 step。

8. 例如：sequence length / 有效 tokens、gradient accumulation steps、GPU 数量、per-device micro batch、global effective batch、drop/padding 处理、tokens per update 等。

9. 至少要控制或报告：Learning Rate 是否重新调参、总 Step / 总 Token / Epoch 是否一致、Warmup 和 Scheduler、随机种子与重复实验、训练是否充分收敛、计算预算是否可比。单一结果不能推出“大 Batch 天然泛化差”。