

第 35 讲

实验设计

Batch、Epoch、Step、Accumulation 与 Token 预算验证

《面向 LLM / Agent Systems 科研的深度学习零基础课》

实验目标

不是训练复杂模型，而是把“计数单位”做成可观察、可复现实验。所有实验均可在 CPU 上完成。

1 实验问题与假设

编号	研究问题	预期假设
H1	drop_last 是否改变 batches/epoch?	False 用向上取整；True 用向下取整。
H2	accumulation 后 micro-batch 与 optimizer step 是否一一对应?	不再对应，约每 A 个 micro-batch 才更新一次。
H3	Epoch 边界处理是否影响总 step?	flush 与跨 Epoch 连续累计可能产生不同 step 总数。
H4	global effective batch 如何计算?	$\text{per-device micro batch} \times \text{devices} \times \text{accumulation}$ 。
H5	scheduler 跟错 step 有什么后果?	每 micro-batch 推进会让 LR schedule 过快。
H6	LLM sequence batch 能否直接等同于有效 token 数?	不能，padding / masking 会改变有效 token。

2 实验环境

- Python 3;
- NumPy;
- PyTorch;
- Matplotlib;
- 不需要 GPU;
- 固定随机种子 35，保证可复现。

3 实验 1: DataLoader 的真实 Batch 划分

自变量: drop_last=False/True。

控制变量: $N = 23$, $B = 6$, shuffle=False。

观测量: len(loader)、每个 Batch 的 size、样本编号范围。

理论预测：

$$\lceil 23/6 \rceil = 4, \quad \lfloor 23/6 \rfloor = 3$$


实际输出应分别出现：

$$[6, 6, 6, 5]$$

与：

$$[6, 6, 6]$$

N=23, batch_size=6：一个 Epoch 怎样被切成 Batch



4 实验 2：micro-batch iteration 与 optimizer step

设：


$$M = 7, \quad A = 3$$

每个 Epoch 结束时 flush 剩余梯度。

预测：

$$\text{optimizer steps/epoch} = \lceil 7/3 \rceil = 3$$

训练 2 Epoch：14 个 micro-batch iteration，但只有 6 次 optimizer step。



5 实验 3: Epoch 边界策略


比较:

- 每个 Epoch 末尾立即 flush;
- 跨 Epoch 连续 accumulation。

在 $M = 7, A = 3, E = 2$ 时:

flush total = 6

continuous total = 5



与科研的关系

复现实验时, 如果目标是严格复现 update 次数和 scheduler 进度, 这个“边界策略”必须从源码确认。配置文件本身未必能说明。

6 实验 4: Global Effective Batch 与 Tokens per Update

设置:

$$B_{micro} = 2, \quad G = 4, \quad A = 8$$


则:

$$B_{global} = 2 \times 4 \times 8 = 64$$

固定 $T = 2048$:

$$64 \times 2048 = 131,072 \text{ token slots/update}$$

进一步构造不同有效长度的 8 条序列，比较 raw slots、valid tokens 与 padding tokens。



7 实验 5: Scheduler 跟错 Step


设置：20 个 micro-batch, $A = 4$, 真正 optimizer step 只有 5 次；初始 LR=0.1，每次 scheduler 乘 0.9。

正确:

$$0.1 \times 0.9^5 = 0.059049$$

错误地每 micro-batch 调 scheduler:

$$0.1 \times 0.9^{20} \approx 0.012158$$



8 实验 6：统一训练预算

设置：

$$N = 1000, B = 128, E = 10, A = 4$$

`drop_last=False`。

应得到：

8 micro-batches/epoch

2 optimizer steps/epoch

80 total micro-batch iterations

20 total optimizer steps

10,000 sample visits

若每条 512 tokens：

5,120,000 raw token slots

9 执行方法

在终端进入本讲目录后执行：

```
python lesson35_batch_epoch_step_experiment.py
```

脚本会：

1. 在终端打印所有关键计数；
2. 在 `figures/` 下生成 5 张 PNG；
3. 不下载任何外部数据；

4. 不需要 GPU。

10 结果判读与科研记录模板

建议实验日志至少记录：

- Dataset Size;
- micro-batch size / per-device batch;
- world size;
- gradient accumulation;
- optimizer steps;
- total sample / token visits;
- scheduler step 定义;
- drop_last / padding / masking / packing;
- random seed;
- 运行环境。

常见误区

本实验只验证计数逻辑，不证明某个 Batch Size、Epoch 数或 Step 数“更优”。优化效果需要单独控制学习率、模型、随机种子、数据顺序和训练预算后再比较。