

第 35 讲

Batch / Epoch / Step 速查卡

训练时间尺度、Gradient Accumulation 与 Token 预算

《面向 LLM / Agent Systems 科研的深度学习零基础课》

用途

这份速查卡用于复习与读论文配置。核心解释请看完整讲义。

1. 三个基础时间尺度

Batch / Micro-batch	一次 forward/backward 实际送入模型的一组样本。
Epoch	常见有限 Dataset 中，训练集被完整遍历一次。
Optimizer Step	一次真正的参数更新，即执行一次 <code>optimizer.step()</code> 。
Global Step	框架自定义全局计数器，必须查实现确认是否等于 optimizer step。

2. 无 Gradient Accumulation

Dataset Size N , Batch Size B :

$$M = \left\lceil \frac{N}{B} \right\rceil \quad (\text{drop_last=False})$$

$$M = \left\lfloor \frac{N}{B} \right\rfloor \quad (\text{drop_last=True})$$

若每 Batch 更新一次:

$$\text{optimizer steps/epoch} = M$$

训练 E Epoch:

$$\text{total optimizer steps} = E \times M$$

3. 有 Gradient Accumulation

累积 A 个 micro-batch 再更新:

$$\text{optimizer steps/epoch} \approx \left\lceil \frac{M}{A} \right\rceil$$

前提: Epoch 末尾把剩余梯度 flush 一次。

常见误区

micro-batch iteration 与 optimizer step 不再相等。读日志里的 “step” 必须确认计数器放在哪里。

4. Global / Effective Batch

单 GPU:

$$B_{effective} = B_{micro} \times A$$

多 GPU 数据并行:

$$B_{global} = B_{micro} \times G \times A$$

其中 G 为 GPU / device 数。

5. LLM Token 预算

固定序列长度 T :

$$\text{raw token slots/update} = B_{global} \times T$$

$$\text{total token slots} = \text{optimizer steps} \times B_{global} \times T$$

Padding / Masking / Packing 存在时, 要进一步区分 raw token slots 与 valid/loss tokens。

6. 常见数字例子

$N = 1000, B = 128, E = 10, A = 4$, `drop_last=False`:

$$M = \lceil 1000/128 \rceil = 8$$

$$\text{optimizer steps/epoch} = \lceil 8/4 \rceil = 2$$

$$\text{total micro-batch iterations} = 80$$

$$\text{total optimizer steps} = 20$$

7. Scheduler / Warmup

如果 `accumulation=A`:

- 每 micro-batch 调一次 scheduler, 学习率计划可能快 A 倍;
- 常见做法是 optimizer update 后再推进 scheduler;
- “warmup 1000 steps” 必须确认 step 的定义。

8. 读论文时必须确认

1. batch size 是 per-device、global 还是 effective?
2. world size / GPU 数是多少?

3. accumulation 是多少?
4. training steps 是 micro-batch 还是 optimizer steps?
5. sequence length / tokens per update 是多少?
6. scheduler / warmup 按哪个 step?
7. drop_last / padding / packing / masking 怎样处理?

记忆句

Epoch 看“数据轮数”；Batch 看“一次吃多少”；Optimizer Step 看“参数改了多少次”；Tokens Seen 看“模型实际处理了多少 Token”。