

# 第 35 讲

## 第 35 讲练习题与答案

Batch、Epoch、Step 与训练预算换算

《面向 LLM / Agent Systems 科研的深度学习零基础课》

### 建议

先独立完成，再看答案。重点不是机械套公式，而是先确认题目里的“step”指哪个层级。

### 练习题

1. Dataset 有 1000 个样本，batch size=128，drop\_last=False。一个 Epoch 有多少个 Batch？最后一个 Batch 有多少样本？
2. 同上，但 drop\_last=True。一个 Epoch 有多少个 Batch？每个 Epoch 实际使用多少样本？
3. Dataset 有 9600 个样本，batch size=64，无 gradient accumulation，训练 5 Epoch。总 optimizer steps 是多少？
4. 一个 Epoch 有 13 个 micro-batch，gradient accumulation steps=4。若 Epoch 末尾 flush 剩余梯度，一个 Epoch 有多少 optimizer steps？
5. micro batch per GPU=2，GPU 数=8，gradient accumulation=16。global effective batch 是多少条序列？
6. 上题如果 sequence length=4096，固定满长度，一次 optimizer update 对应多少 raw token slots？
7. 训练日志写“step=10,000”，但代码每个 DataLoader Batch 都将 step 加 1，同时 accumulation=8。你能否直接断言参数更新了 10,000 次？为什么？
8. 为什么在 accumulation=4 时，每个 micro-batch 都调用一次 scheduler，可能让 LR schedule 提前走完？
9. 两个实验都训练 10 Epoch，一个 batch size=32，一个 batch size=256。能否仅凭“Epoch 相同”说优化预算完全公平？列出至少两项仍然不同的量。
10. Agent 数据由 200 条 trajectory 构成，每条 trajectory 平均 30 个 environment steps。把它拆成约 6000 个 transition 后，为什么不能简单说“样本量从 200 变成了 6000 个独立样本”？
11. 判断：torch.optim.SGD 表示 batch size 必须等于 1。对还是错？说明原因。
12. 判断：在固定 Dataset、固定 batch size、无 accumulation 条件下，总 Epoch 增加一倍，总 optimizer steps 也增加一倍。对还是错？说明边界条件。

## 答案与解释

1.  $\lceil 1000/128 \rceil = 8$  个 Batch。前 7 个共 896 个样本，最后一个为  $1000 - 896 = 104$  个。
2.  $\lfloor 1000/128 \rfloor = 7$  个 Batch。实际使用  $7 \times 128 = 896$  个样本，最后 104 个被丢弃。
3. 每 Epoch:  $9600/64 = 150$  steps; 5 Epoch:  $150 \times 5 = 750$  optimizer steps。
4.  $\lceil 13/4 \rceil = 4$  optimizer steps。前三组各 4 个 micro-batch，最后 1 个 micro-batch 在 Epoch 末 flush。
5.  $2 \times 8 \times 16 = 256$  sequences/update。
6.  $256 \times 4096 = 1,048,576$  raw token slots/update。
7. 不能。若 step 每 DataLoader Batch 加 1，那么它是 micro-batch iteration；在 accumulation=8 时，真正 optimizer step 大约只有其 1/8，还要考虑 Epoch 边界剩余组如何处理。
8. 因为 optimizer 每 4 个 micro-batch 才更新一次；若 scheduler 每 micro-batch 前进一步，则同样 optimizer updates 下 scheduler 走了约 4 倍的步数，LR 会下降/变化得过快。
9. 不能。至少 optimizer step 数不同、gradient noise 不同；此外 wall-clock、scheduler 进度、通信次数、optimizer state update 次数也可能不同。
10. 同一 trajectory 内的 transition 通常高度相关，不能视为 6000 个独立同分布样本。Train/Val/Test 随机按 transition 切分还可能造成同一轨迹泄漏到不同集合。
11. 错。torch.optim.SGD 描述参数更新规则；batch size 由 DataLoader / 数据管线决定。Mini-batch 下使用 SGD optimizer 是常态。
12. 在题目给定边界下基本正确，因为 steps/epoch 固定，所以 Epoch 翻倍总 optimizer steps 也翻倍。但如果改变 drop\_last、accumulation、sampler、动态数据长度或训练中断策略，则未必成立。

### 自检标准

如果你能不看答案直接解释第 7、8、9 题，说明你已经不再把“step”当作单一固定含义，而开始用训练系统的层级来理解日志。