

第 36 讲

实验设计文档

Learning Rate: 步长、稳定性、曲率与 Optimizer

《面向 LLM / Agent Systems 科研的深度学习零基础课》

实验目标

通过可复现实验观察 LR 太小、合适、振荡、发散，以及曲率、Optimizer、Scheduler 对实际更新的影响。

1 实验总问题

本讲不是为了“找到一个万能最佳 LR”，而是回答以下可验证问题：

1. 在同一个 Loss Landscape 上，改变 LR 是否会改变收敛速度、振荡和发散？
2. 稳定 LR 上限是否会被高曲率方向限制？
3. 在相同模型、数据、初始化下，不同 LR 是否产生不同训练轨迹？
4. 相同 nominal LR 在 SGD 与 Adam 中是否对应相同 Parameter Update？
5. Warmup + Cosine 是否可以理解为“每个 optimizer step 使用不同 LR”？

2 实验 1：一维二次函数的精确行为

对象

$$L(w) = (w - 3)^2, \quad w_0 = 8$$

测试：

$$\eta \in \{0.01, 0.1, 0.5, 0.9, 1.0, 1.1\}$$

假设

由：

$$e_{t+1} = (1 - 2\eta)e_t$$


预测：

- 0.01 很慢；
- 0.1 稳定；
- 0.5 一步到最优；
- 0.9 振荡但收敛；
- 1.0 等幅振荡；
- 1.1 发散。

结果

实际 25 步后：

LR	Final w	Final Loss
0.01	6.0173	9.1042
0.1	3.0189	3.57×10^{-4}
0.5	3.0000	0
0.9	2.9811	3.57×10^{-4}
1.0	-2.0000	25
1.1	-473.9811	2.28×10^5



3 实验 2：高曲率方向限制 LR

对象

$$L(w_1, w_2) = \frac{1}{2}(w_1^2 + 20w_2^2)$$

由于 w_2 方向：

$$w_{2,t+1} = (1 - 20\eta)w_{2,t}$$

稳定理论条件：

$$\eta < 0.1$$

变量

测试：

$$\eta = 0.02, 0.08, 0.095, 0.105$$


其他条件保持一致。

结果

$\eta = 0.105$ 超过理论边界, 30 步后 Loss 约为:

$$6.85 \times 10^3$$

而 $\eta = 0.08$ 仍稳定下降。



与科研的关系

这里的目的是不是证明真实神经网络一定有明确的单一曲率常数, 而是建立“稳定步长与局部几何有关”的可观察直觉。


4 实验 3: PyTorch 同初始化 LR 对照

控制变量

- 同一 Dataset: $y = 2x + 1 + \text{小噪声}$;
- 同一 `nn.Linear(1,1)`;
- 同一初始化;
- 同一 SGD;
- 同样 120 optimizer steps;
- 只改变 LR。

结果


LR	Final Loss	结论
10^{-4}	13.302	太慢
10^{-2}	0.0456	稳定下降
10^{-1}	0.00319	本设置中较快且稳定
0.8	9.83×10^{16}	发散



同时记录：

$$\frac{\|\Delta\theta\|}{\|\theta\|}$$

帮助观察实际更新相对于参数量级是否异常。



5 实验 4: SGD 与 Adam 相同 LR 的第一步


起点相同，Loss 相同，因此初始 Gradient 都为：

$$[8, -40]$$

当 LR=0.1:

$$\Delta\theta_{SGD} \approx [-0.8, 4.0]$$

$$\Delta\theta_{Adam} \approx [-0.1, 0.1]$$



原理

Nominal LR 是 Optimizer 配置中的一个超参数，不等于“实际参数每一步统一移动这个数”。跨 Optimizer 比 LR 数值时必须非常谨慎。

6 实验 5: Warmup + Cosine Schedule

设：

$$\eta_{peak} = 3 \times 10^{-4}$$

Warmup 20 steps, 总训练 200 steps。


第 1 步：

$$\eta = 1.5 \times 10^{-5}$$

第 20 步到达：

$$3 \times 10^{-4}$$

之后余弦衰减，最后接近 0。



7 复现实验步骤

1. 确保 Python、NumPy、Matplotlib、PyTorch 可用；
2. 运行: `python lesson36_learning_rate_experiment.py`;
3. 查看终端输出；
4. 对照 第 36 讲 _ 实验实际输出.txt；
5. 打开 figures/ 中的图；
6. 修改一项变量，例如把二维曲率 20 改为 50，再预测稳定 LR 上限如何变化；
7. 再运行验证你的预测。

8 建议扩展实验

1. 固定 LR，改变 Batch Size，观察 Gradient Noise 与 Loss 曲线；
2. 固定 Batch Size，对 LR 做对数扫描；
3. 对同一 LR 重复多个 Random Seed；
4. 记录 Validation Loss，验证 Training Loss 最低是否等于最好泛化；
5. 把 SGD 换成 Momentum、Adam、AdamW，比较 nominal LR 与实际 Update。

实验结论边界

这些实验是为了理解优化机制，不是为了给出真实 LLM 的“最佳学习率”。大型 Transformer 的稳定训练还受模型规模、Optimizer、Warmup、Batch/Tokens、Precision、Initialization、Normalization、Gradient Clipping 等共同影响。