

第 36 讲

核心概念速查卡

Learning Rate 学习率

《面向 LLM / Agent Systems 科研的深度学习零基础课》

用途

用于课后快速复习，不替代完整讲义。

1. 最核心公式

$$\theta_{t+1} = \theta_t - \eta g_t$$

$$\Delta\theta = -\eta g$$

最简单 SGD：Gradient 决定方向与局部坡度，Learning Rate η 控制更新尺度。

2. 一维二次函数的精确直觉

$$L(w) = (w - 3)^2, \quad e_t = w_t - 3$$

$$e_{t+1} = (1 - 2\eta)e_t$$

收敛条件：

$$0 < \eta < 1$$

本例： $\eta = 0.5$ 一步到最优； $\eta = 1$ 等幅振荡； $\eta > 1$ 发散。

3. 三个量不要混

量	含义
$\ g\ $	Gradient Norm, 当前梯度大小
η	Learning Rate, 更新规则的步长缩放
$\ \Delta\theta\ $	参数这一步真正改变多少

SGD 下：

$$\|\Delta\theta\| = \eta\|g\|$$

4. 典型训练现象

- LR 太小：Loss 降得很慢，固定预算内学不够；
- LR 合适：明显下降且整体稳定；
- LR 偏大：跨过谷底、震荡；
- LR 太大：Loss 爆炸、NaN/Inf、参数异常增大。

5. 曲率

二维：

$$L = \frac{1}{2}(w_1^2 + 20w_2^2)$$

陡峭 w_2 方向要求：

$$\eta < 0.1$$

全局 LR 往往受最陡方向限制。

6. Optimizer 与 LR

SGD：

$$\Delta\theta = -\eta g$$

Adam 会用历史一阶/二阶统计量重新缩放 Gradient。因此相同 nominal LR 在 SGD 与 Adam 中不代表相同实际步长。

7. Schedule

$$\eta_t = f(t)$$

常见：Constant、Step Decay、Cosine、Warmup + Decay。Warmup 仍在训练，只是早期 LR 较小。

8. LLM 读配置

看到：

```
optimizer=AdamW
peak_lr=3e-4
warmup_steps=2000
scheduler=cosine
```

继续找：global batch、tokens/update、total steps/tokens、weight decay、gradient clipping、precision、模型规模。

9. 科研最低检查

- 比 LR 时固定初始化、数据、Batch、Optimizer、训练预算；
- Training Loss 最低不等于 Generalization 最好；
- Batch Size 与 LR 有耦合，但 scaling rule 不是普适定律；
- Loss 不降先查训练闭环，不要只会换 LR。